



ML Enablement Workshop #1 : 理解編

# 機械学習の成長サイクルを 理解する

久保 隆宏

Developer Relation  
Machine Learning

# ML Enablement Workshop

プロダクトマネージャー、開発者、データサイエンティストの3者が**組織横断的**にチームを組成し、機械学習による**成長サイクル**を実現する計画を作成する。

## 理解編

### 目的

機械学習の改善がプロダクトの成長につながるサイクルを理解し、自社プロダクトでの実現方法を考えられるようになる。

### アウトプット

自社プロダクトの成長サイクルを表すビジネスモデル図

### 時間

・ ~2時間

## 応用編

### 目的

顧客の視点からプロダクトの体験をたどることで問題点を特定し、改善後の体験をチーム全員で共有できるようになる。

### アウトプット

顧客体験、課題、改善後体験を可視化したボード

### 時間

・ ~3時間

## 開始編

### 目的

改善後の体験実現を最終目標とし、実現可能かつ短期で効果が確認できる最初の計画を立てられるようになる。

### アウトプット

1~3 カ月間の活動と計測指標をまとめた行動計画

### 時間

・ ~2時間

# ML Enablement Workshop のスコープ

加速フェーズ  
1~3 ヶ月

ユースケースを決め、  
仮説検証に着手する

異なるチームとの協調を  
日常的にする

チームで検証を繰り返し  
価値あるユースケースを  
特定する

拡大フェーズ  
1 年～

AI/ML の組織戦略立案

検証を通じ得られた知見をもとに、長期的な AI/ML の投資計画を立て、推進するための組織を組成する。

データ基盤・ML基盤構築

仮説検証の速度、AI/ML の開発速度を速めるためのデータ基盤や ML 基盤の設計と構築。

チームワークの醸成

MLEW から始まったチームワークを組織全体へ波及しつつ、責任ある AI 活用に向けガバナンスを整える

# 理解編の流れ

- |                        |        |
|------------------------|--------|
| 1. 機械学習の成長サイクルを理解する    | 30 min |
| 2. プロダクトで応用できそうな事例の共有  | 10 min |
| 3. 自社版のビジネスモデルキャンバスの作成 | 60 min |

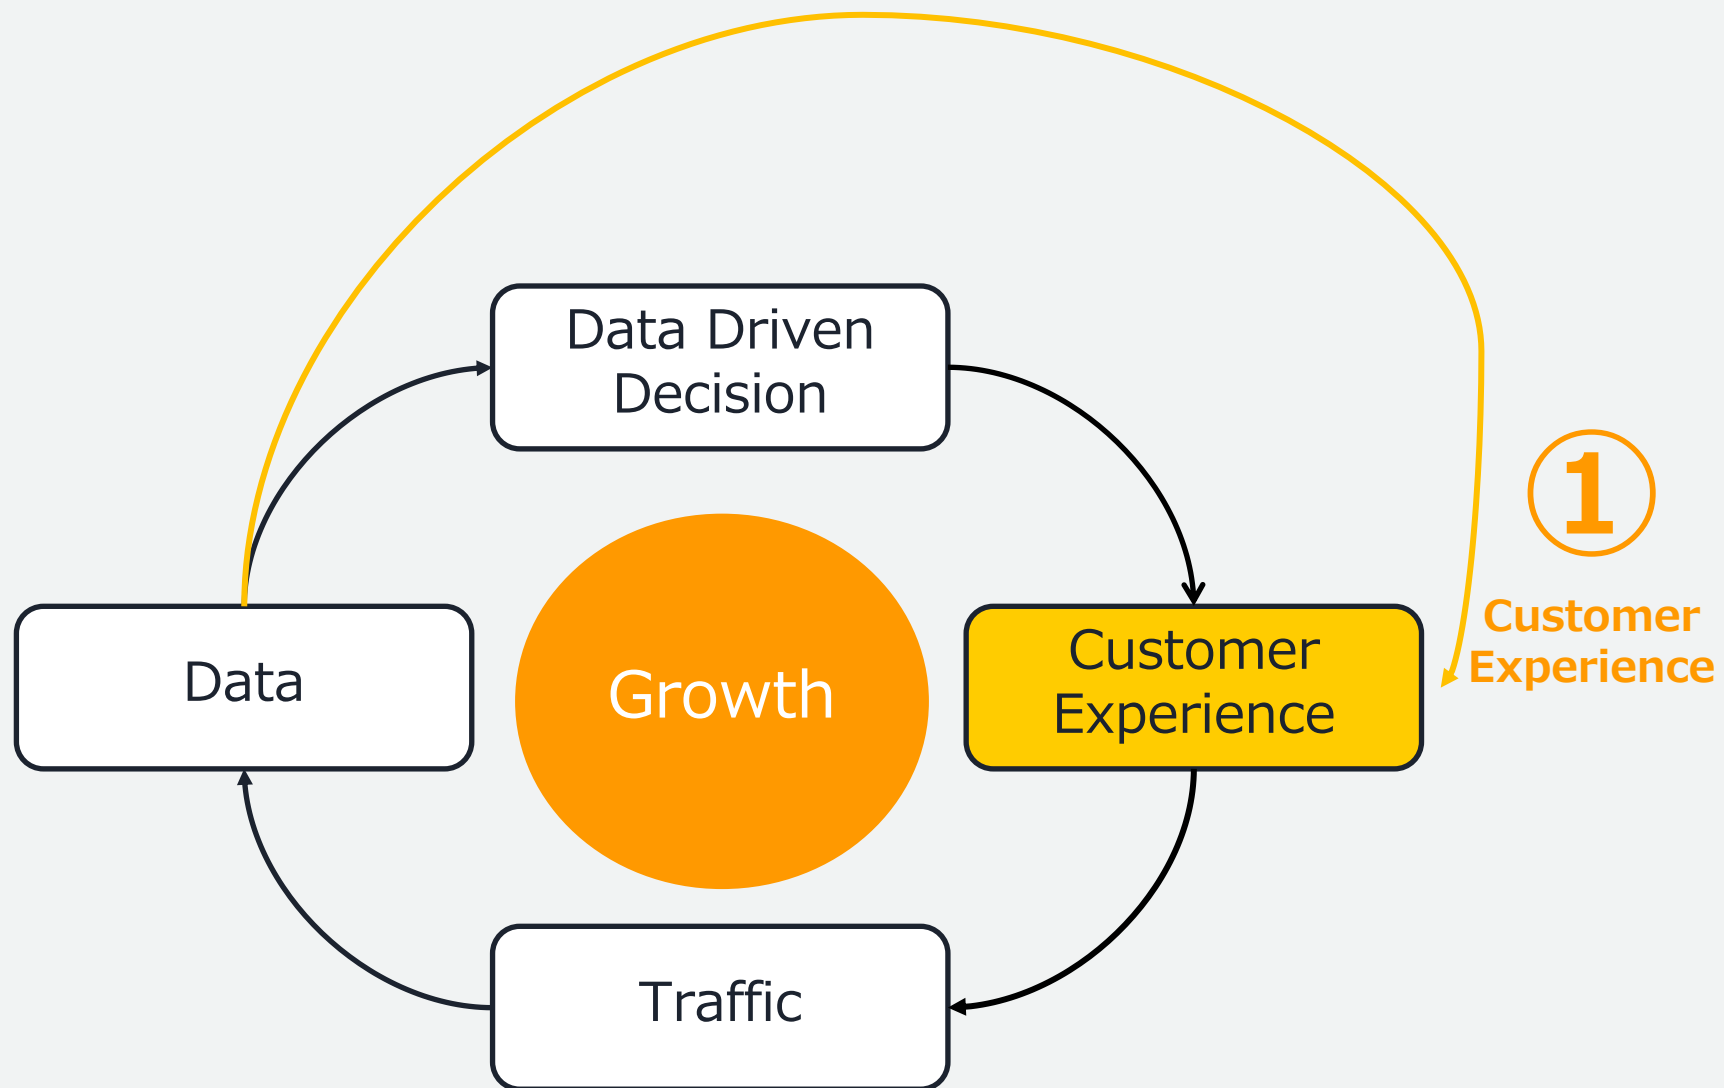
# 理解編の流れ

- |                        |        |
|------------------------|--------|
| 1. 機械学習の成長サイクルを理解する    | 30 min |
| 2. プロダクトで応用できそうな事例の共有  | 10 min |
| 3. 自社版のビジネスモデルキャンバスの作成 | 60 min |

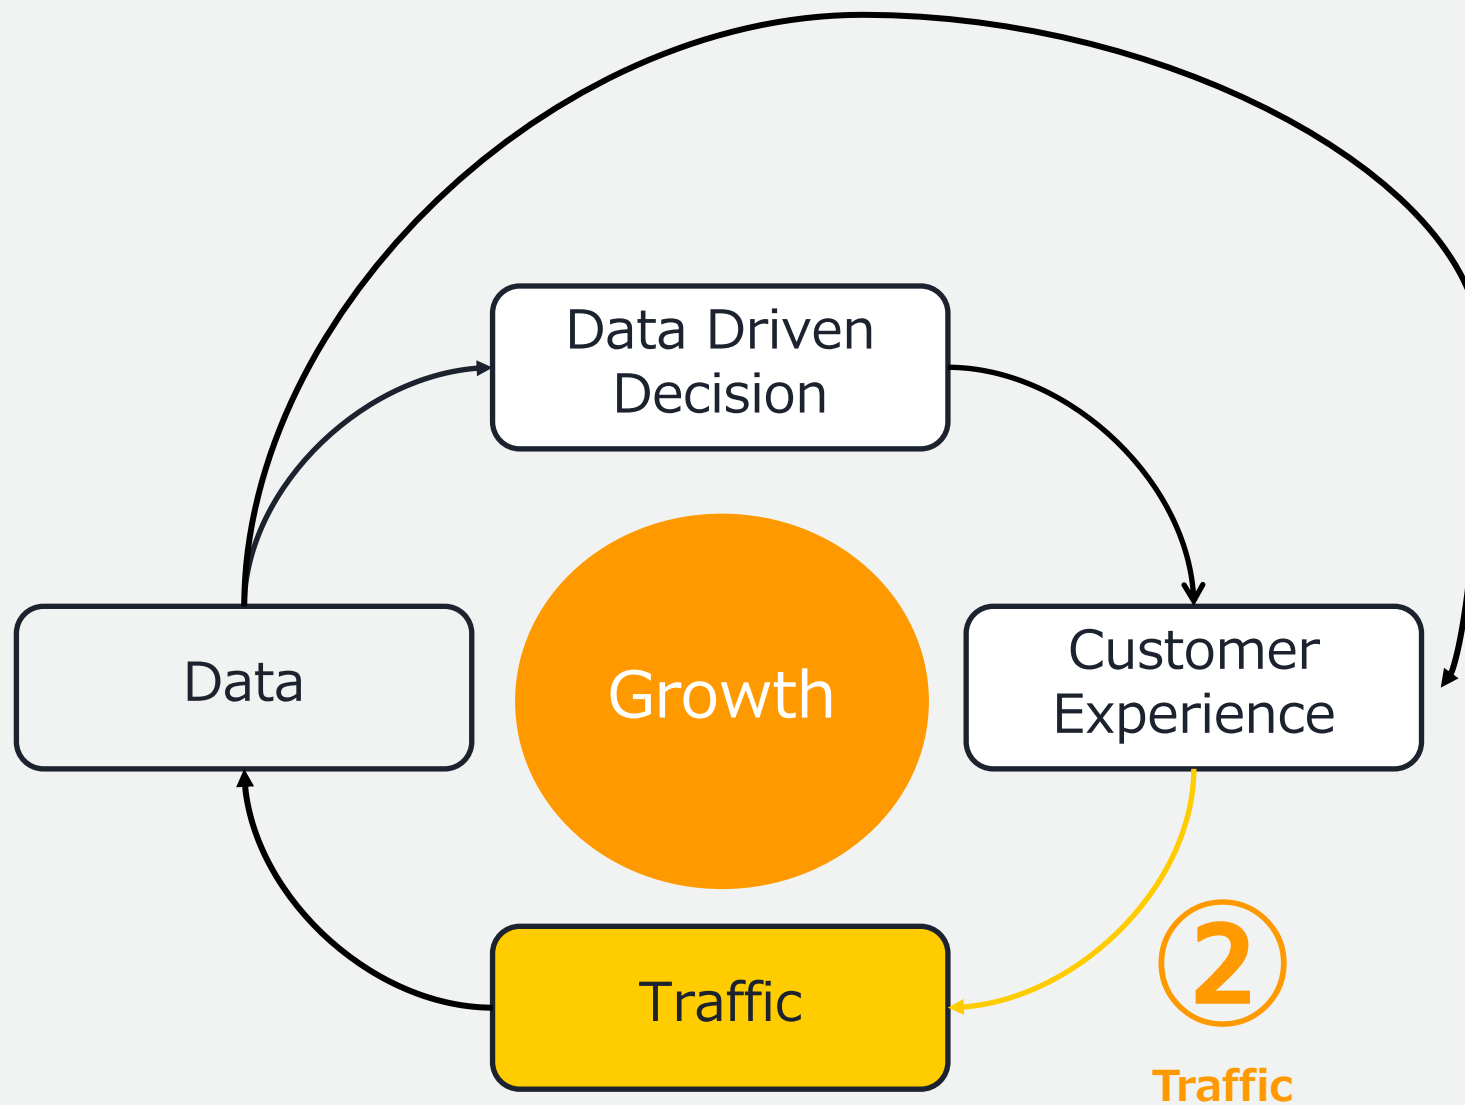
# 機械学習の成長サイクルを理解する

- 機械学習の成長サイクルとは
- 機械学習とは
- 事例から成長サイクルを分析する

# 機械学習の成長サイクル

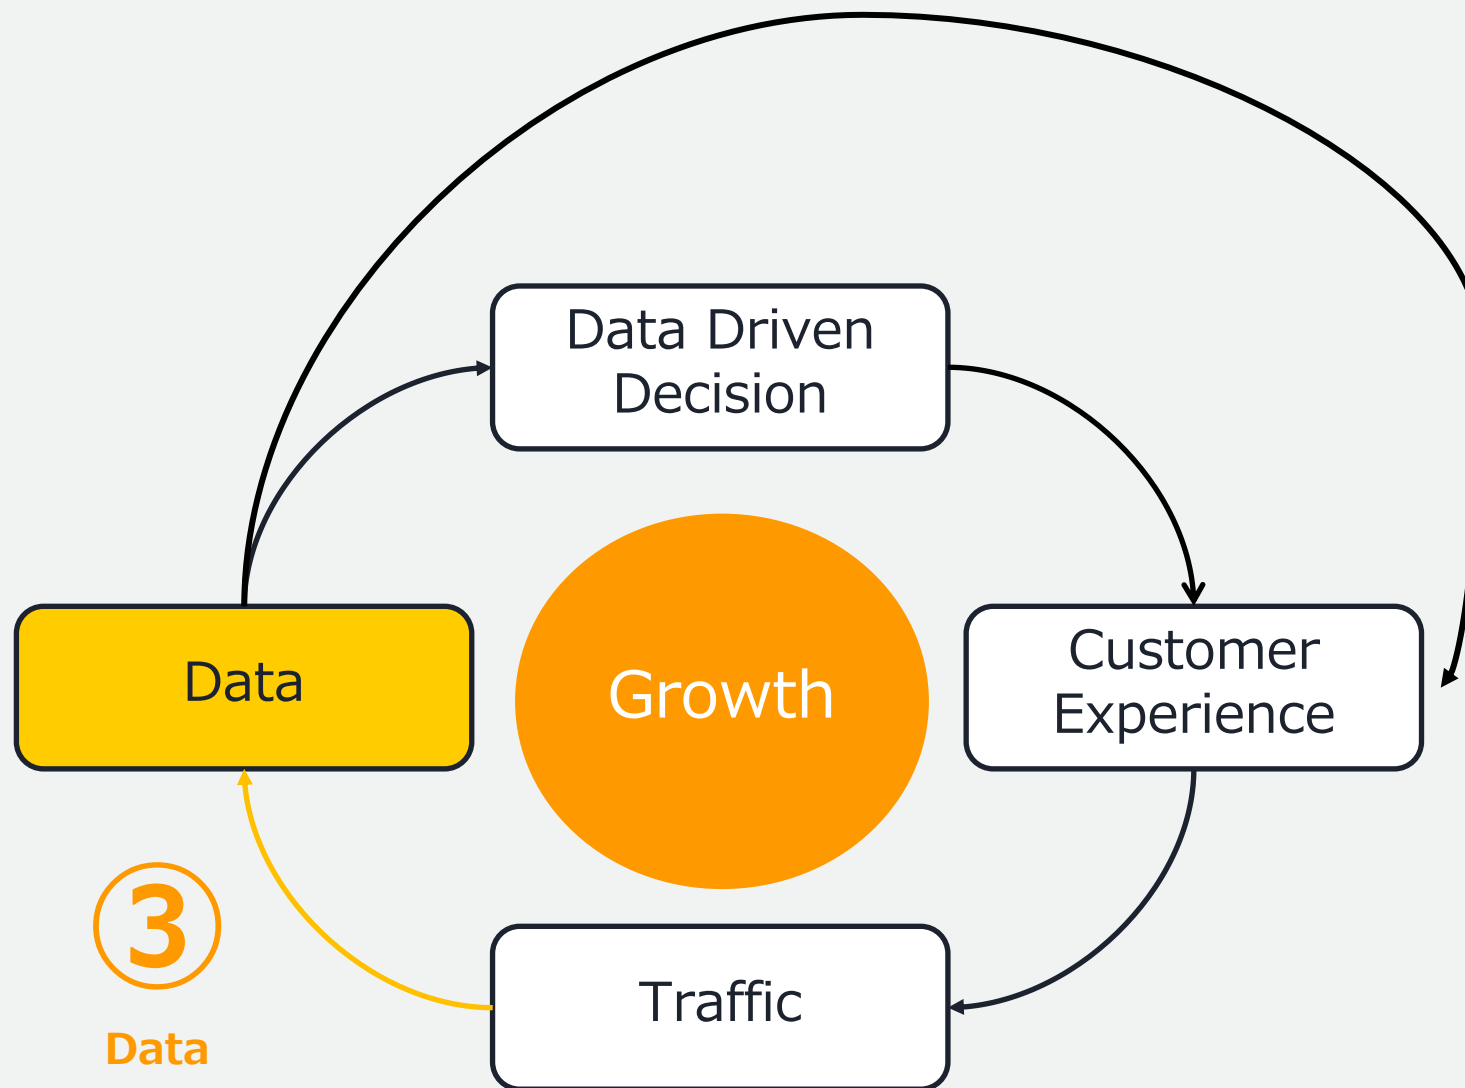


# 機械学習の成長サイクル





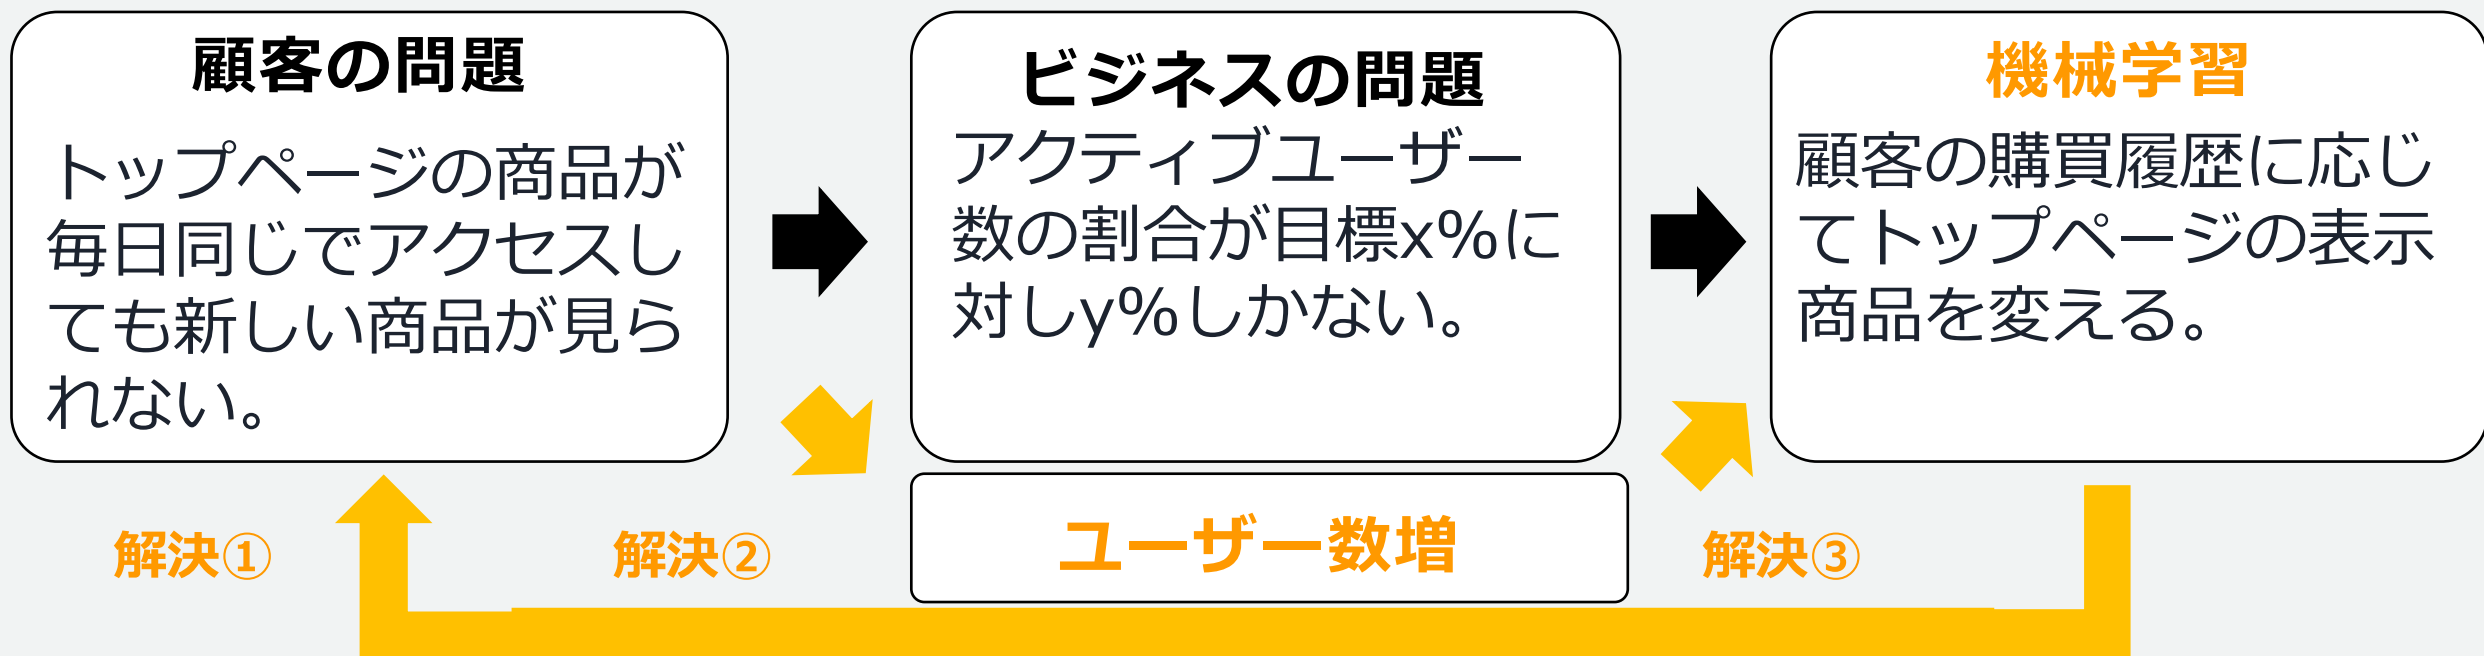
# 機械学習の成長サイクル



# 成長サイクルは次の 3 つの条件を満たす。

1. 機械学習が顧客の問題を解決している
2. 顧客体験の改善がビジネスの問題解決につながる
3. ビジネスの KPI 改善が機械学習の精度改善につながる

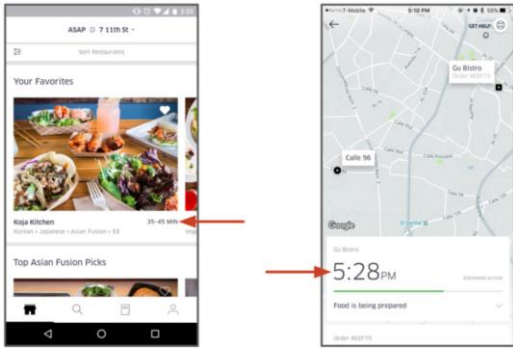
例：ファッションのECサイト



**自社の顧客の問題、ビジネスの問題は？  
経営の資料などからみてる。**

※ お客様に合わせてファシリテーターが事前に調査しうめる

# 成長サイクルを確立した事例



画像引用: [Meet Michelangelo: Uber's Machine Learning Platform](#)

## Uber Eats

- ①注文前に食べられるまでの待ち時間がわかる。
- ②Uber Eats 利用者が増え、取引量が増える。
- ③取引量が増えることで待ち時間の予測が正確になる。



画像引用: [Get Perfect Song Recommendations in the Playlists You Create with Enhance](#)

## Spotify

- ①プレイリストのパーソナライゼーションを提供。
- ②音楽を聴く人が増える。
- ③聞く人が増えるほど好みをの予測が正確になる。

# 成長サイクルの条件が満たされていない場合

## 1. 機械学習が顧客の問題を解決していない

精度が 100% でないといけない、予測に対し完全な説明性が必要

## 2. 顧客体験の改善がビジネスの問題解決につながらない

無料ユーザーは増えているが有料プランにコンバージョンしていない


## 3. ビジネスの KPI 改善が機械学習の精度改善につながらない

ユーザー数は増加したがデータを機械学習につかえない

# 機械学習の成長サイクルを理解する


- 機械学習の成長サイクルとは
- **機械学習とは**
- 事例から成長サイクルを分析する

# 機械学習の位置づけ




## 人工知能 (Artificial Intelligence, AI)

人間の知的判断をコンピュータ上で実現するための技術全般  
(ロジック、if-then文、機械学習 (深層学習を含む))



## 機械学習 (Machine Learning, ML)

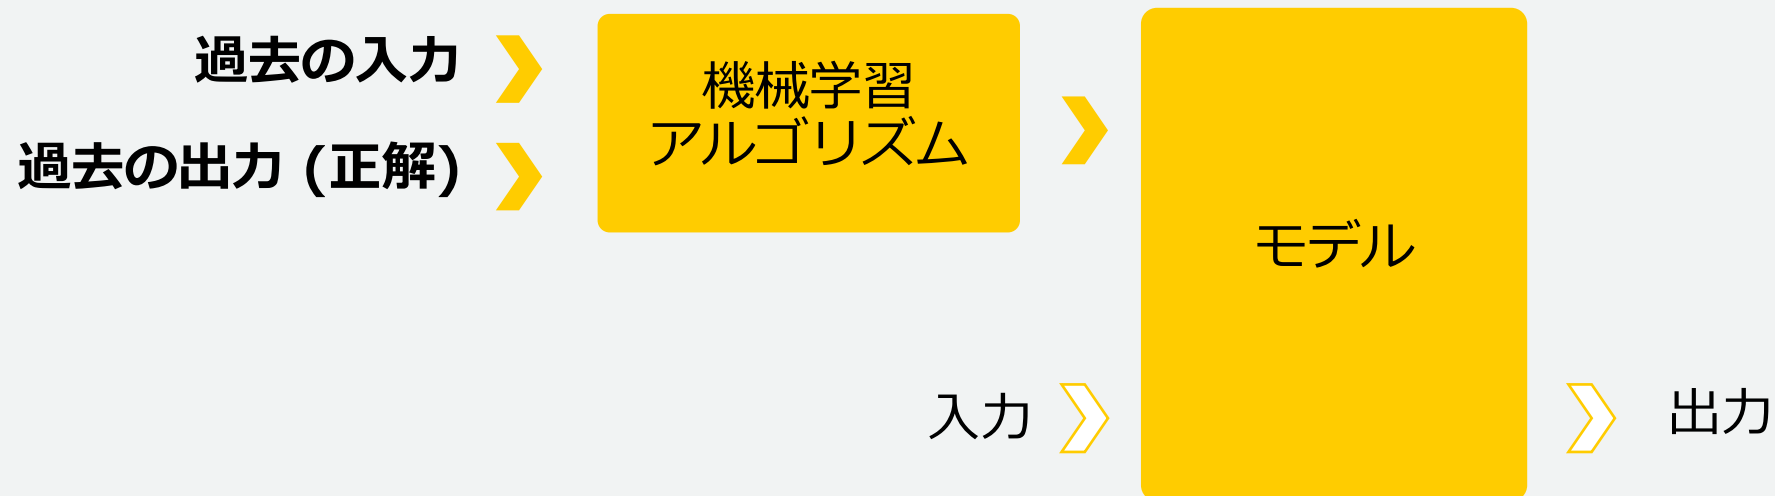
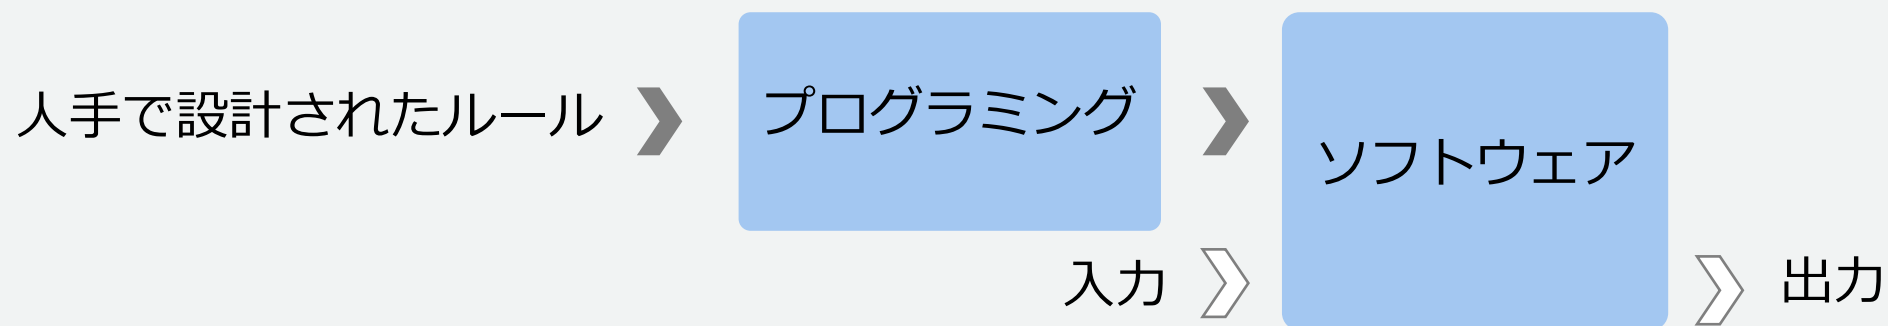
AIの一種であり、知的モデルを構築するためにデータの中の傾向を学習する技術



## 深層学習 (Deep Learning, DL)

MLの一種であり、音声・画像認識などのタスクを深い複数レイヤー構造のニューラルネットワークで実現する技術


# 従来型ソフトウェア vs. 機械学習



**機械学習では、データを変えるだけで挙動を変えられる。**




# 生成系AIは、深層学習の用途の一つ。




## 人工知能 (Artificial Intelligence, AI)

人間の知的判断をコンピュータ上で実現するための技術全般  
(ロジック、if-then文、機械学習 (深層学習を含む) )



## 機械学習 (Machine Learning, ML)

AIの一種であり、知的モデルを構築するためにデータの中の傾向を学習する技術



## 深層学習 (Deep Learning, DL)

MLの一種であり、音声・画像認識などのタスクを深い複数レイヤー構造のニューラルネットワークで実現する技術



## 生成系AI (Generative AI)

テラバイト規模のデータで数千億規模のパラメーターのモデルを学習することで、**追加学習なしに**人間のような生成を実現する技術。

# 生成系 AI がこれまでの機械学習と異なる点

追加学習をほとんど必要としない

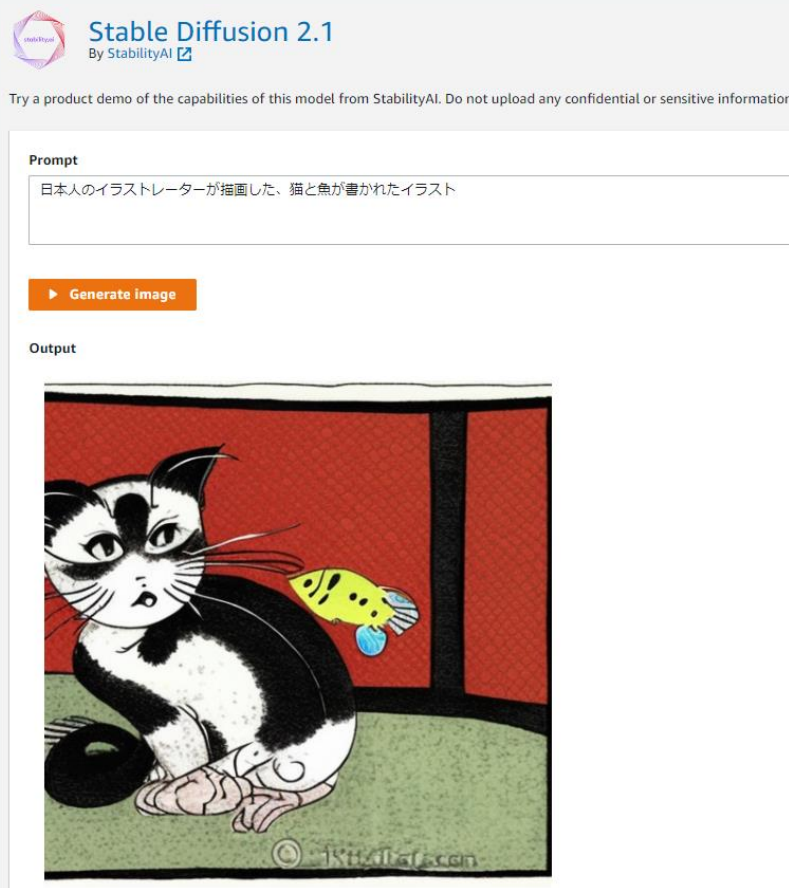
簡単な指示 (Prompt) で多様なタスクを解かせることができる

追加学習なし、簡単な指示にも関わらず高精度である

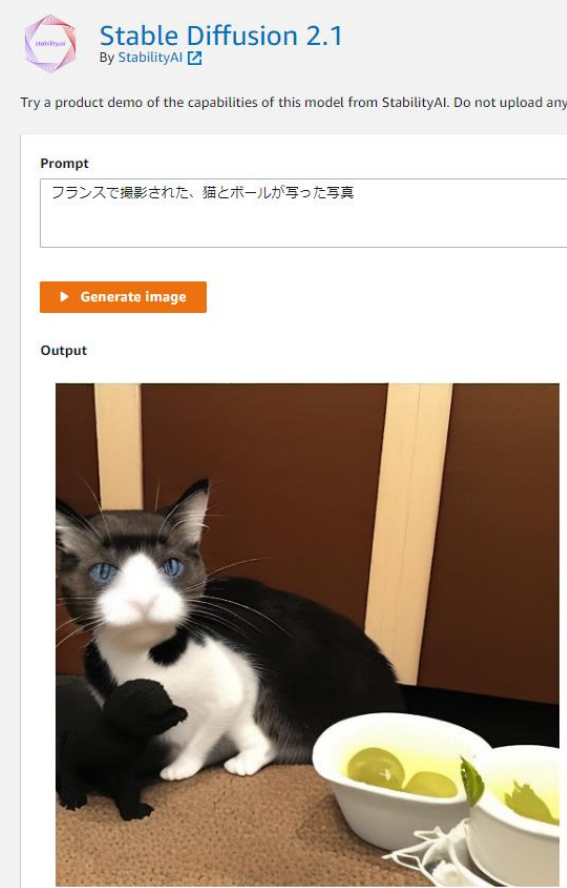
**大規模な事前学習を行った基盤モデルが上記 3 点を可能にしている**

# 生成系AIの生成例

“日本人のイラストレーターが描画した、猫と魚が書かれたイラスト”の生成例



“フランスで撮影された、猫とボールが写った写真”の生成例



AWSのSageMaker JumpStartで、テキストから画像を生成するStable Diffusionのモデルを実行した例

# 生成系 AI の様々なユースケース

参考: [Exploring opportunities in the generative AI value chain](#)



文書作成  
チャットボット  
分析結果記述  
文書要約



動画生成  
動画編集  
音声変換  
話者変換 (VTuber等)



コード生成  
データ生成  
プロトタイプ生成



3D オブジェクト生成  
製品デザイン、創薬



素材画像生成  
画像編集



音声合成  
音楽生成  
音声/音楽編集

# 機械学習のデメリット

## 1. 運用が困難

データの取得、前処理、学習など幅広い処理を繋ぎ合わせ実装するので統合的な管理とチーム連携が不可欠（次スライド）。

## 2. 責任ある利用が困難

学習データが膨大になるにつれ潜在する偏りの検知が困難になる。

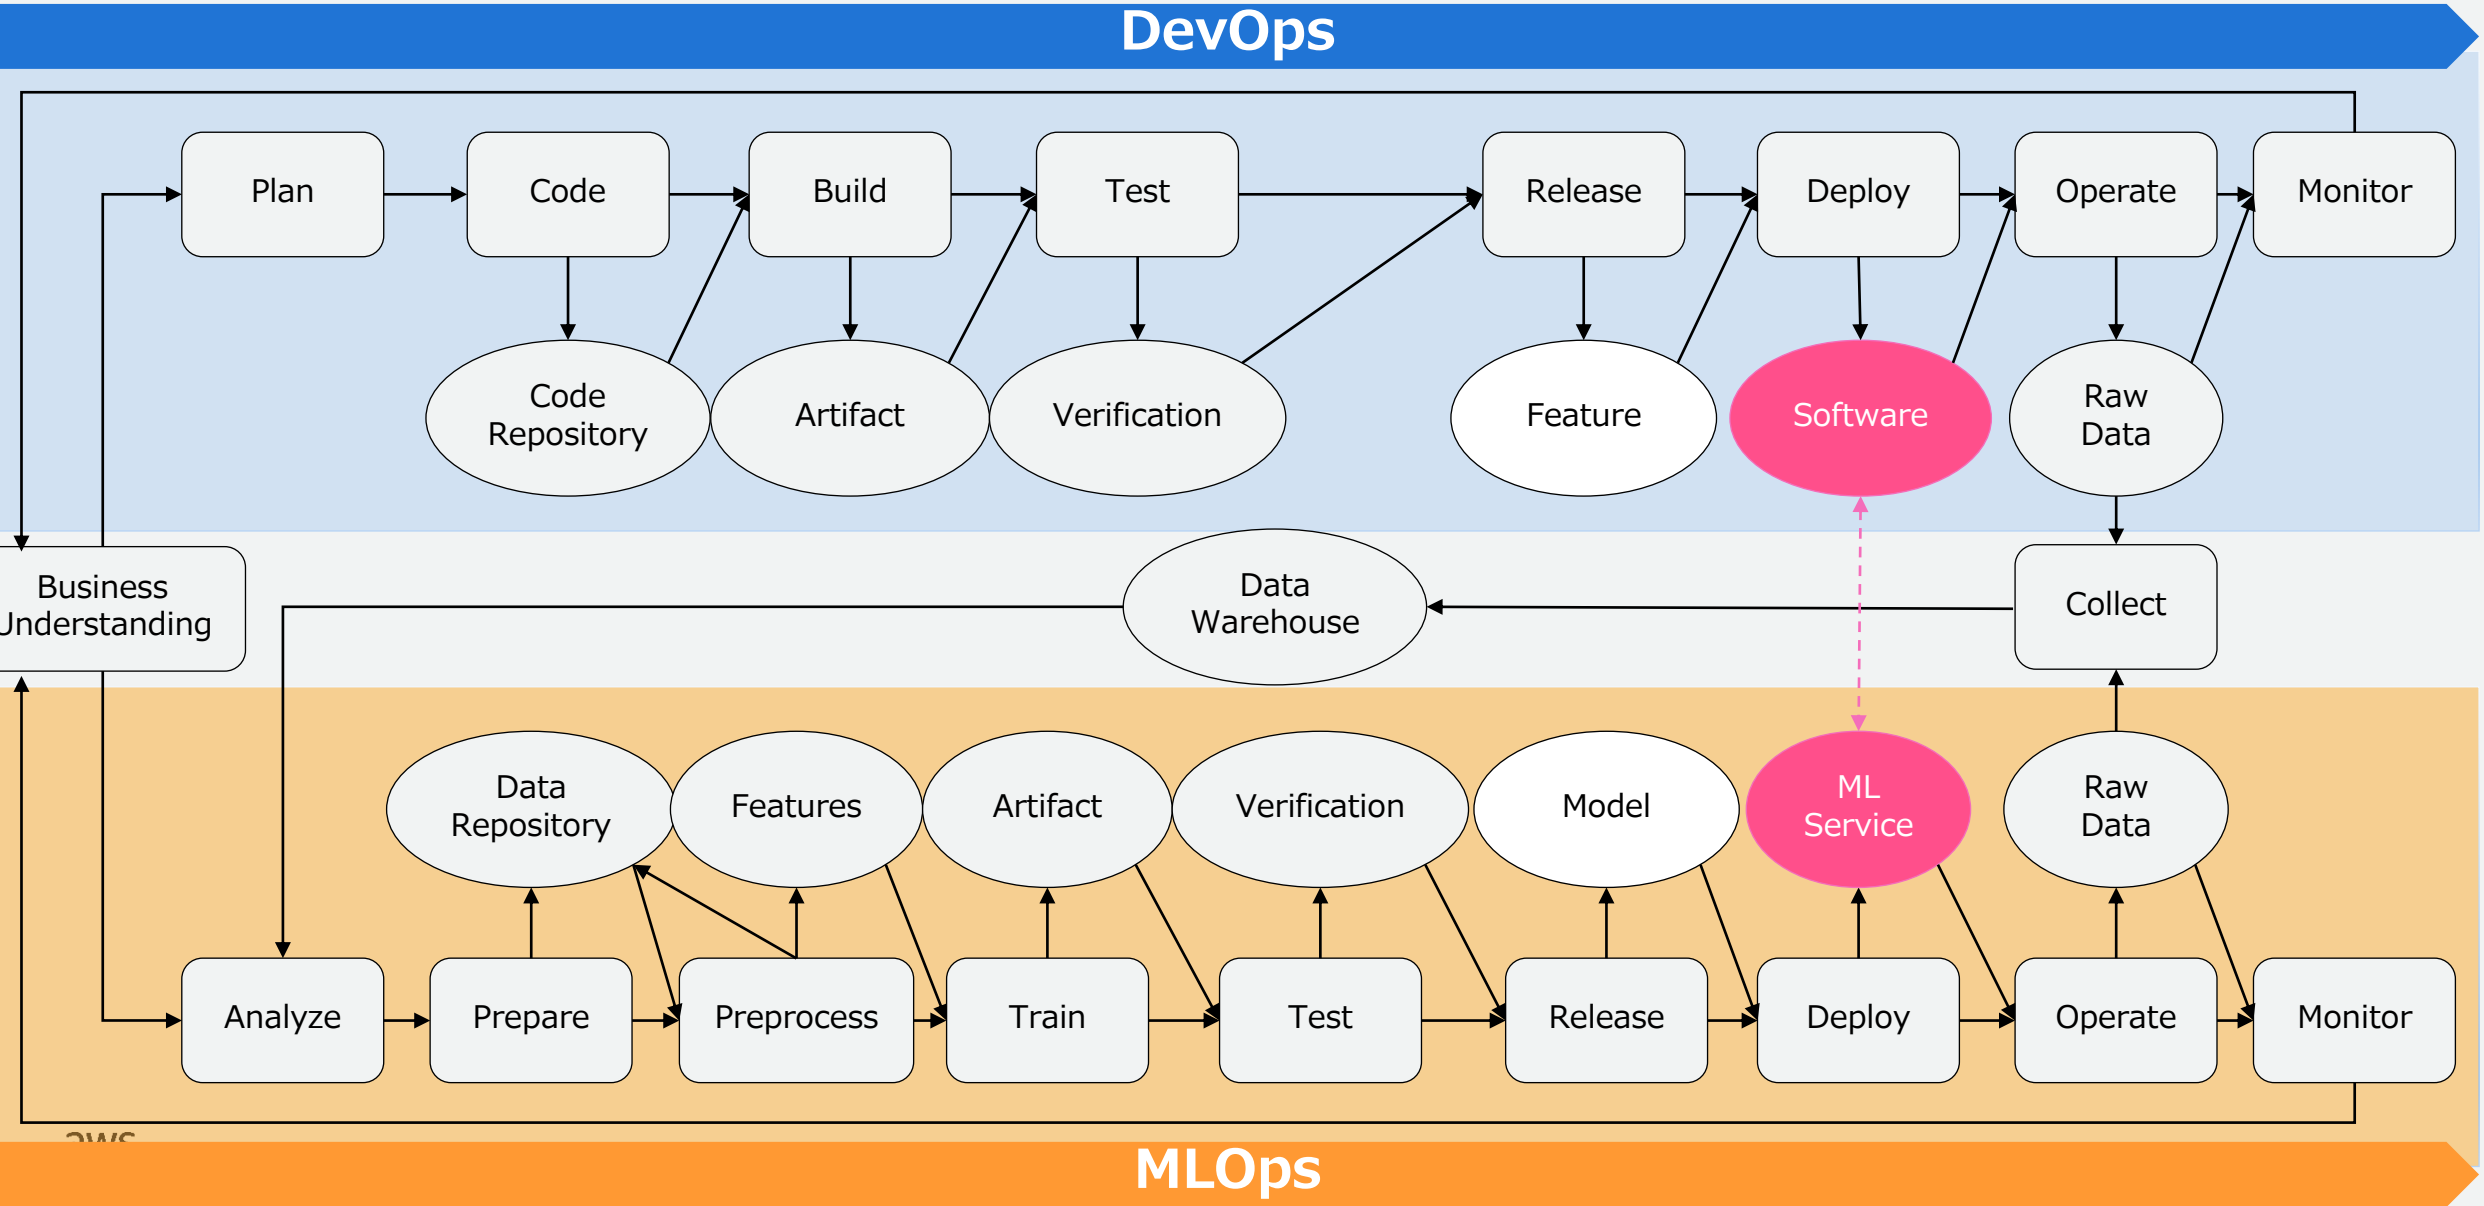
## 3. 学習・推論のリソース調達が困難

GPUをはじめとし、開発や推論に必要なリソースの調達が困難。

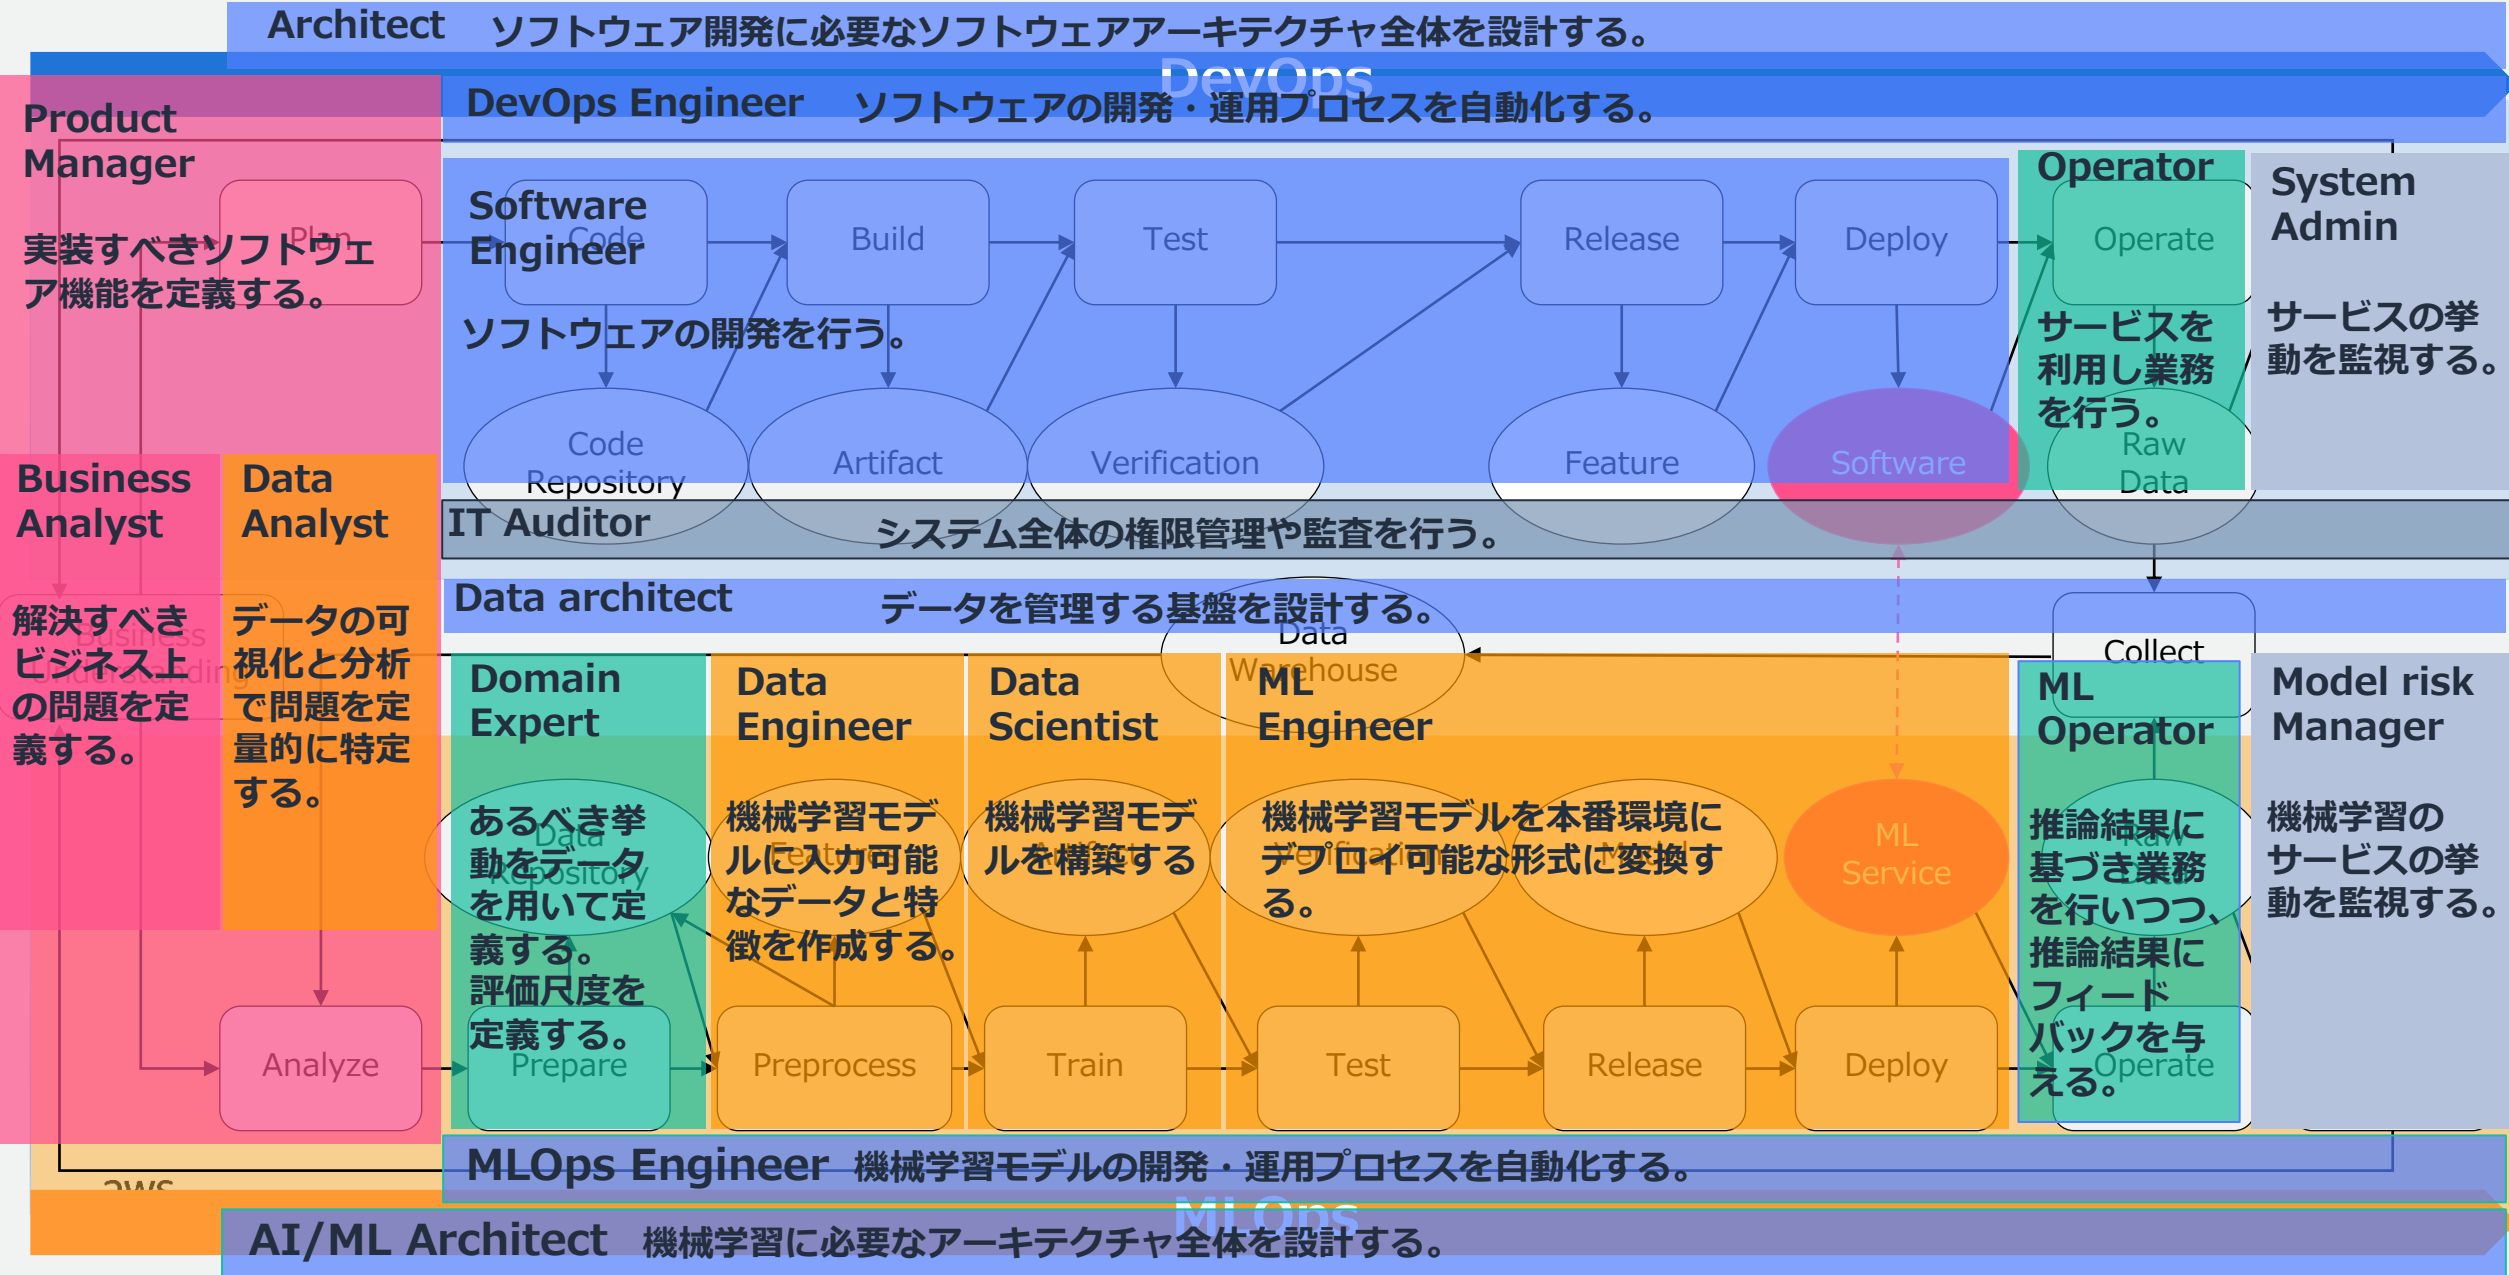
## 4. テストが困難

確率的な挙動をするためテストが難しく、推論根拠の特定も困難

# 機械学習を用いる開発では通常の開発とモデル開発が並走する。



# プロダクトのリリースまでには多くのロールが関わる。



# Responsible AI : 責任ある AI

## 公平性

Fairness

システムがユーザーの  
集団に応じて与える影  
響を考慮する  
(例：性別、民族など)

## 説明可能性

Explainability

AI システムの出力結  
果を理解し評価する  
仕組み

## 堅牢性

Robustness

AI システムの確実な  
運用を実現するた  
めの仕組み

## プライバシーと セキュリティ

Privacy and Security

プライバシーに配慮した  
データ利用  
盗難・流出からの保護

## ガバナンス

Governance

Responsible AI の  
実践を定義し、実装  
し遵守するプロセス

## 透明性

Transparency

ステークホルダーが  
十分な情報を得た上で  
AI を利用できる仕組み



# まとめ：機械学習とは

- 機械学習は人工知能を実現する技術の一つ。
- 収集したデータで挙動を変えることができる。
- 生成系 AI は、事前学習した大規模なモデルによりデータ収集をせずに高い精度でタスクを行える。
- 多様なシステムやロールが関わり、責任ある利用も求められることから高度な運用が求められる。

# 機械学習の成長サイクルを理解する

- 機械学習の成長サイクルとは
- 機械学習とは
- 事例から成長サイクルを分析する


# 他社事例から、成長サイクルを成立させた「仕組み」を見極める

事例となるような大きな成果は、機械学習の成長サイクルが継続的に回転することから生まれる。

会社の規模や業種が異なっても、成長サイクルを成立させた**仕組み**を見極められれば、自社のビジネスの参考にできる。

**仕組み = 「ビジネスモデル」**

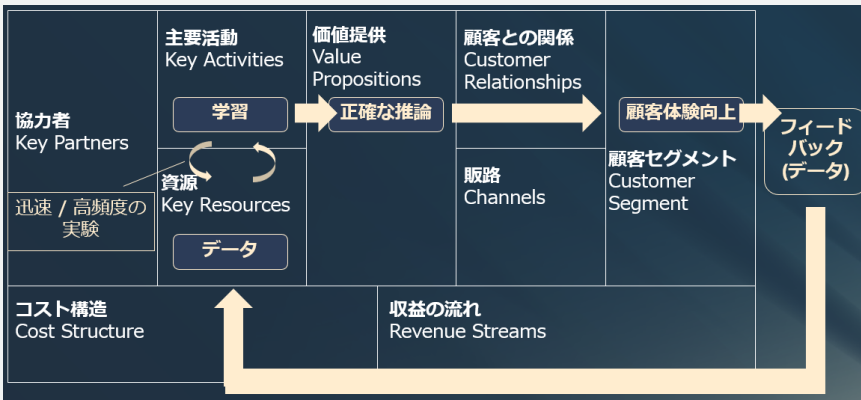
# エンジニア・データサイエンティストの方向け説明 ビジネスモデル ≡ アーキテクチャのパターン



※この図はイメージ図で、読み解く必要はありません

## アーキテクチャのパターン


過去の経験から「こうするとうまく動く」システム構成のパターンが大体きまっている。



## ビジネスモデル

過去の経験から「こうするとビジネスが成立する」プロセスの構成パターンが大体きまっている。


# エンジニア・データサイエンティストの方向け説明 ビジネスモデル ≡ アーキテクチャのパターン 開発におけるパターン集



左から

- [Java言語で学ぶデザインパターン入門第3版](#)
- [機械学習デザインパターン](#)
- [AWSで実現するモダンアプリケーション入門](#)

## ビジネスモデルにおけるパターン集




左から

- [ビジネスモデルの教科書](#)
- [ビジネスモデル 2.0 図鑑](#)
- [MBAより簡単で英語より大切な決算を読む習慣](#)

# ビジネスモデルを書くための手法：ビジネスモデルキャンバス

2005 年に経営コンサルタントのアレクサンダー氏が発案したフレームワーク。フレームワークを解説した「[ビジネスモデルジェネレーション](#)」は 45 カ国の実践者により執筆され、シリーズの累計部数は 14 万部に上る。

本屋で平積みされているのを見たことがある方もいるのでは？



画像引用：[翔泳社の書籍サイト](#)より

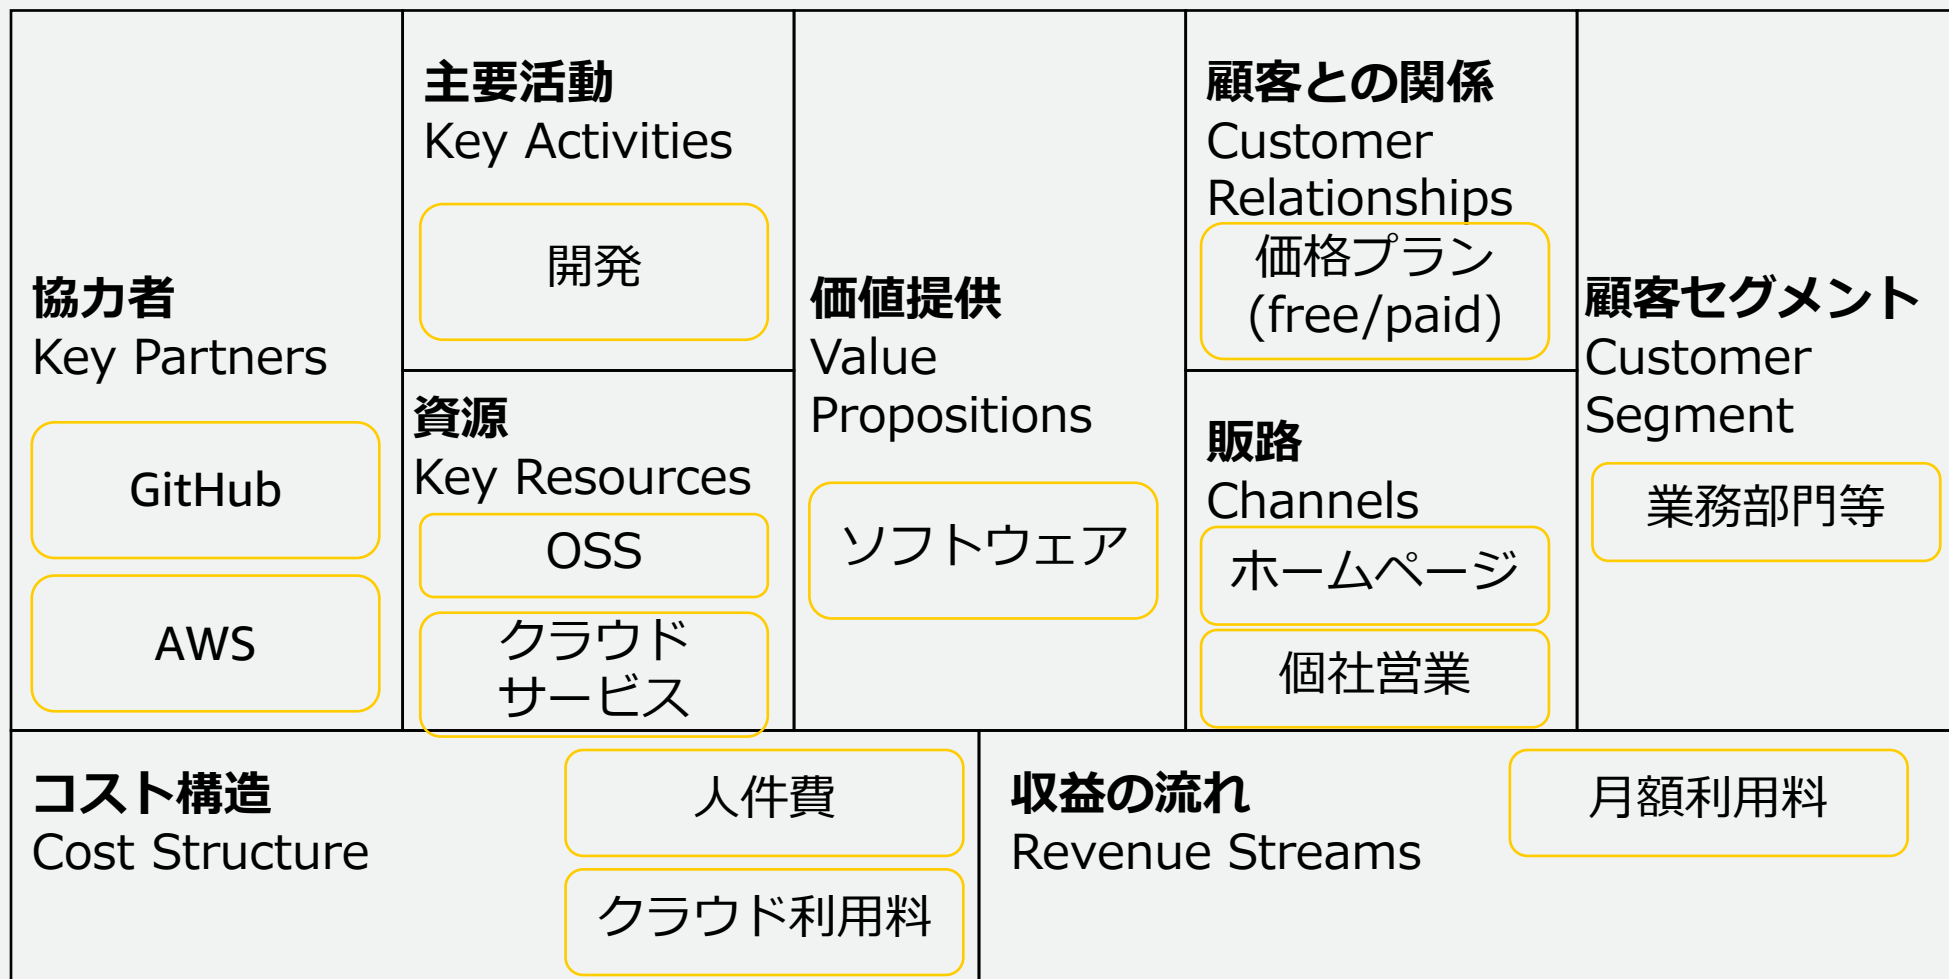
# ビジネスモデルキャンバスの図：9 象限で表現

協力者 Key Partners	主要活動 Key Activities	価値提供 Value Propositions	顧客との関係 Customer Relationships	顧客セグメント Customer Segment
	資源 Key Resources		販路 Channels	
コスト構造 Cost Structure			収益の流れ Revenue Streams	



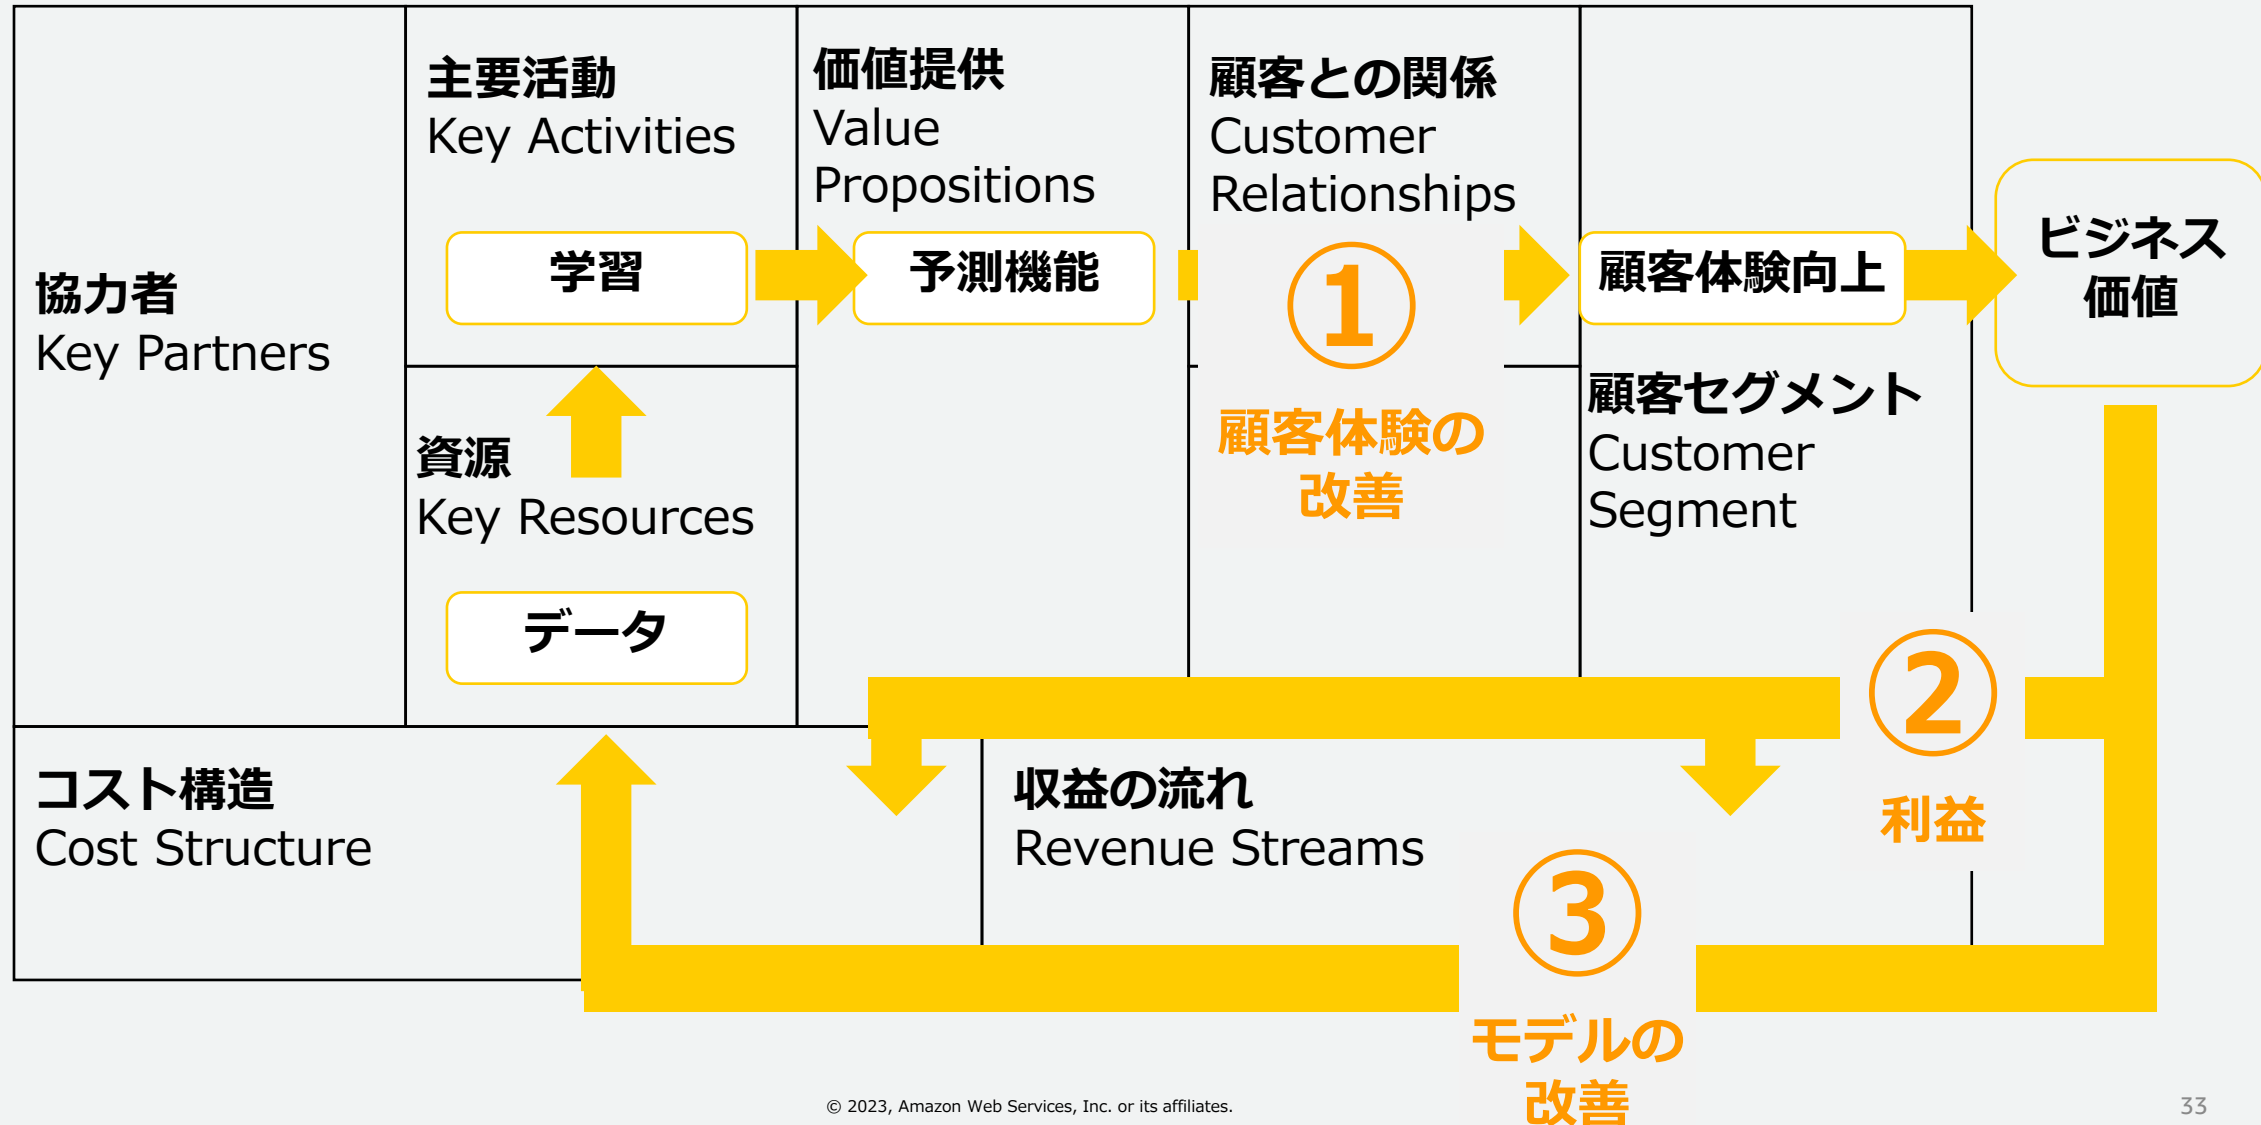
# エンジニア・データサイエンティストの方向け説明

## ビジネスモデルキャンバスの図：9 象限で表現





# ビジネスモデルキャンバスを使用した成長サイクルの表現



# 生成系 AI の事例を分析してみよう!

# Bizreach: ChatGPTで職務経歴書を自動作成

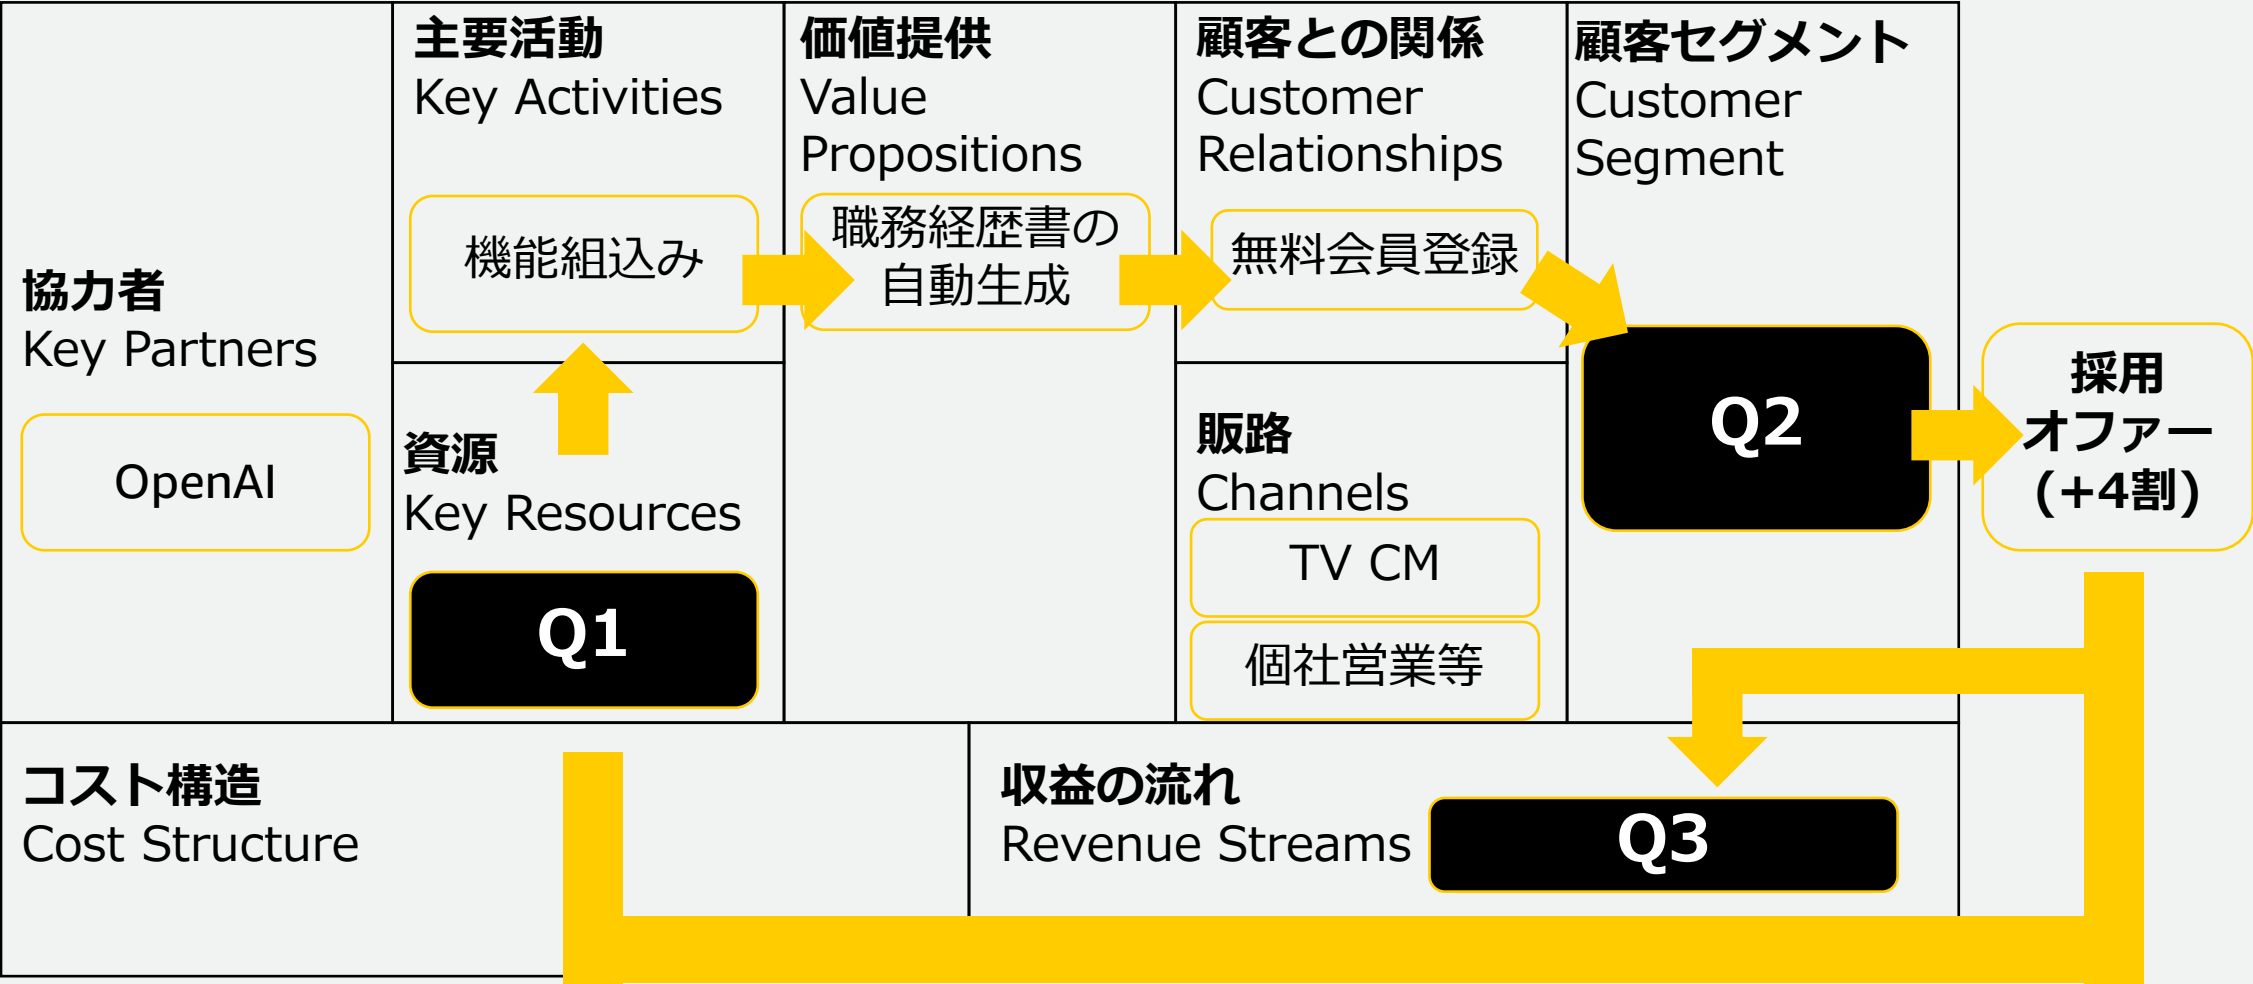
ChatGPT を使用した職務経歴書の自動作成機能をリリース。

選択式の質問に回答するだけで最短 30 秒で 350 文字以上の経歴書を作成し（Bizreach では 400 文字以上を推奨）、試験導入時の検証では 4 割面談の誘いが増加。

The image displays a mobile application interface for creating a resume using ChatGPT. The interface is divided into several steps, indicated by numbered circles (1, 2, 3, 4, 5). The first step is '職務内容を自動生成' (Automatic resume generation). The second step is '職種を選んでください (3個)' (Please select a job type (3)). The third step is 'ポジションを選んでください (3個まで)' (Please select a position (up to 3)). The fourth step is '職務内容を自動生成' (Automatic resume generation). The fifth step is '生成結果' (Generation result). The final screen shows the generated resume text, which includes a summary, key skills, and project experience.

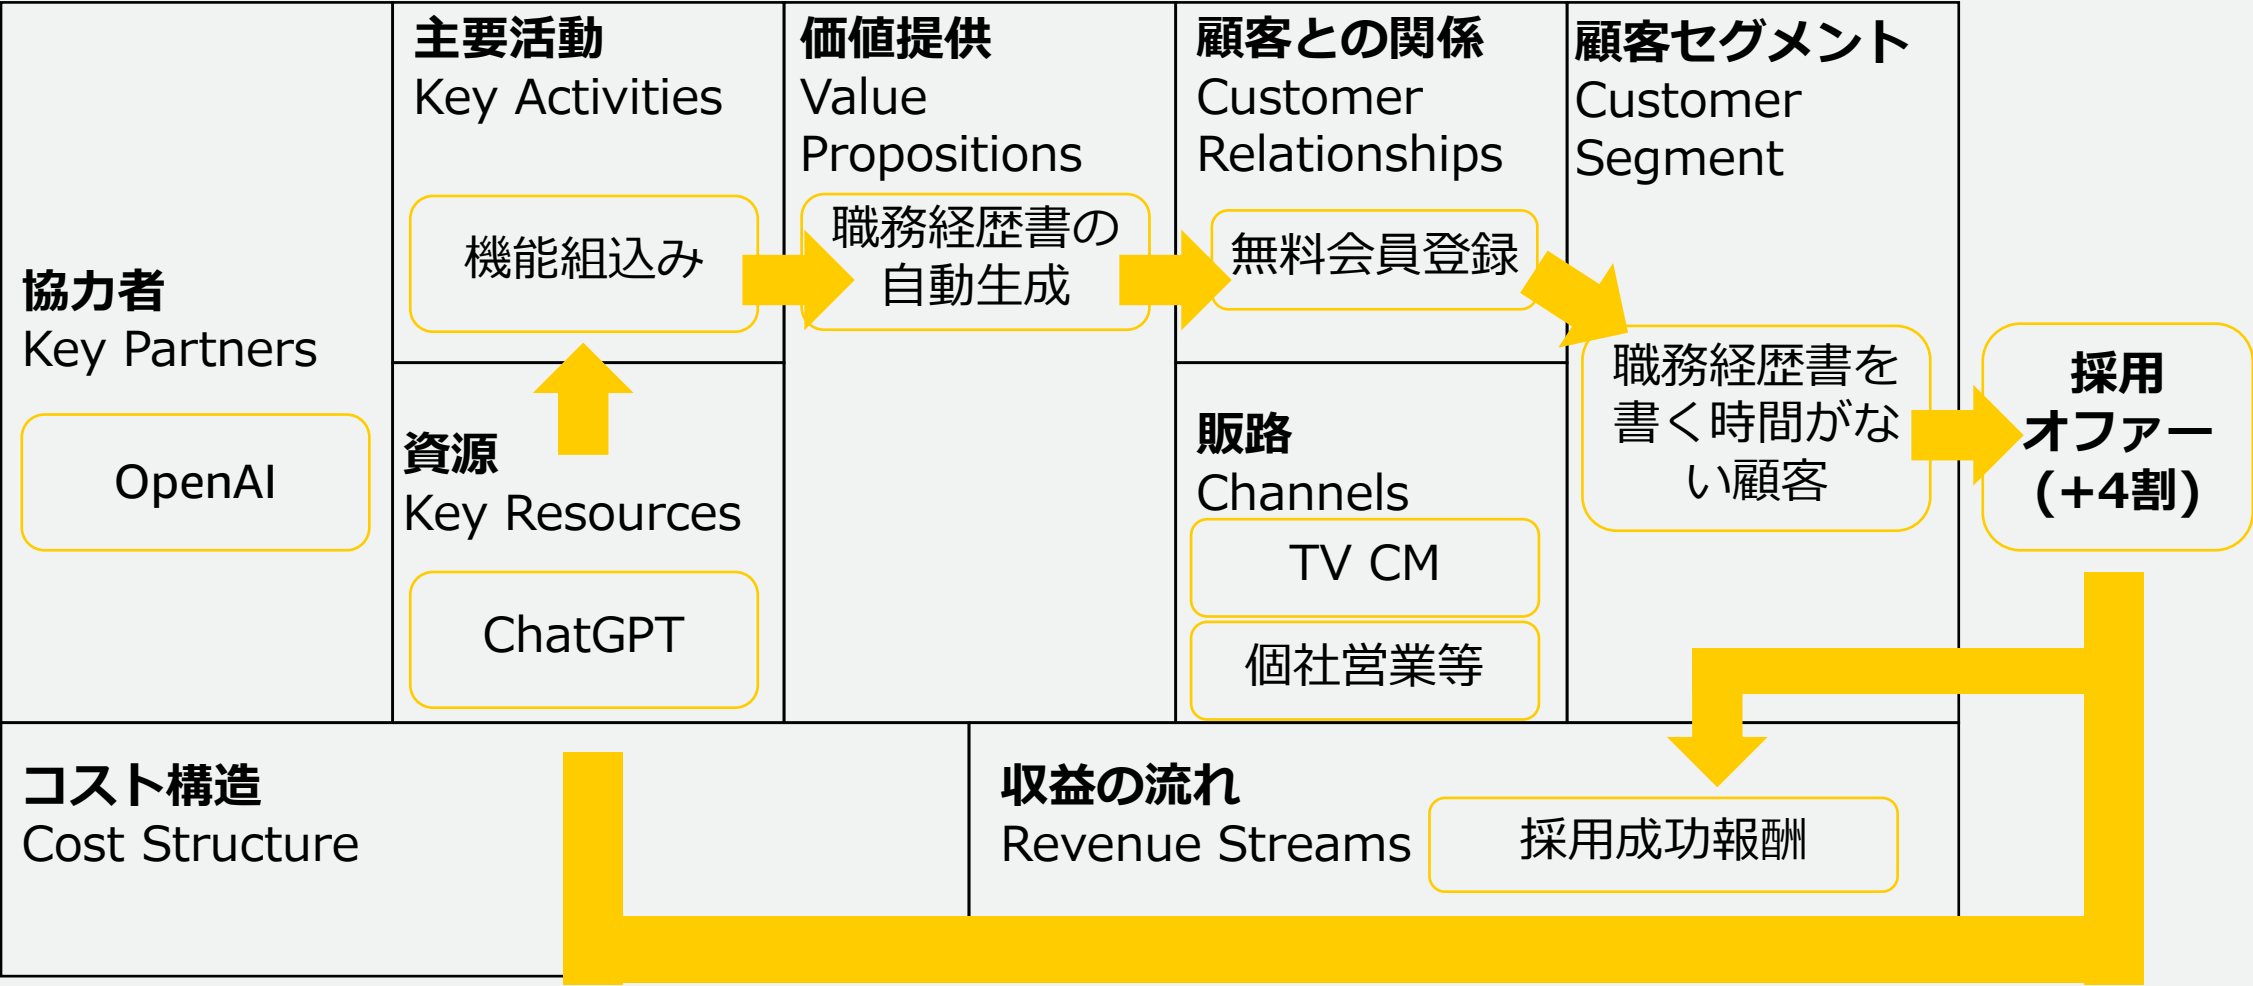
“[ビズリーチ、ChatGPT で職務経歴書を自動作成 最短 30 秒](#)” より引用

# Bizreach の事例分析



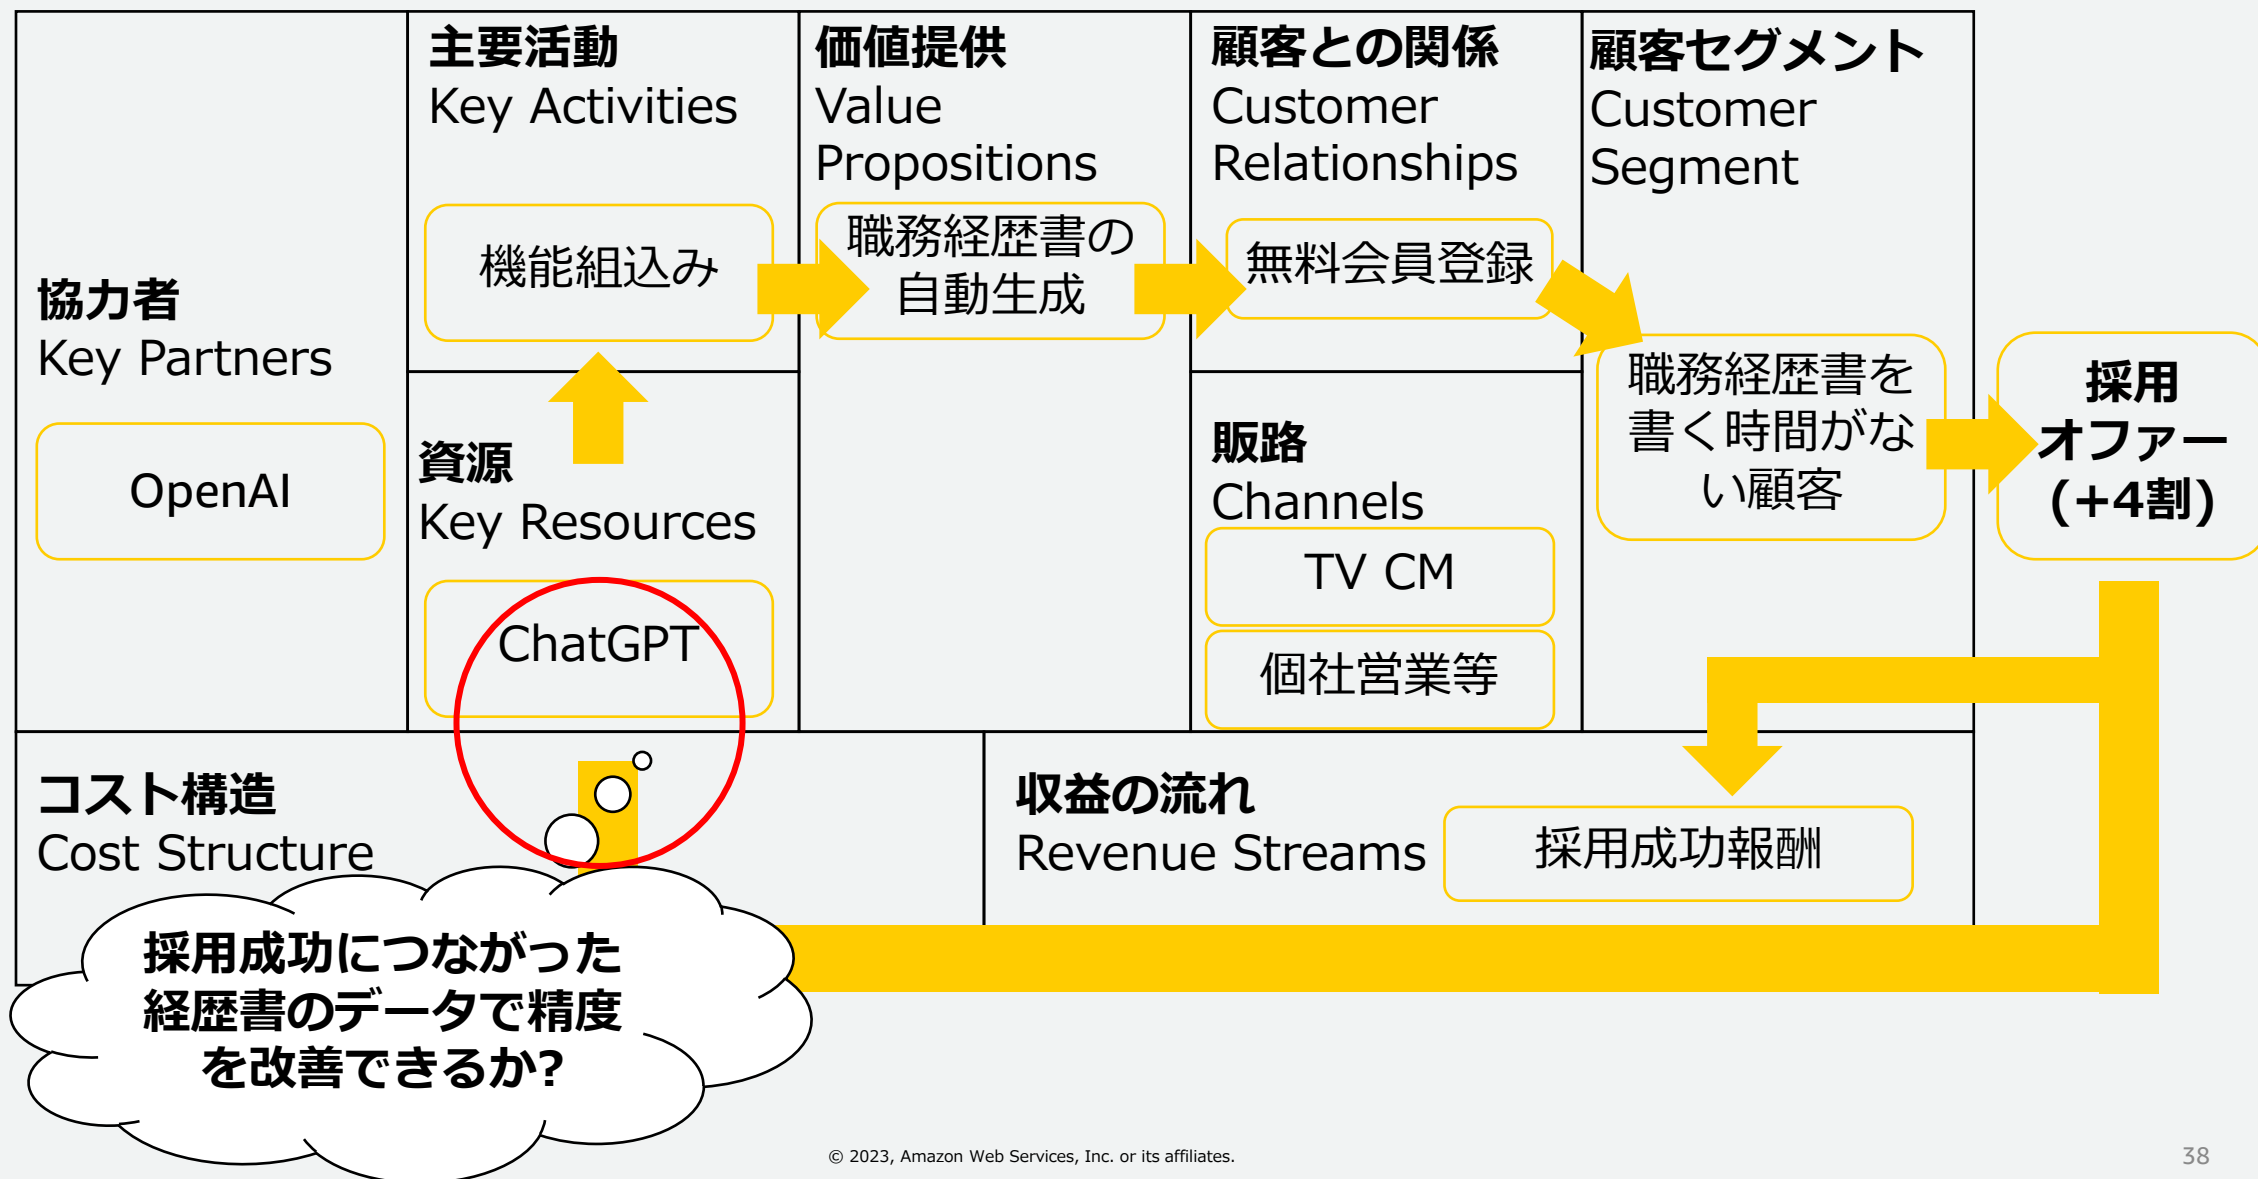
[2023 年 7 月期 の決算説明会資料を参照](#)

# Bizreach の事例分析



[2023 年 7 月期 の決算説明会資料を参照](#)

# Bizreach の事例分析：成長サイクル分析



# はじめに：理解編の振り返り

- 機械学習の成長サイクルを回すことが重要
  - 機械学習が顧客体験を改善し利用が拡大することでビジネス KPI が向上し、データが蓄積されることでモデルの精度が良くなりさらに体験を改善。
- 機械学習はこれまでのソフトウェア開発とは方式が異なる。
  - 仕様をもとにプログラミングするソフトウェアに対し、機械学習は収集したデータを仕様としてアルゴリズムのパラメーターを調整しモデルを作る。
- 成長サイクルはゼロから作るより事例を参考にする
  - 機械学習は不確実性が高い技術であるため、成功した事例を参考にすることで期待成果や使用するモデルについて知見を得てリスクを下げられる。

# Have a break + Question time



# 实践

# 理解編の流れ

- |                        |        |
|------------------------|--------|
| 1. 機械学習の成長サイクルを理解する    | 30 min |
| 2. プロダクトで応用できそうな事例の共有  | 10 min |
| 3. 自社版のビジネスモデルキャンバスの作成 | 60 min |

# 理解編の流れ

- |                              |               |
|------------------------------|---------------|
| 1. 機械学習の成長サイクルを理解する          | 30 min        |
| <b>2. プロダクトで応用できそうな事例の共有</b> | <b>10 min</b> |
| 3. 自社版のビジネスモデルキャンバスの作成       | 60 min        |

# プロダクトで応用できそうな事例の共有と分析

効果と実現性の確度が高いユースケースから検討をスタートするため、データサイエンティストの方からプロダクトに応用できそうな事例を 2~6 個共有をお願いします。

# 理解編の流れ

- |                               |               |
|-------------------------------|---------------|
| 1. 機械学習の成長サイクルを理解する           | 30 min        |
| 2. プロダクトで応用できそうな事例の共有         | 10 min        |
| <b>3. 自社版のビジネスモデルキャンバスの作成</b> | <b>60 min</b> |

# ユースケースのアイディエーションと検証

事例をもとに、  
プロダクトで有効そうな  
ユースケースを書き出し、  
筋が良いものをピックアップ

ビジネスモデルキャンバスで  
成長サイクルを確認する



**Step1**



**Step2**

# ユースケースのアイディエーション

事例をもとに、  
プロダクトで有効そうな  
ユースケースを書き出し、  
筋が良いものをピックアップ



## 助けが必要な時は・・・

**自分に合った化粧品が使えるプロダクト**で、**画像の生成**を使った機能を検討しています。 1) このプロダクトをよく使用すると思われる顧客の年齢、家族構成、職業、趣味、1日の簡単なスケジュールからペルソナ作成し、 2) このプロダクトに出会う心理的および状況的必然性を述べ、 3) この顧客にとって不可欠な生成系AIの機能を発案し、 4) 生成系AI機能の利用を促すためのコピーを作成してください。異なるペルソナを用い2回繰り返してください。

プロダクト案、生成系 AI 案を変更し  
お好きな生成系 AI サービスに入力




# ユースケース発想タイム



**10min**

# ユースケース共有・絞り込みタイム



# 20min

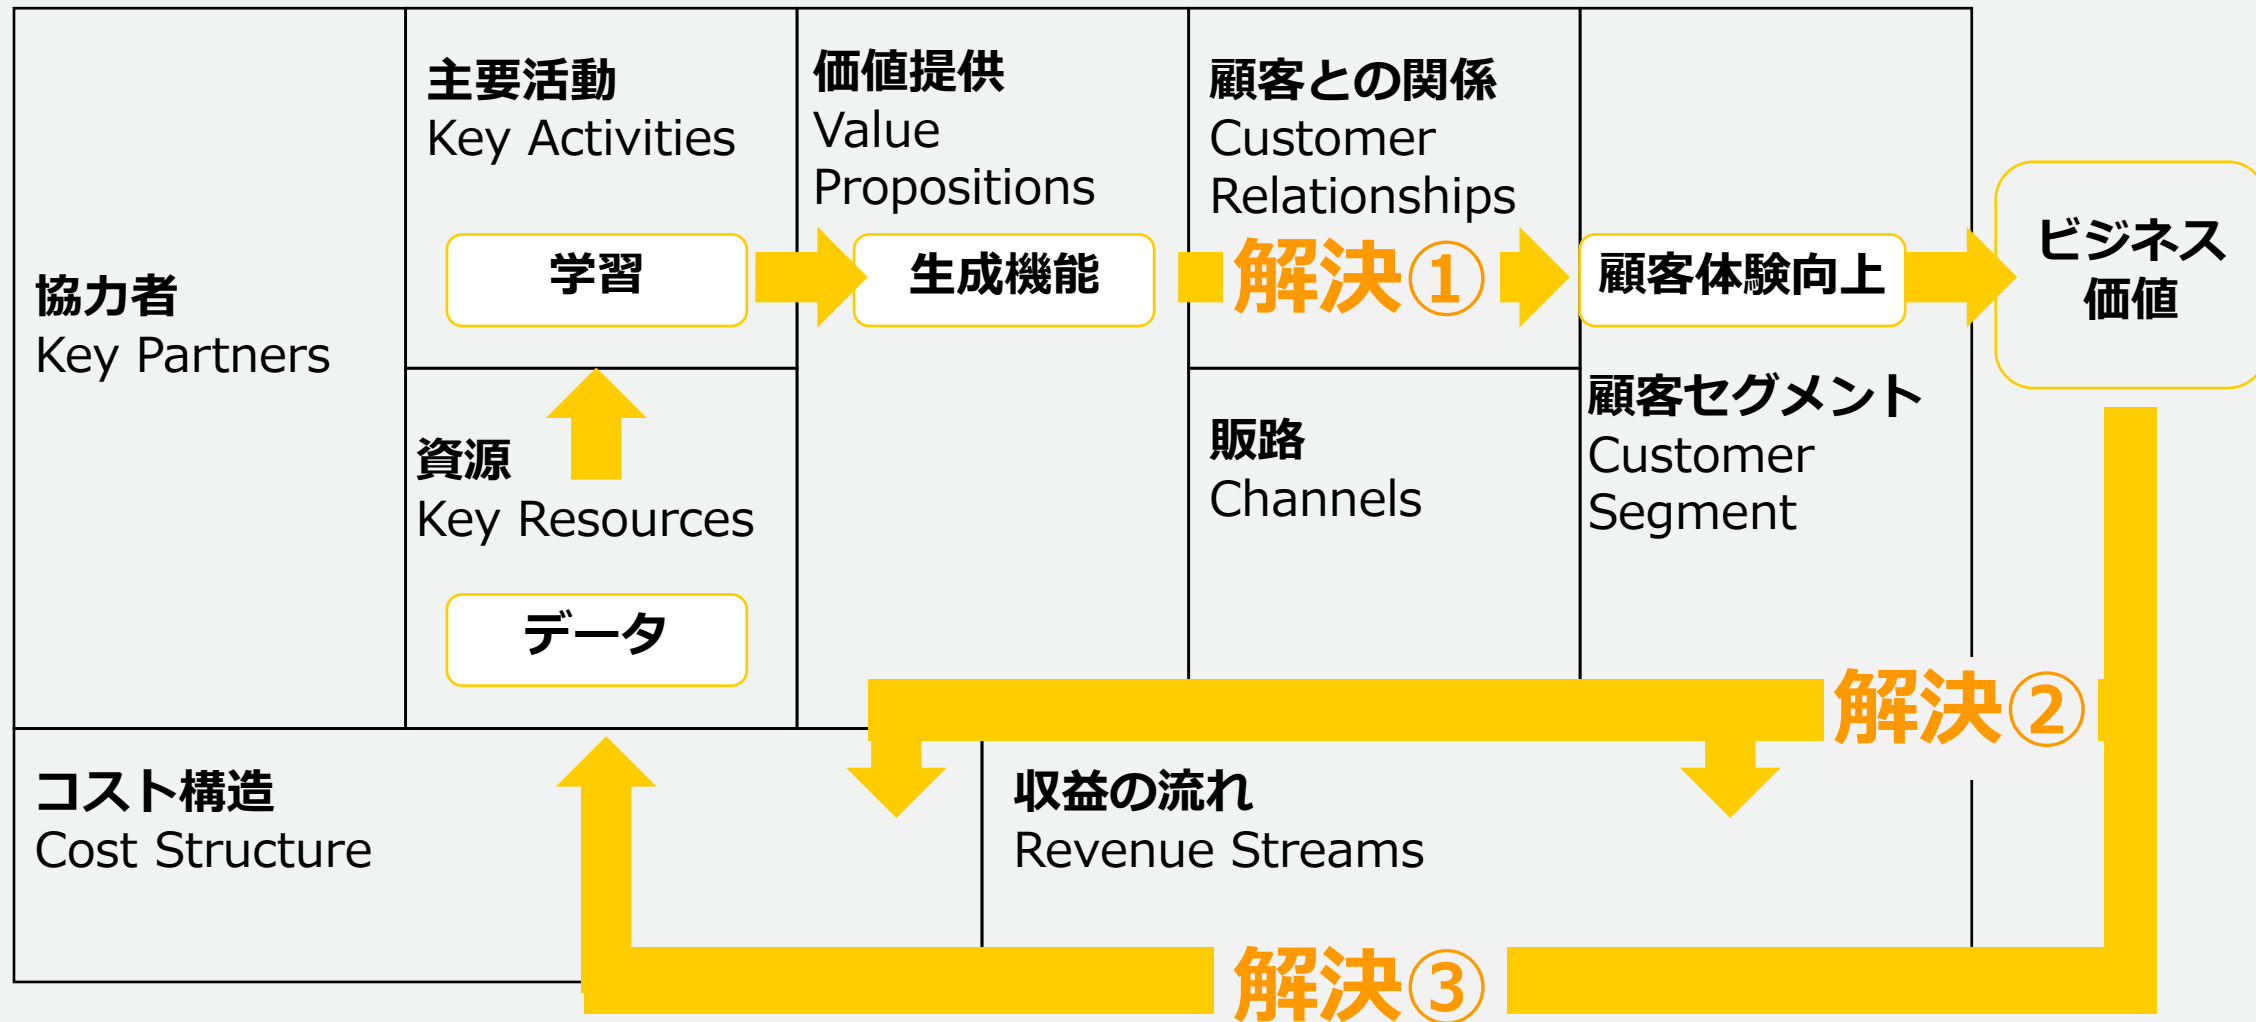
会社で使用しているドキュメント共有ツールなどをお使いください

# ユースケースの検証

ビジネスモデルキャンバスで  
成長サイクルを確認する



# ビジネスモデルキャンバスを使用して、アイデアの成長サイクルを確認する

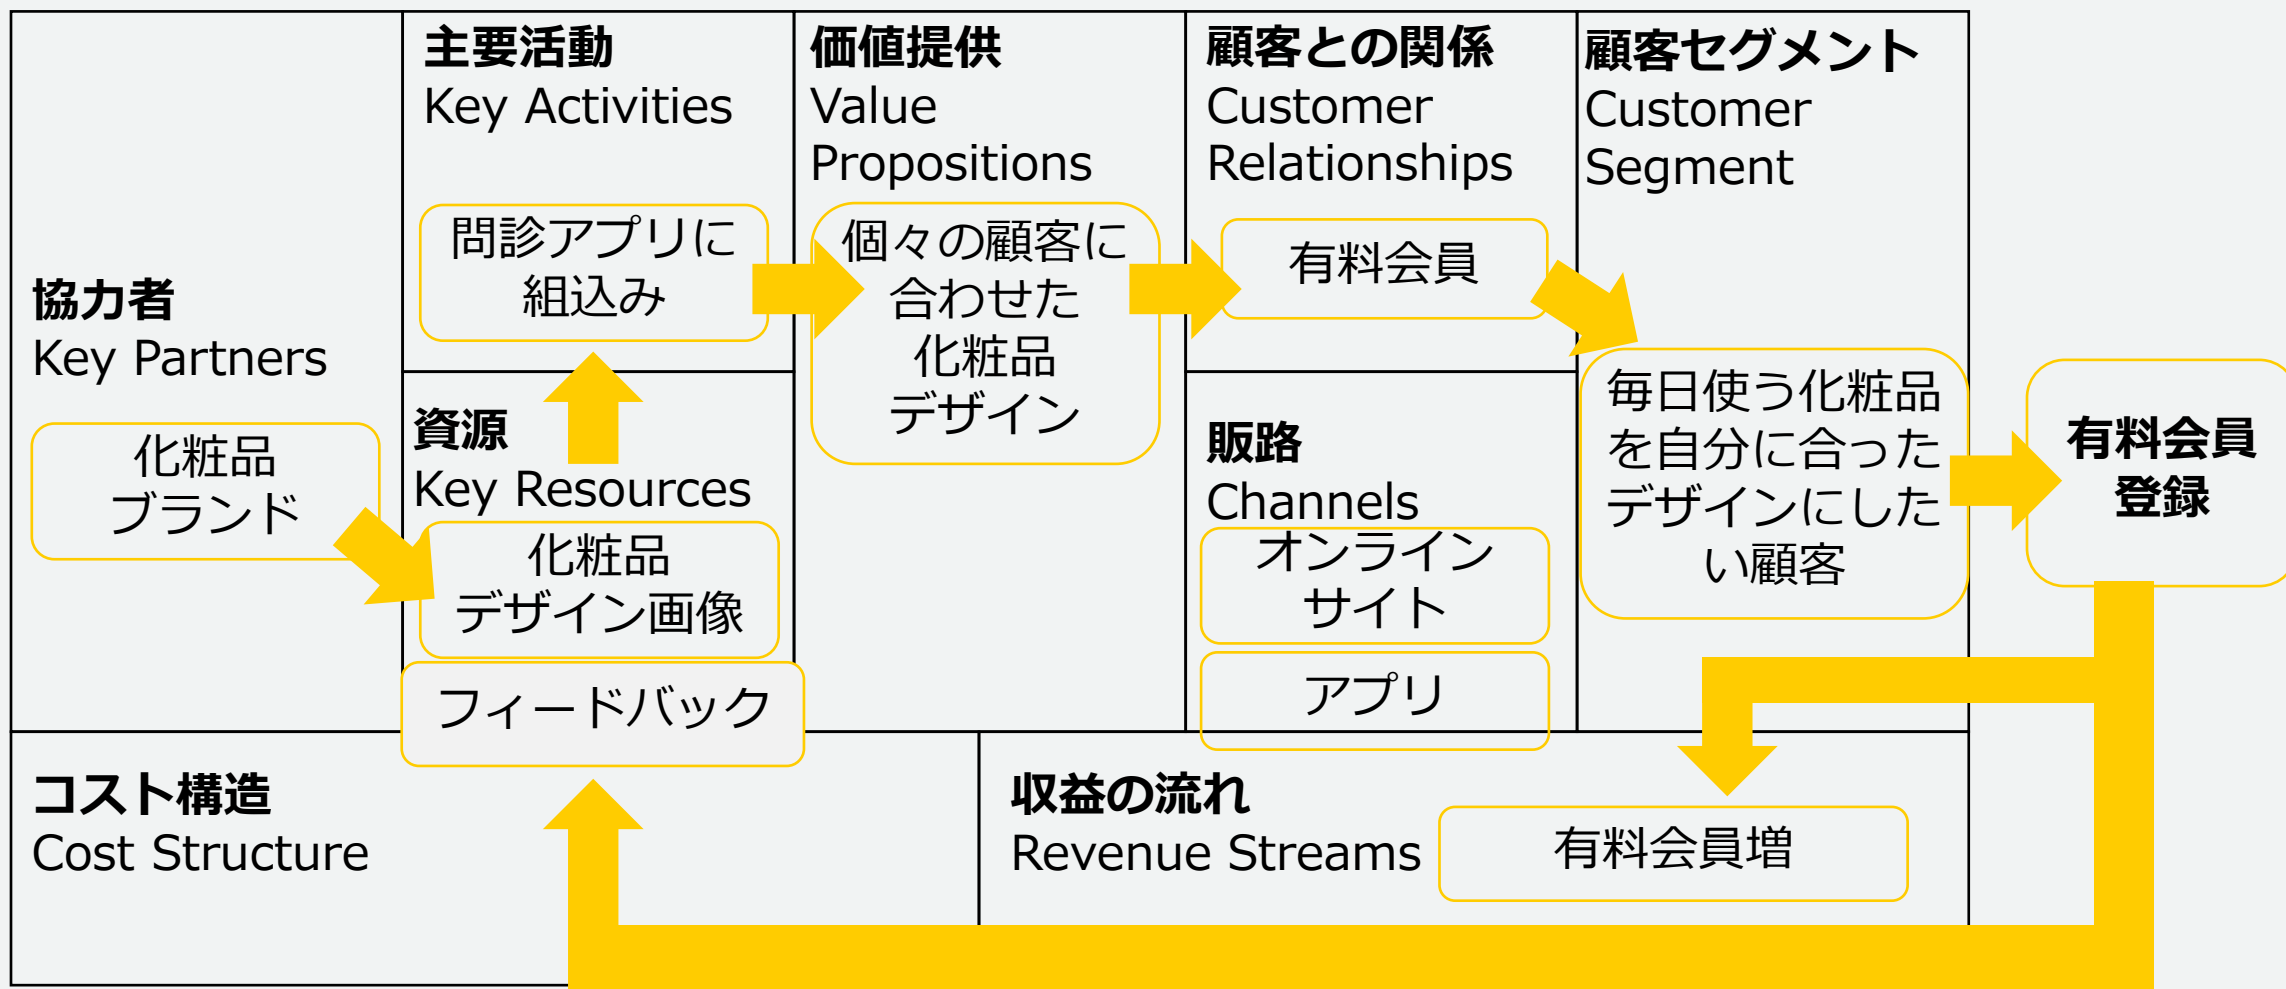


# 活用アイデアの下地を作るプロンプト

**自分に合った化粧品が使えるプロダクトで、自分の肌に合ったカラーパレットを生成する機能**を検討しています。この機能の実装がビジネスモデルとして成立するか、ビジネスモデルキャンバスを使用し分析したいと考えています。このプロダクトおよび機能について、1) ビジネスモデルキャンバスを顧客セグメント、顧客との関係(価格プラン)、販路、価値提供、主要活動、資源、協力者、コスト構造、収益の流れの順に記載してください。2) 顧客セグメントへの価値提供が顧客の問題を解決していること、コストもしくは収益の改善につながることで、生成系AIモデルの精度をさらに向上させるためのデータの増加につながることの3点を確認した結果を Markdown の表でまとめ、確認結果が不十分であれば改善案を提示してください。

プロダクト案、生成系 AI 案を変更し  
お好きな生成系 AI サービスに入力

# 下地プロンプトの出力をベースにしたビジネスモデル例



# ビジネスモデルキャンバス作成タイム



## 30min

会社で使用しているドキュメント共有ツールなどをお使いください（※ Day2 で使います）

# ビジネスモデルキャンバスの図（コピー用）

協力者 Key Partners	主要活動 Key Activities	価値提供 Value Propositions	顧客との関係 Customer Relationships	顧客セグメント Customer Segment
	資源 Key Resources		販路 Channels	
コスト構造 Cost Structure			収益の流れ Revenue Streams	



# Next Step

## Next Step

理解編で作成したビジネスモデルは、企業側の成長計画をしたためたものであり、顧客に受け入れられる保証はありません。

次回応用編では、**顧客目線の体験**を共有し、顧客としてもビジネスモデルに乗りたくなるか検証するための（必要最小限の）検証範囲を**視覚的に**特定します。

**プロダクトマネージャーの方にカスタマージャーにマップを事前に共有いただくとスムーズです（AWSにも共有ください）。**

ビジネスモデルキャンバスの詰めなど、追加でワークが必要そうな場合ご相談ください

# See you next day!

This material is based on the AWS Machine Learning Embark Program,  
an immersive ML training program provided by Amazon Machine Learning Solutions Lab



# Appendix:

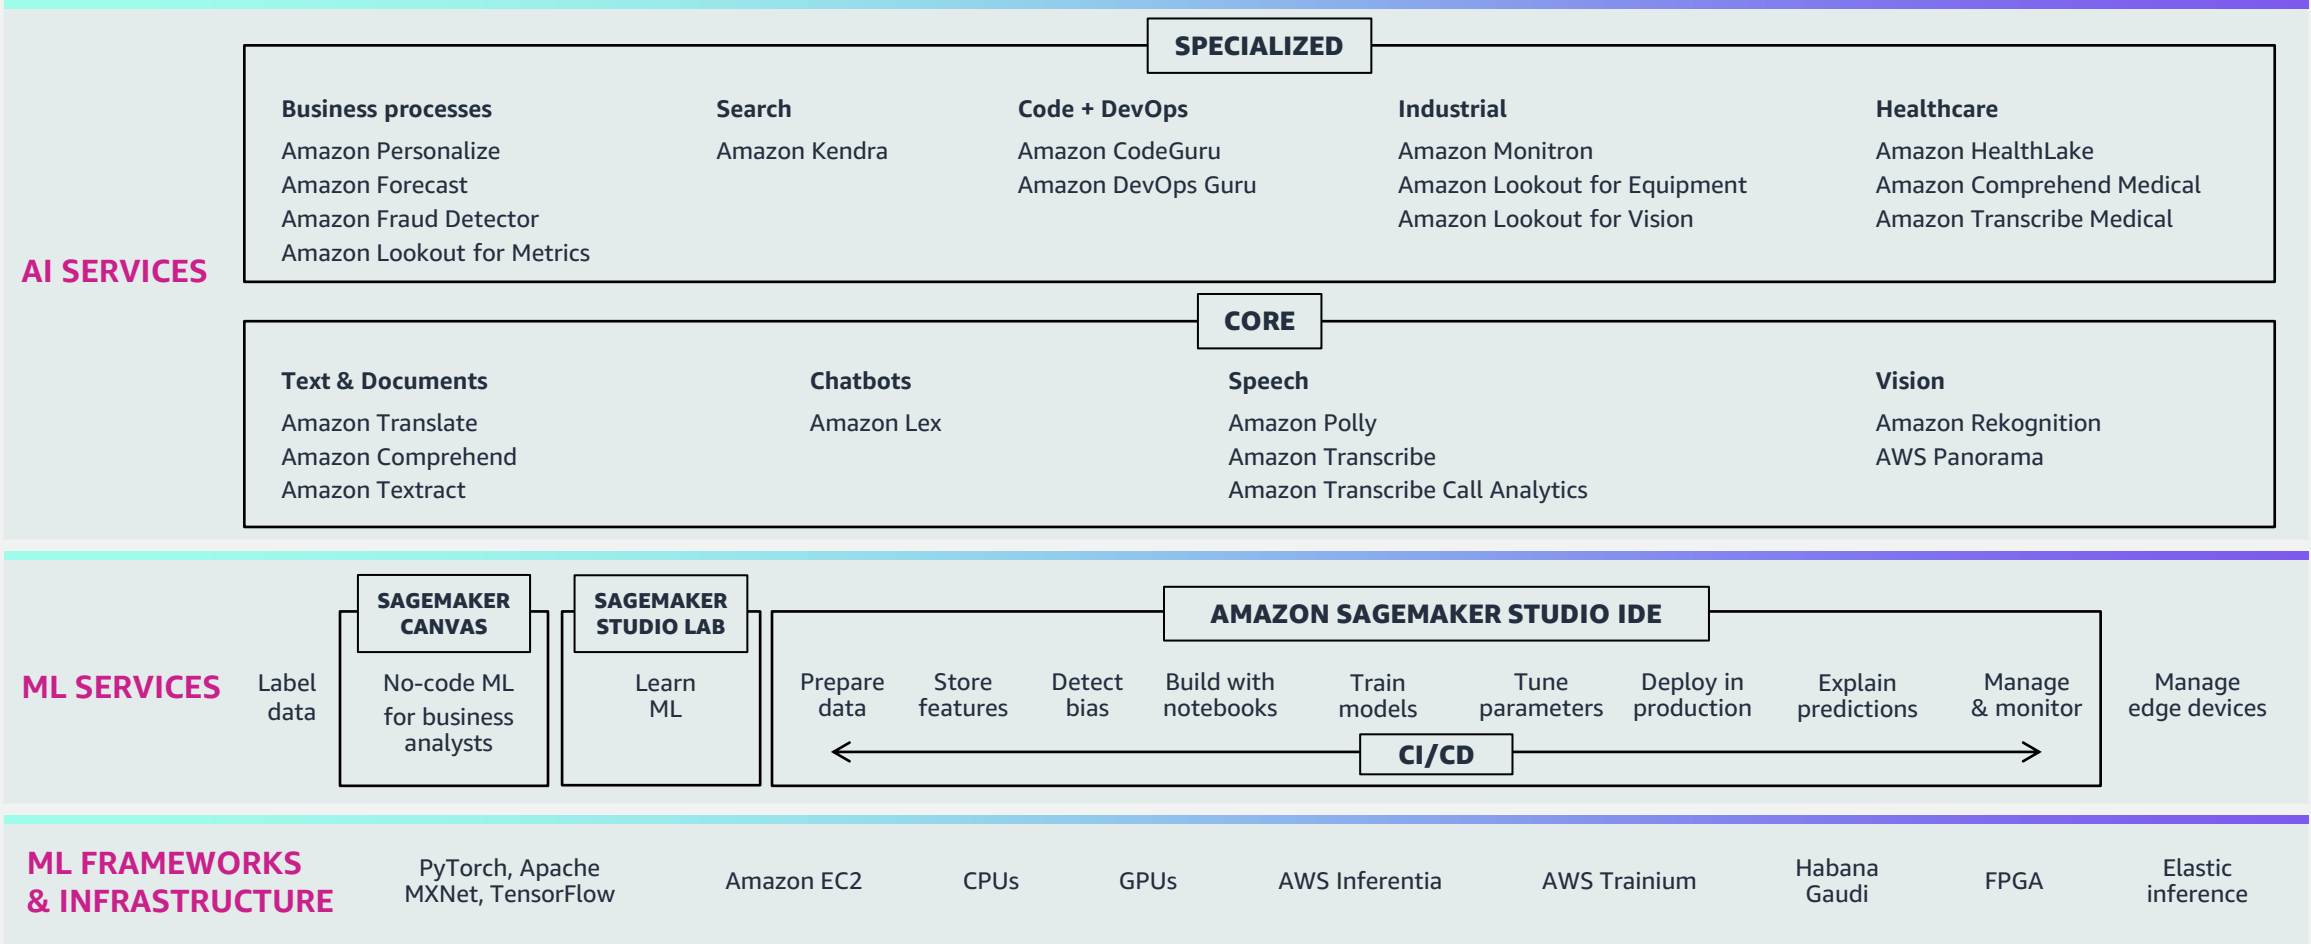
1. AWS の機械学習サービス
2. 機械学習の解説
3. DevOps と MLOps
4. 機械学習の事例

# Appendix:

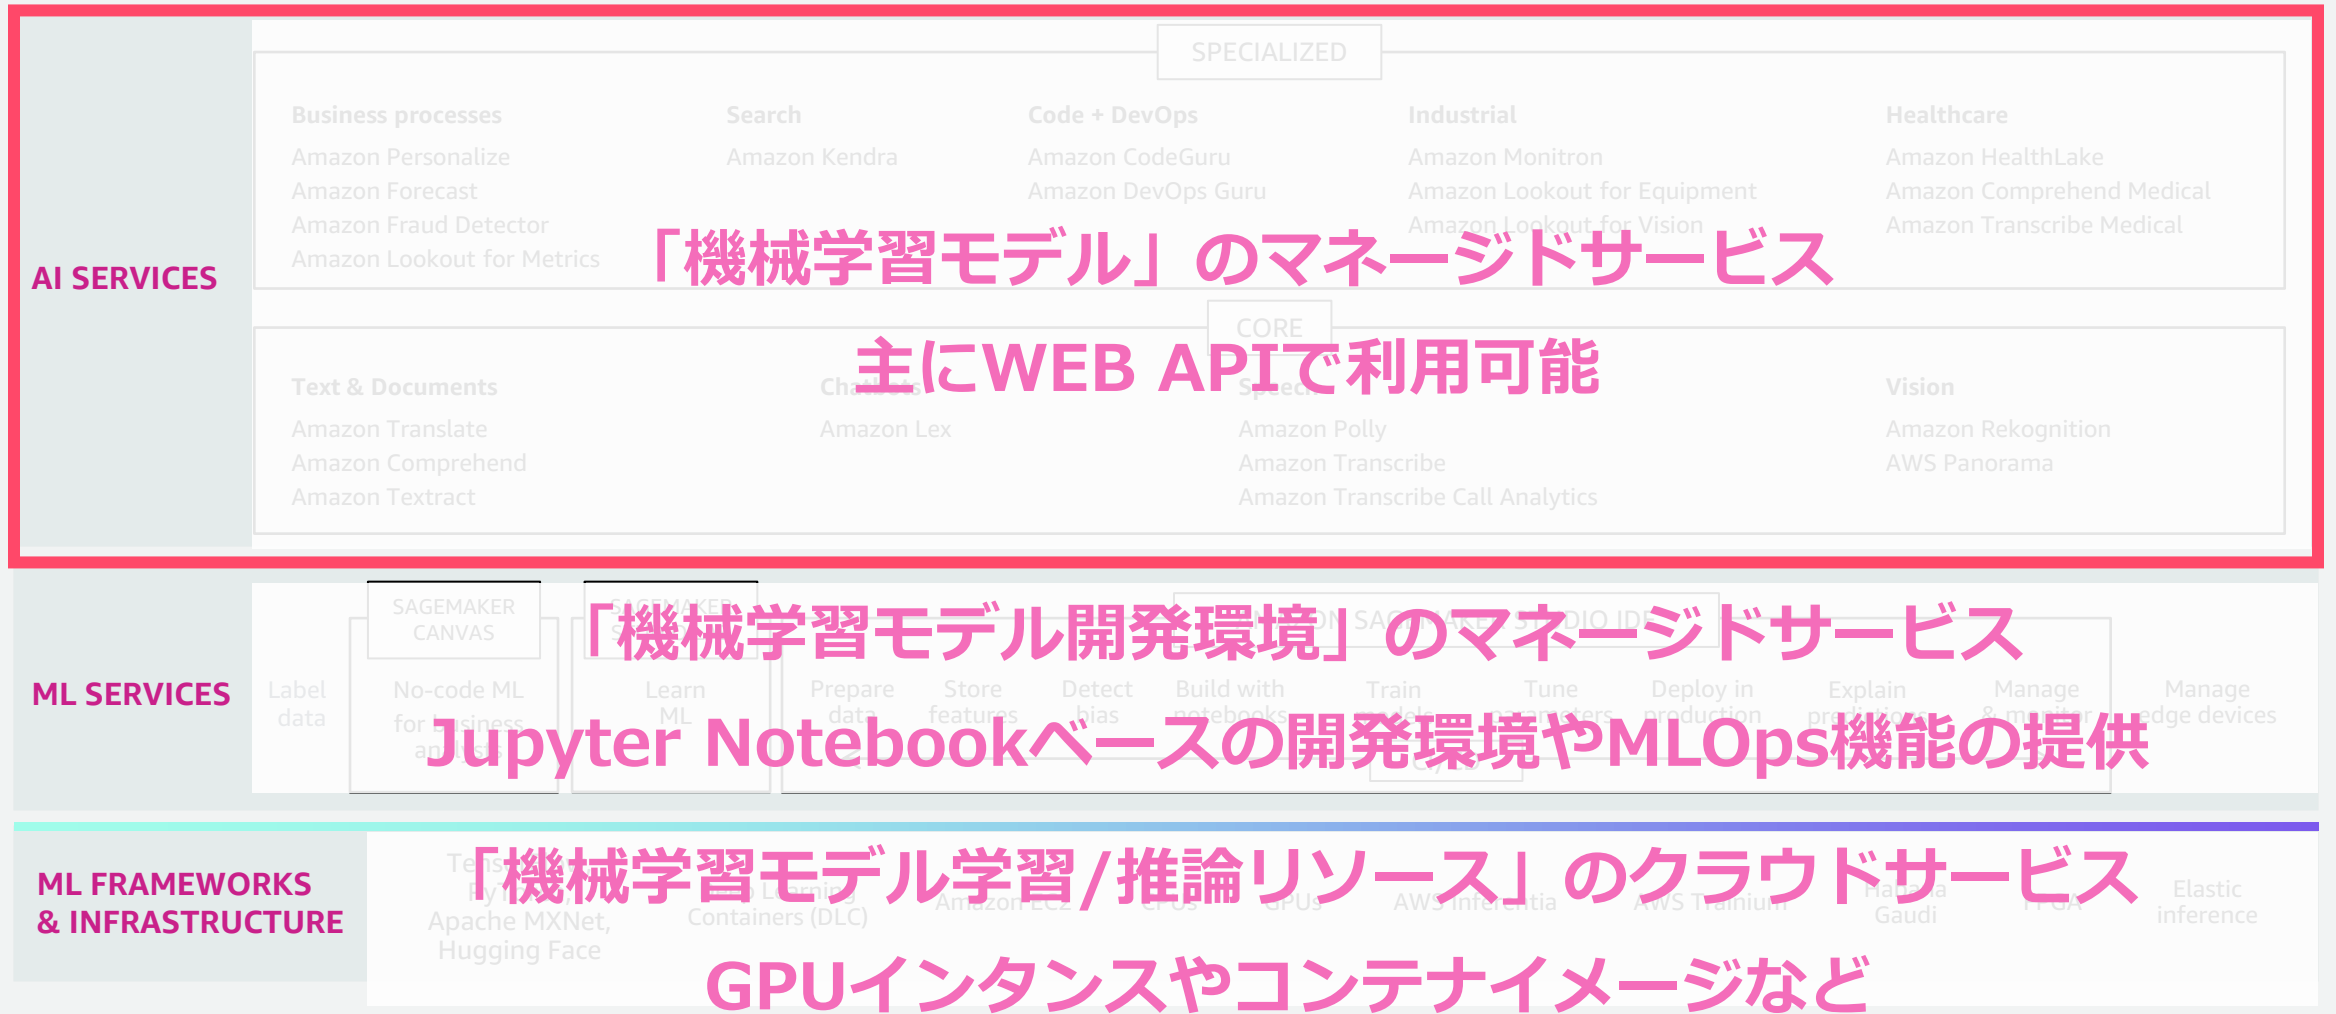
1. **AWS の機械学習サービス**
2. 機械学習の解説
3. DevOps と MLOps
4. 機械学習の事例

# AWS 機械学習サービス

## 最も広範な機械学習機能のセット

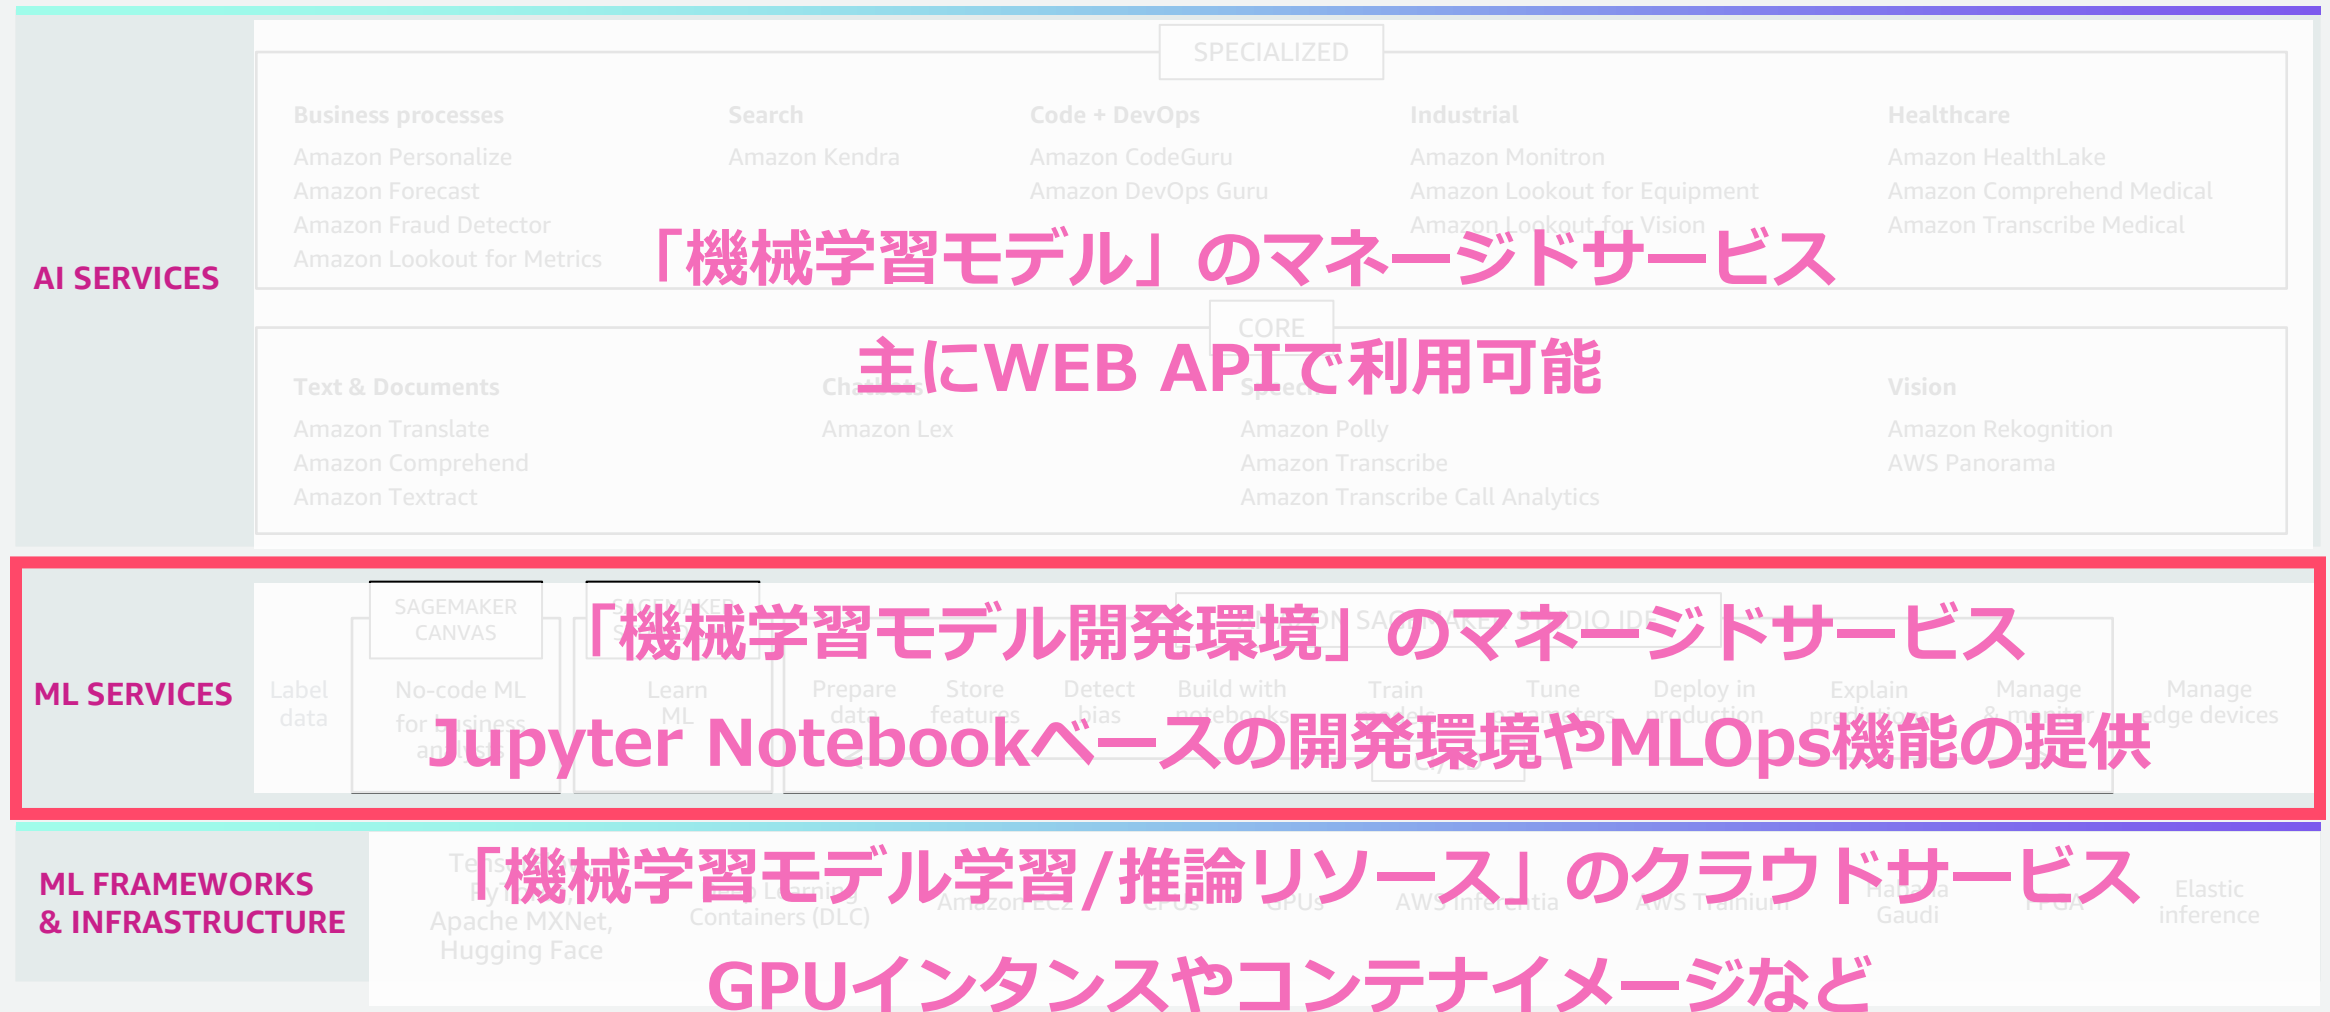


# AWS 機械学習サービス 最も広範な機械学習機能のセット



# AWS 機械学習サービス

## 最も広範な機械学習機能のセット





# AWS 機械学習サービス 最も広範な機械学習機能のセット



# AWS 機械学習サービス

## 最も広範な機械学習機能のセット


機械学習を学び、検証し、試作する

Learning

Experimenting

Prototyping

SageMaker Studio Lab



無料・メールアドレスのみで利用可


機械学習モデルを構築・運用・スケールする

Building

Deploying

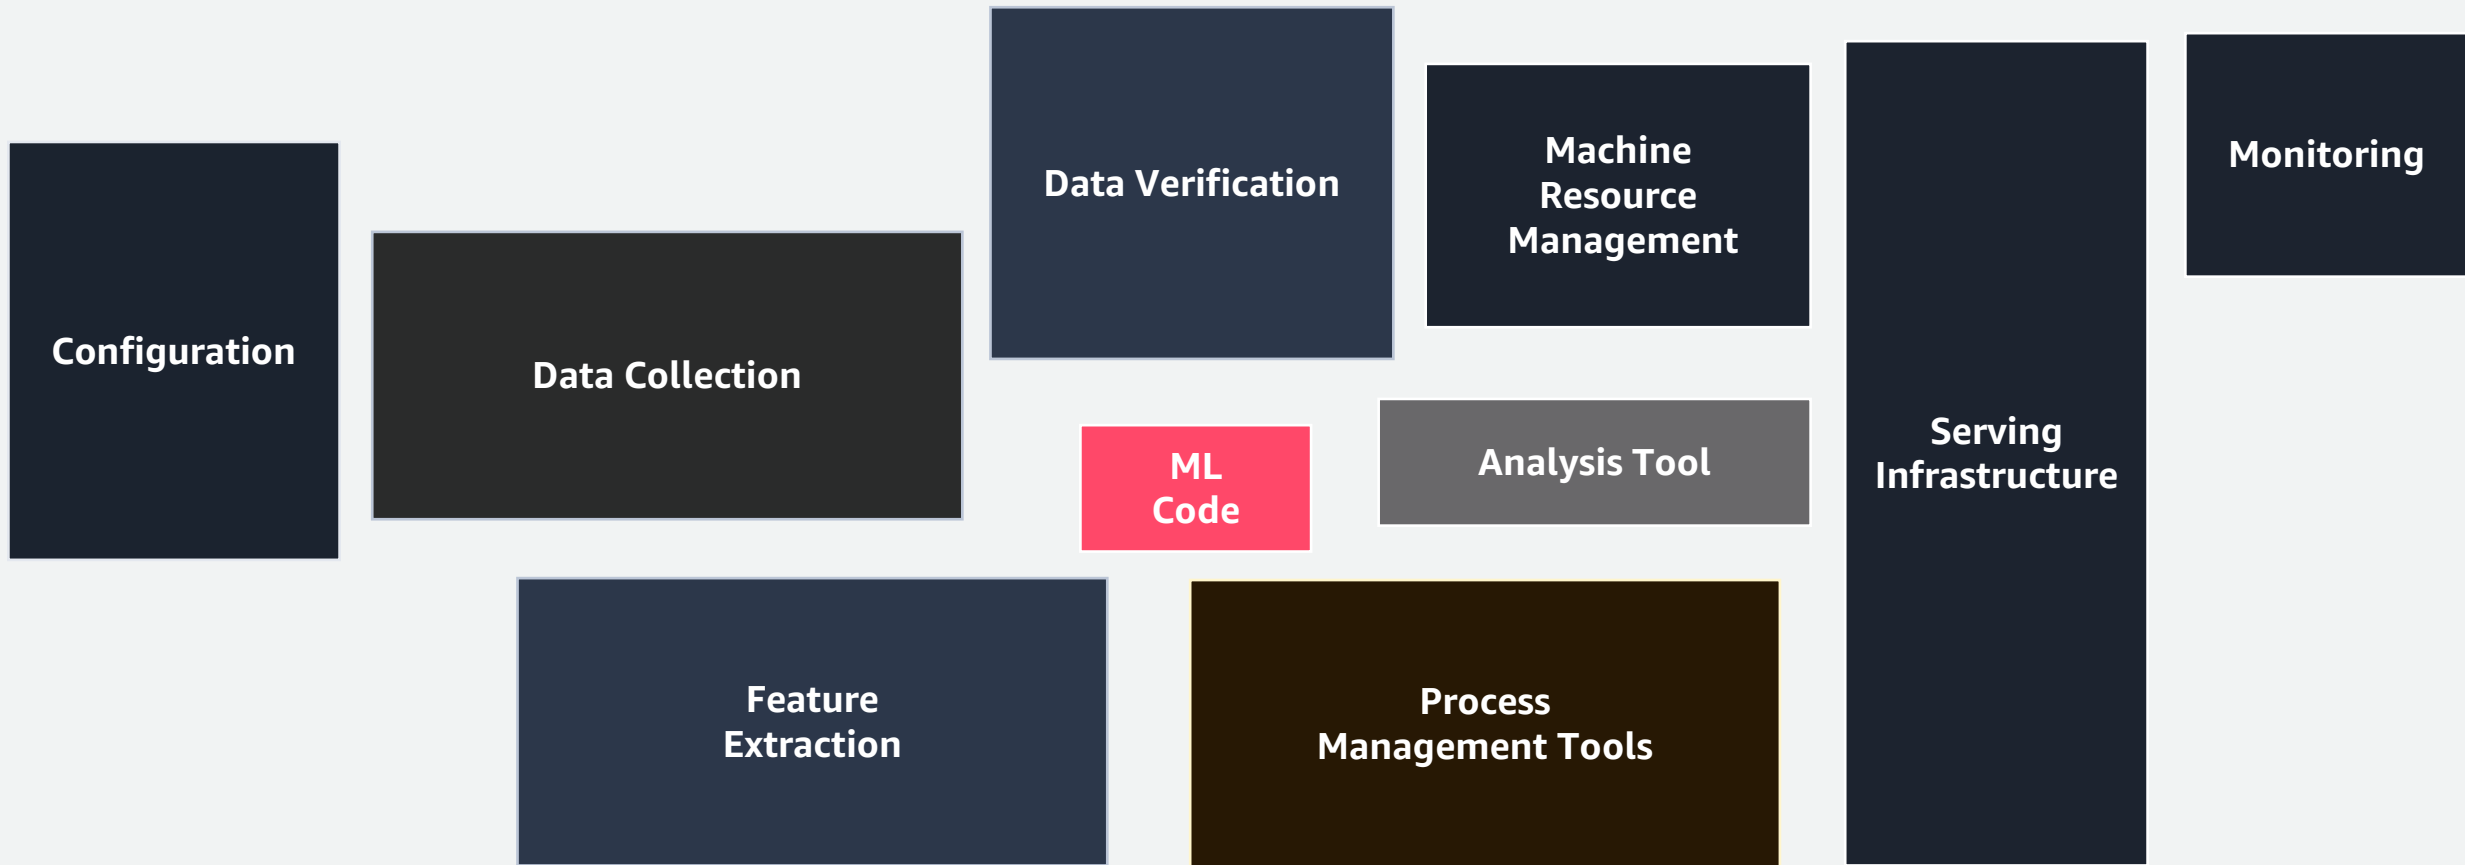
Scaling

SageMaker



# AWS 機械学習サービス

## 最も広範な機械学習機能のセット




***“Only a small fraction of real-world ML systems is composed of the ML code”***

source: Hidden Technical Debt in Machine Learning Systems [D. Sculley, & al.] – 2015

<https://papers.nips.cc/paper/5656-hidden-technical-debt-in-machine-learning-systems.pdf>

# SageMakerはML Codeに集中したい開発者のために、機械学習の技術的負債を解消するマネージドサービスを提供します



# 正確な情報を迅速かつ容易に見つけ出すことで、従業員の生産性を向上

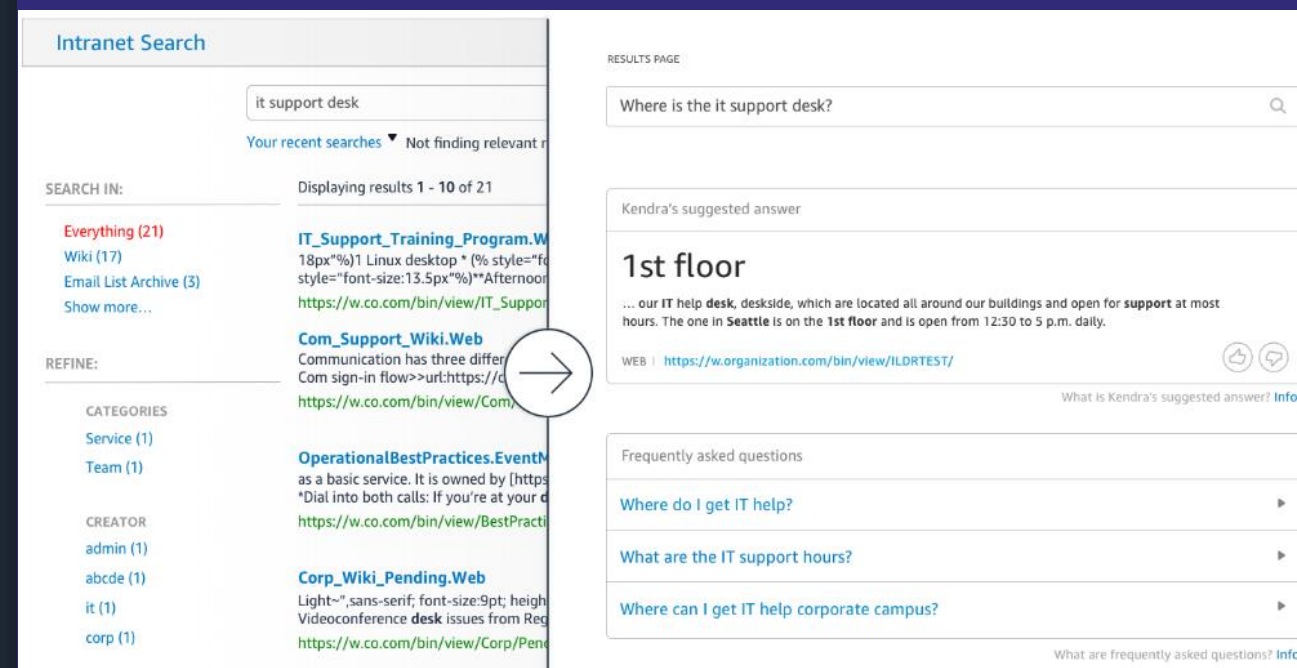
Magellan Health コンタクトセンターは、メンバー、プロバイダー、クライアントにとって重要なものです。医療分野の情報量の多さを考えると、メンバー、プロバイダー、クライアントの具体的な情報をコンタクトセンターのアプリケーションに結びつけることができるソリューションが必要でした。Amazon Kendra は、最小限の労力ですべてをシームレスに動作させることができるソリューションでした。

**BRIAN LICHTLE**  
Director of Software Engineering  
Magellan Health

**Magellan**  
HEALTH.



Amazon  
Kendra



自然な言葉で質問し、即座に回答を得る  
数回のクリックですべてのデータをまとめることができる  
絶えず改善される検索結果



# 不正なオンライン活動を迅速かつ容易に特定

Fraud Detectorの導入は、高度な機械学習技術を用いて、不正な予約を正確に検知することができるようになることを意味しています。私たちの「フロントドア」を潜在的な被害から守ることで、バケーションレンタルの体験をシームレスで安心して利用できるものにすることに集中することができます。

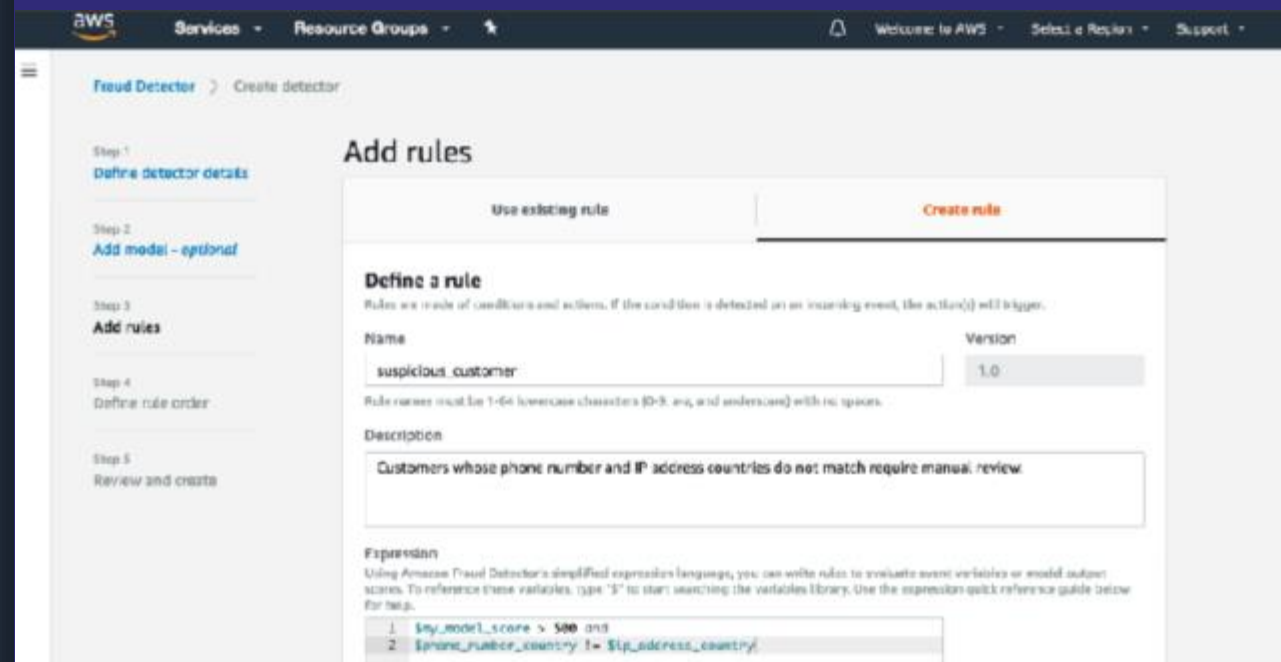
**ERIC BREON**  
Founder and CEO



Amazon  
Fraud Detector



Amazon  
SageMaker



高品質の不正検知MLモデルをより早く構築  
悪質な行為者を入り口で阻止  
オンライン詐欺に関する専門知識を内蔵  
不正防止チームにより強力なコントロールを

# リッチメディア資産を分析して価値を高め、新たな知見を生み出す

C-SPAN社 はAmazon Rekognition を使ってビデオニュースの映像を自動的にインデックス化して検索しています。C-SPAN社はRekognitionの導入により、1本のビデオのインデックス作成時間を1時間から20分に短縮し、97,000枚の画像を2時間以内にアップロードしました。

IAN CLOUTIER  
Technical Manager

C-SPAN



POPSUGAR



Media Insights Engine

Media Collection

Discover insights in your media by searching for keywords, objects, or even people.

Search Collection... Search

Thumbnail	File Name	Status	Asset ID	Created	Actions
	GrandTour.mp4	Complete	70ed493d-d376-498f-899e-4650acbb27fa	2019-09-24T21:32:04.000Z	<a href="#">Analyze</a> <a href="#">Delete</a>
	MozartTheJungleLanguage.mp4	Complete	a56229d-1546-40a9-8f18-a5ef802b61c	2019-09-24T21:30:19.000Z	<a href="#">Analyze</a> <a href="#">Delete</a>
	TwoPradoPavilion.mp4	Complete	6d133160-903e-4323-93be-a52ab80d1edd	2019-09-24T21:28:21.000Z	<a href="#">Analyze</a> <a href="#">Delete</a>

コンテキスト広告の掲載などによるマネタイズの促進

メディアサプライチェーンの主要機能の自動化によるコスト削減と生産性の向上

不適切なコンテンツが表示されるリスクや、ブランディング問題の発生を回避

# 顧客サービスの向上とコスト削減

現在、私たちはAIを使って、電話をかけてきた人のニーズに関する情報を前もって収集する試みを行っています。オペレーターはその情報を画面上で確認し、すぐに解決策を提示することができます。オペレーターは、電話をかけてきた人の役に立っていることを喜び、仕事の繰り返しが減ったと評価しています。

**CHRIS SUTER**  
Lead Cloud Architect

**NHS**  
Business Services Authority

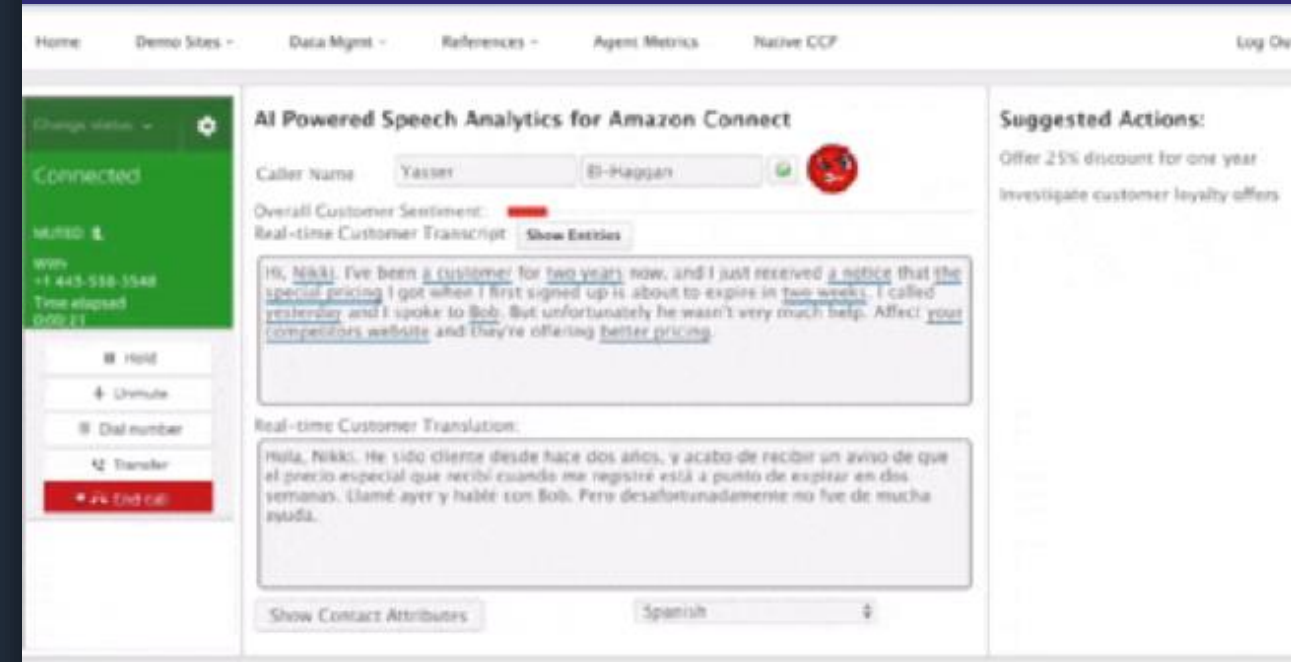
Vonage



Liberty Mutual  
INSURANCE



aws machine  
learning



コスト削減

解決までの時間（TTR）の短縮

電話の待ち時間の短縮

顧客満足度の向上


従業員満足度の向上



# パーソナライズされた提案を行い、顧客エンゲージメントを高める

Amazon Personalize を導入したことで、メールのCTRはコントロールメッセージに比べて67%上昇しました。また、コンテンツの関連性が高まったことで、オプトアウト率が36%減少しました。しかし、私にとって最も重要なのは収益です。テストメールでは、コントロールと比較して12.5%の増収が見られました。AWSが我々に新たな「矢」を与えてくれたことは明らかです。唯一の後悔は、2年前にこの旅を始めたとき、この機能がなかったことです。

KRISTINA SMITH  
Director Global Digital Marketing



高品質なレコメンデーションを実現

リアルタイムのレコメンデーションでその場を演出  
ユーザー・ジャーニーのすべてのタッチポイントをパーソナライズ

数ヶ月ではなく数日でパーソナライズを実現



SUBWAY

Pomelo.

Voodoo

NAVITIME



# ドキュメントからデータを自動的に抽出し分析することで、迅速な意思決定を行う

Amazon Comprehend と Amazon Transcribe のおかげで、VidMob はわたしたちの Agile Creative Suite に高品質の機械学習テキスト分析を組み込むことができ、ブランド顧客がこれまで不可能だった方法でコンテンツのパフォーマンスを理解できるようになりました。動画コンテンツからテキストを書き起こし、Comprehend を使って素早く分析することで、クリエイターコミュニティとクライアントの双方に実用的なインサイトを提供し、市場での戦略的優位性を高めることができます。

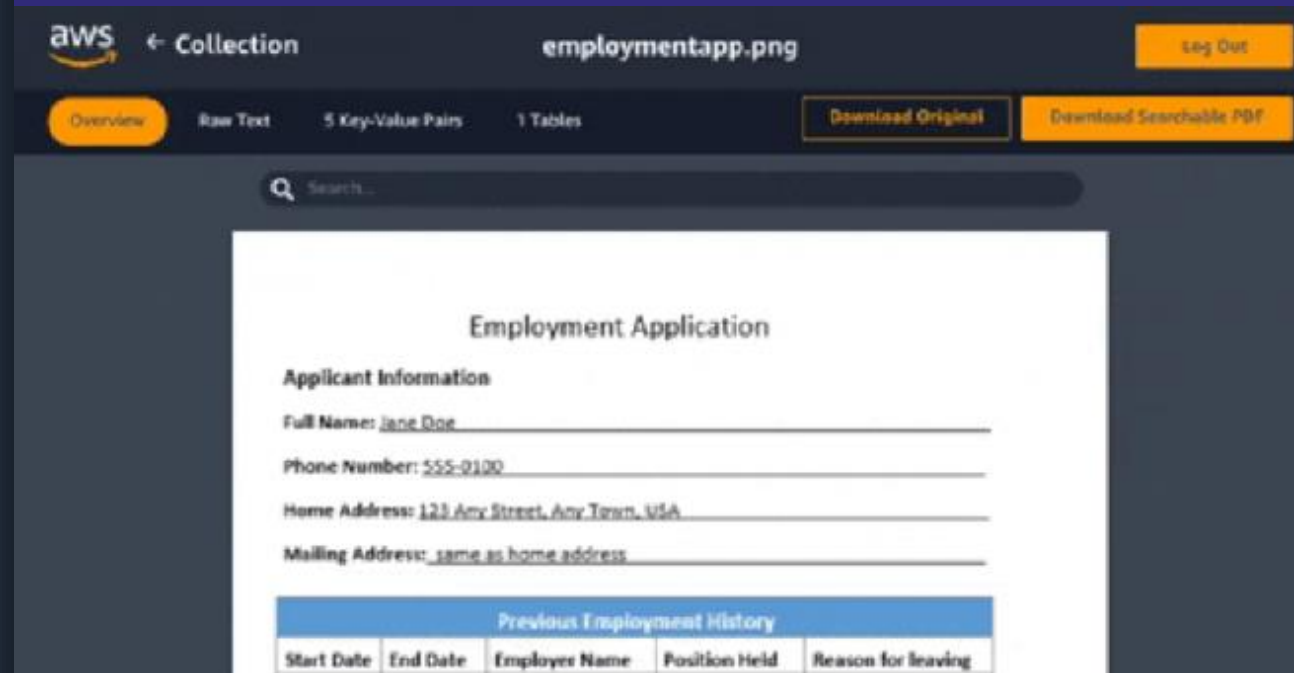
**ALEX COLLMER**  
Founder and Chief Executive Officer



Amazon  
Comprehend  
+Medical



Amazon  
Textract

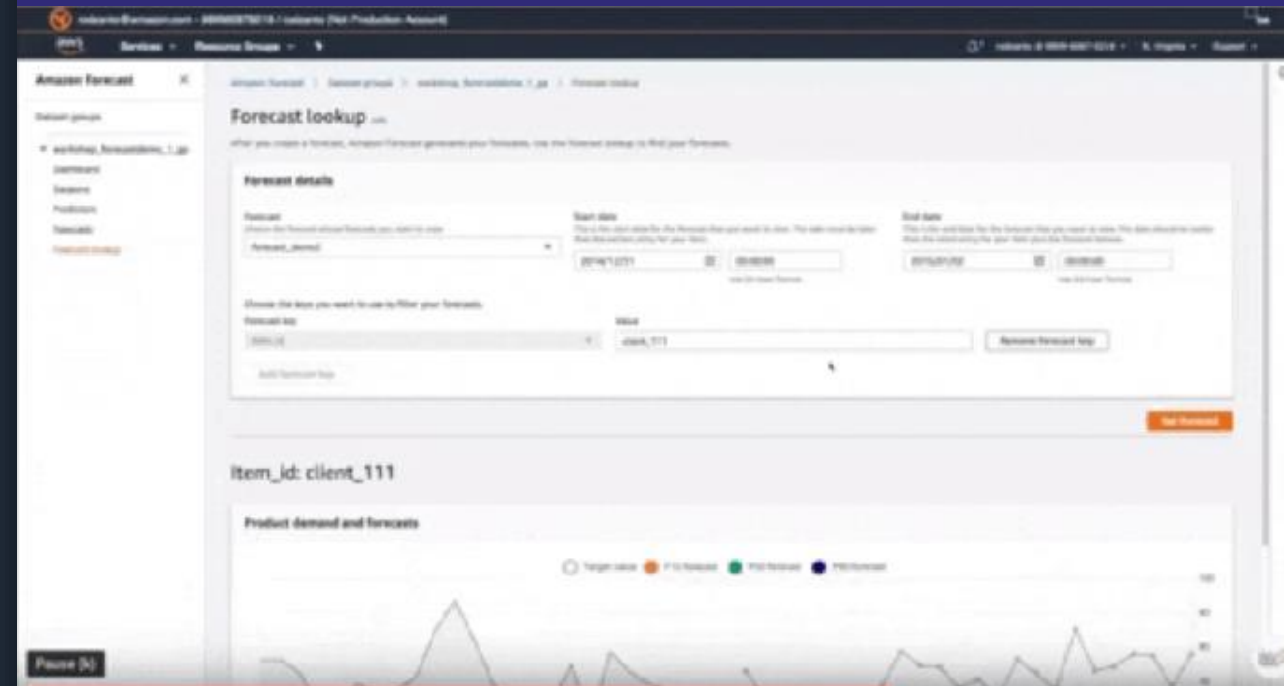


文章からより良い答えを導き出す  
ドキュメントをトピックごとに整理  
コードやテンプレートのメンテナンスが不要  
ドキュメント処理コストの削減

主要な需要指標をより早く、より正確に  
予測し、顧客の需要に応え、無駄を省く

Planalytics 社では、マーケットリーダーとしての地位を当然のものとは考えておらず、分析を改善するためのツールやテクニックを常に探しています。Amazon Forecast を使用することで、生の気象データを使った場合と比べて、迅速かつ効果的に予測の改善を図ることができます。この定量化は Planalytics 社にとって画期的なことであり、お客様に本当のROIを証明できるようになります。

**DERRON SIMON**  
Chief Operating Officer



機械学習により予測精度が50%向上  
予測にかかる時間を数ヶ月から数時間に短縮  
ほぼすべての時系列予測を作成  
ビジネスデータの保護

CJ LOGISTICS

MOTOR

DEV  
FACTORY

PSE PUGET SOUND ENERGY

AffordableTours.com

aws machine  
learning

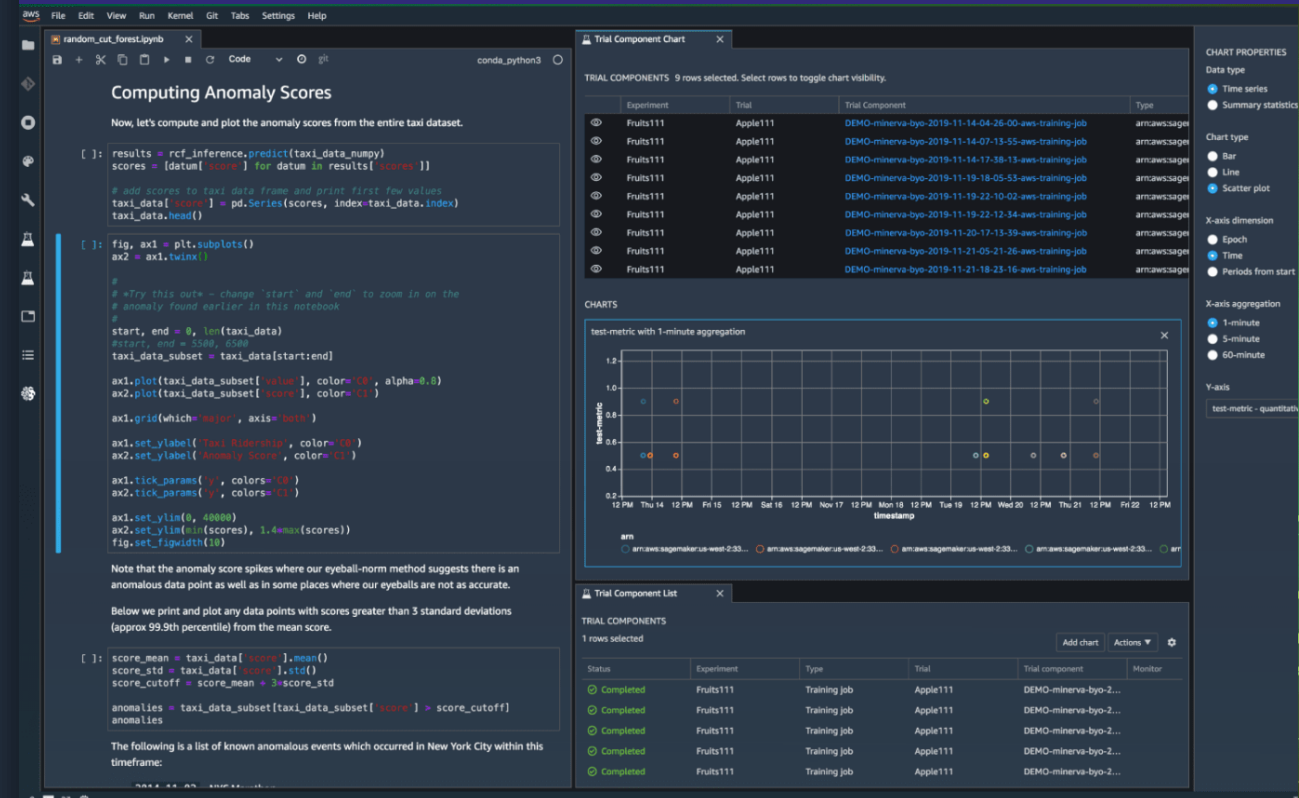
# MLワークロードのスケールリング、生産性の向上、コスト削減により、イノベーションを加速

SageMaker で分散学習を行うことで、モデルのトレーニング時間を数日から数時間に短縮しました。機械学習のワークロードを AWS で標準化することで、開発サイクルの効率化とコスト削減を実現し、最終的に自動運転機能をお客様に提供するというミッションを加速させました。

Alex Bain  
Lead for ML Systems at Lyft Level 5



Amazon  
SageMaker



チームの生産性を10倍向上

マネージド・スポット・トレーニングで90%のコスト削減

推論コストを75%削減

54%のTCO削減



Domino's



# コードの問題をプロアクティブに 検出し、DevOpsデータから実用的

私たちにとって、カスタマーエクスペリエンスは極めて重要です。お客様に影響を与えるインシデントを防止・軽減しようとする、可用性、パフォーマンス、変更要求などのアラートの複数のソースに対処することが課題となります。私たちは、Amazon DevOps Guru を使用し、そのMLを利用した洞察力を活用して、行動のための明確な道筋を提供できることを嬉しく思っています。これにより、問題を迅速に軽減し、お客様に影響を与えるイベントを回避することができます。また、PagerDutyとの連携により、レコメンデーションを適切な人にタイムリーかつ効率的に届けることができますようになりました。

**STEVE THOENNES**

Director Infrastructure Hosting Portfolio



THOMSON REUTERS

**ATLASSIAN**



THOMSON REUTERS

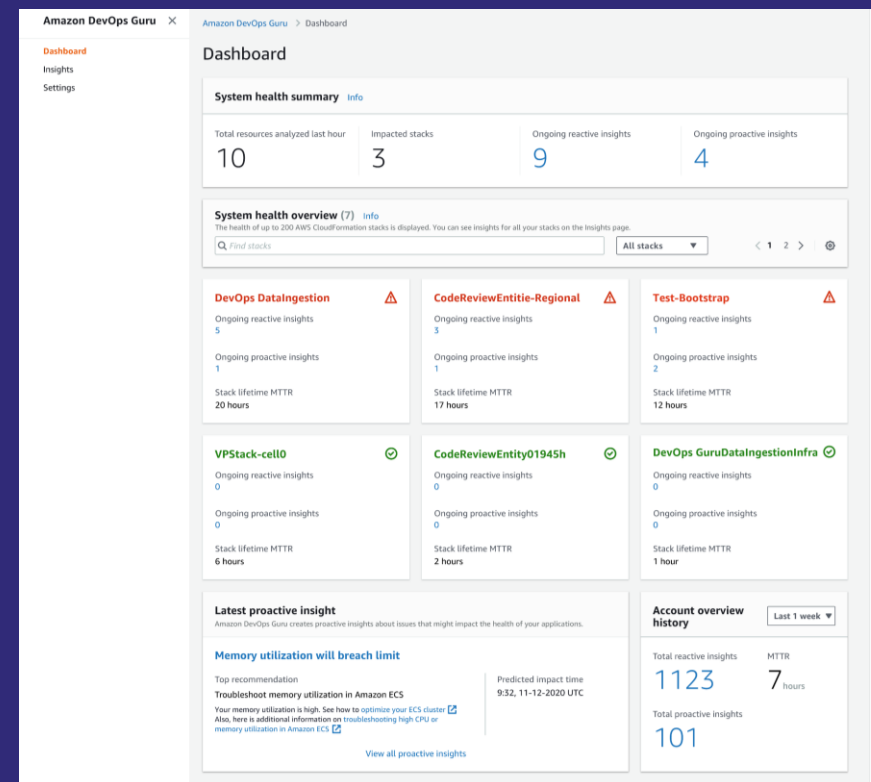
**aws** machine  
learning



Amazon  
DevOps Guru



Amazon  
CodeGuru



運用上の課題を自動的に検出

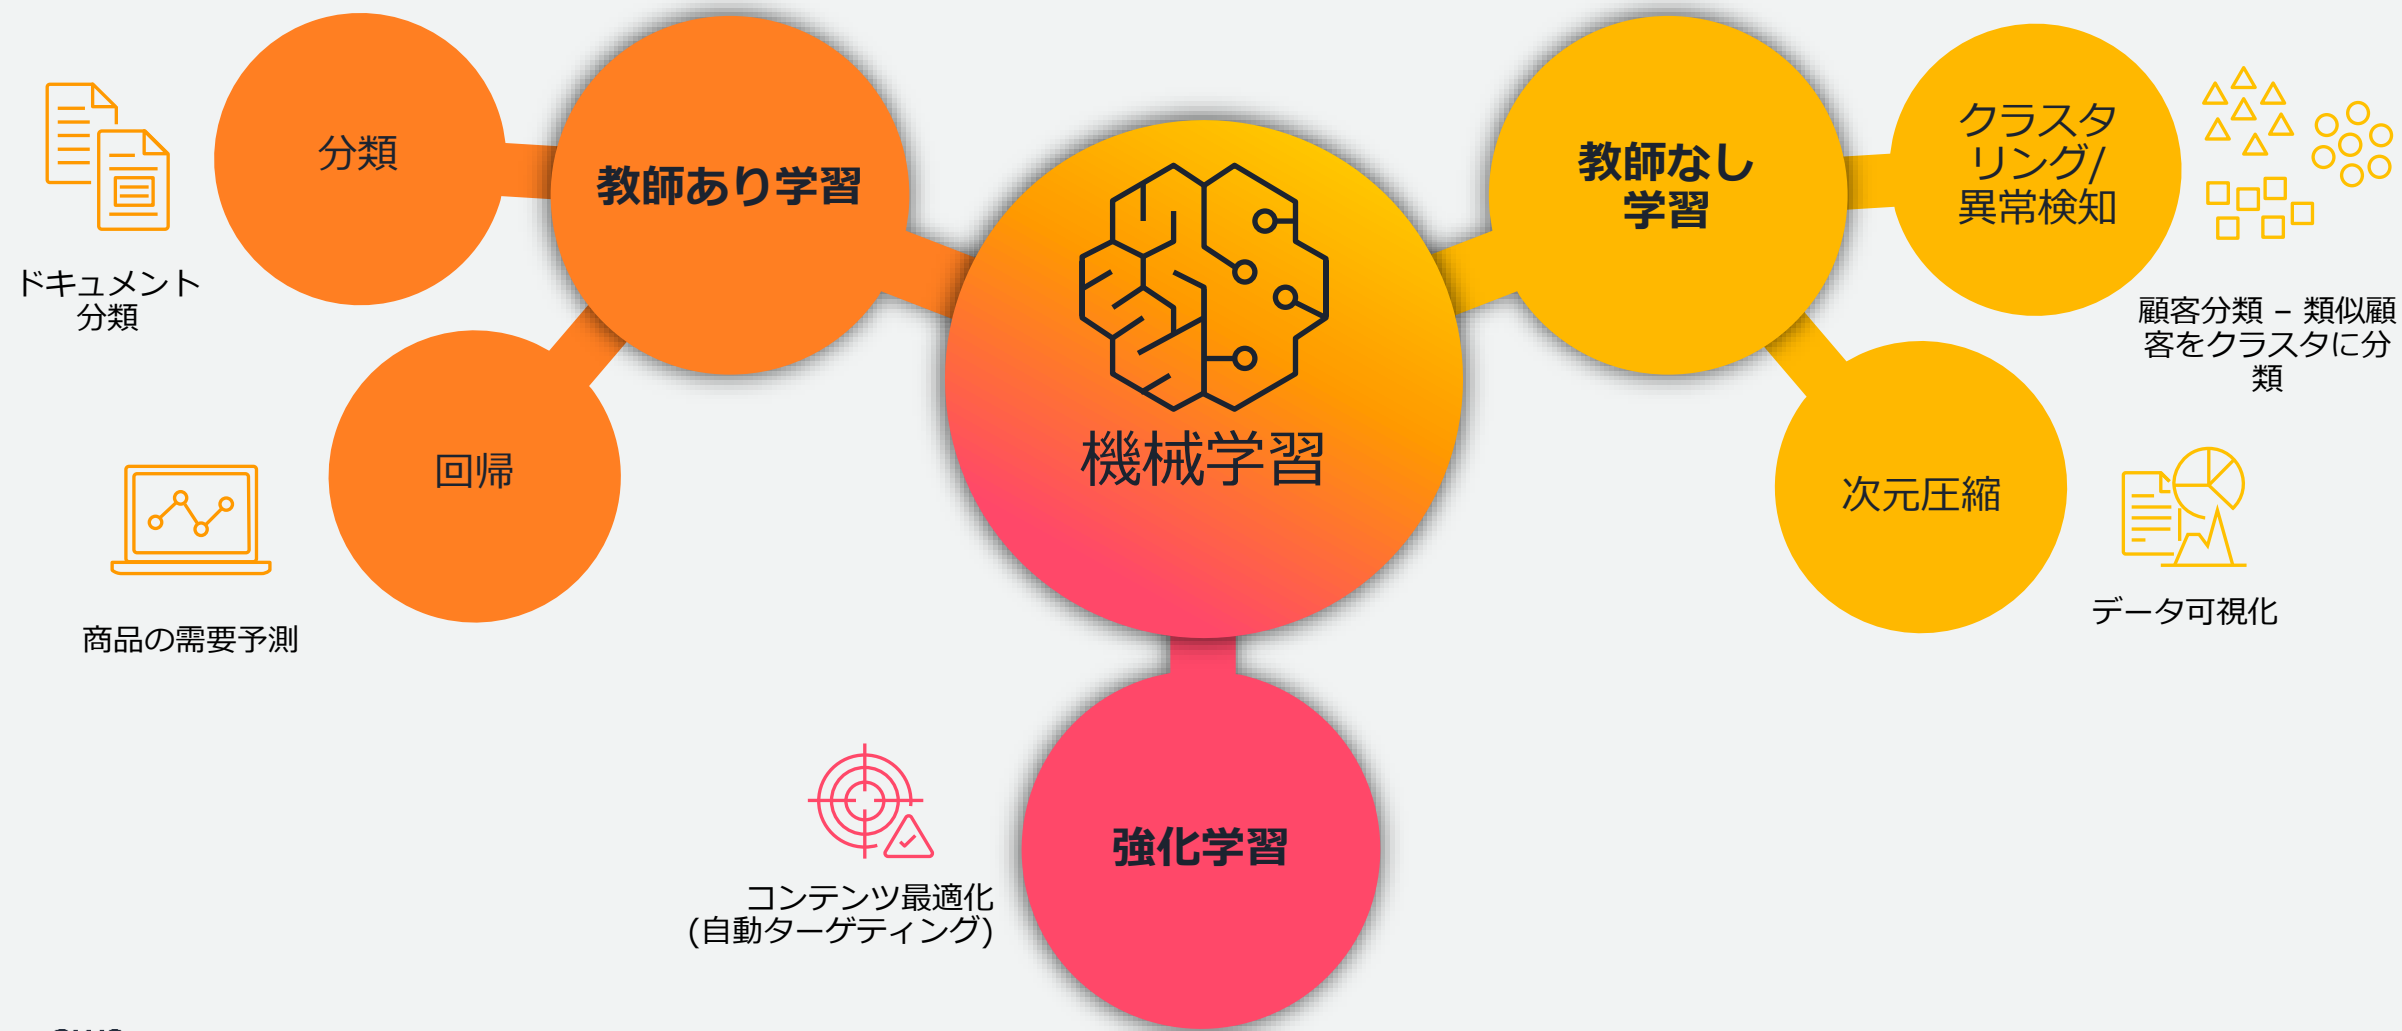
MLを活用したインサイトで課題を迅速に解決  
ベストプラクティスを実施するための実行可能なステップ  
を提供

# Appendix:

1. AWS の機械学習サービス
- 2. 機械学習の解説**
3. DevOps と MLOps
4. 機械学習の事例



# 機械学習の手法



# 機械学習のメリット

## 1. 実装容易性

プログラミング言語の知識がなくても計算処理を実装できる。  
(データを集めれば実装できるという点で)

## 2. 高速な演算

行列演算で処理が構成されるため、GPUによる高速化が可能。

## 3. 高精度

画像認識や音声認識など一部領域で既存ソフトウェアを上回る。

## 4. 可搬性

モデルの実行環境があればどこでも動かせる。



# MLモデルの一般的なタスクとユースケース (1/2)

## 回帰

物件価格を予測

Zillow

Zestimate  
\$1,496,442



ZESTIMATE RANGE  
\$1.38M - \$1.62M



LAST 30 DAY CHANGE  
+\$24,008 (+1.6%)

## 分類

見直しが必要な単語か予測

duolingo



## クラスタリング

アニメーションの自動タグ付け

Disney



# MLモデルの一般的なタスクとユースケース(2/2)

## 異常検知

新たな不正行為の特定


Fraud.net



## ランキング

検索結果の並び替え


ibotta



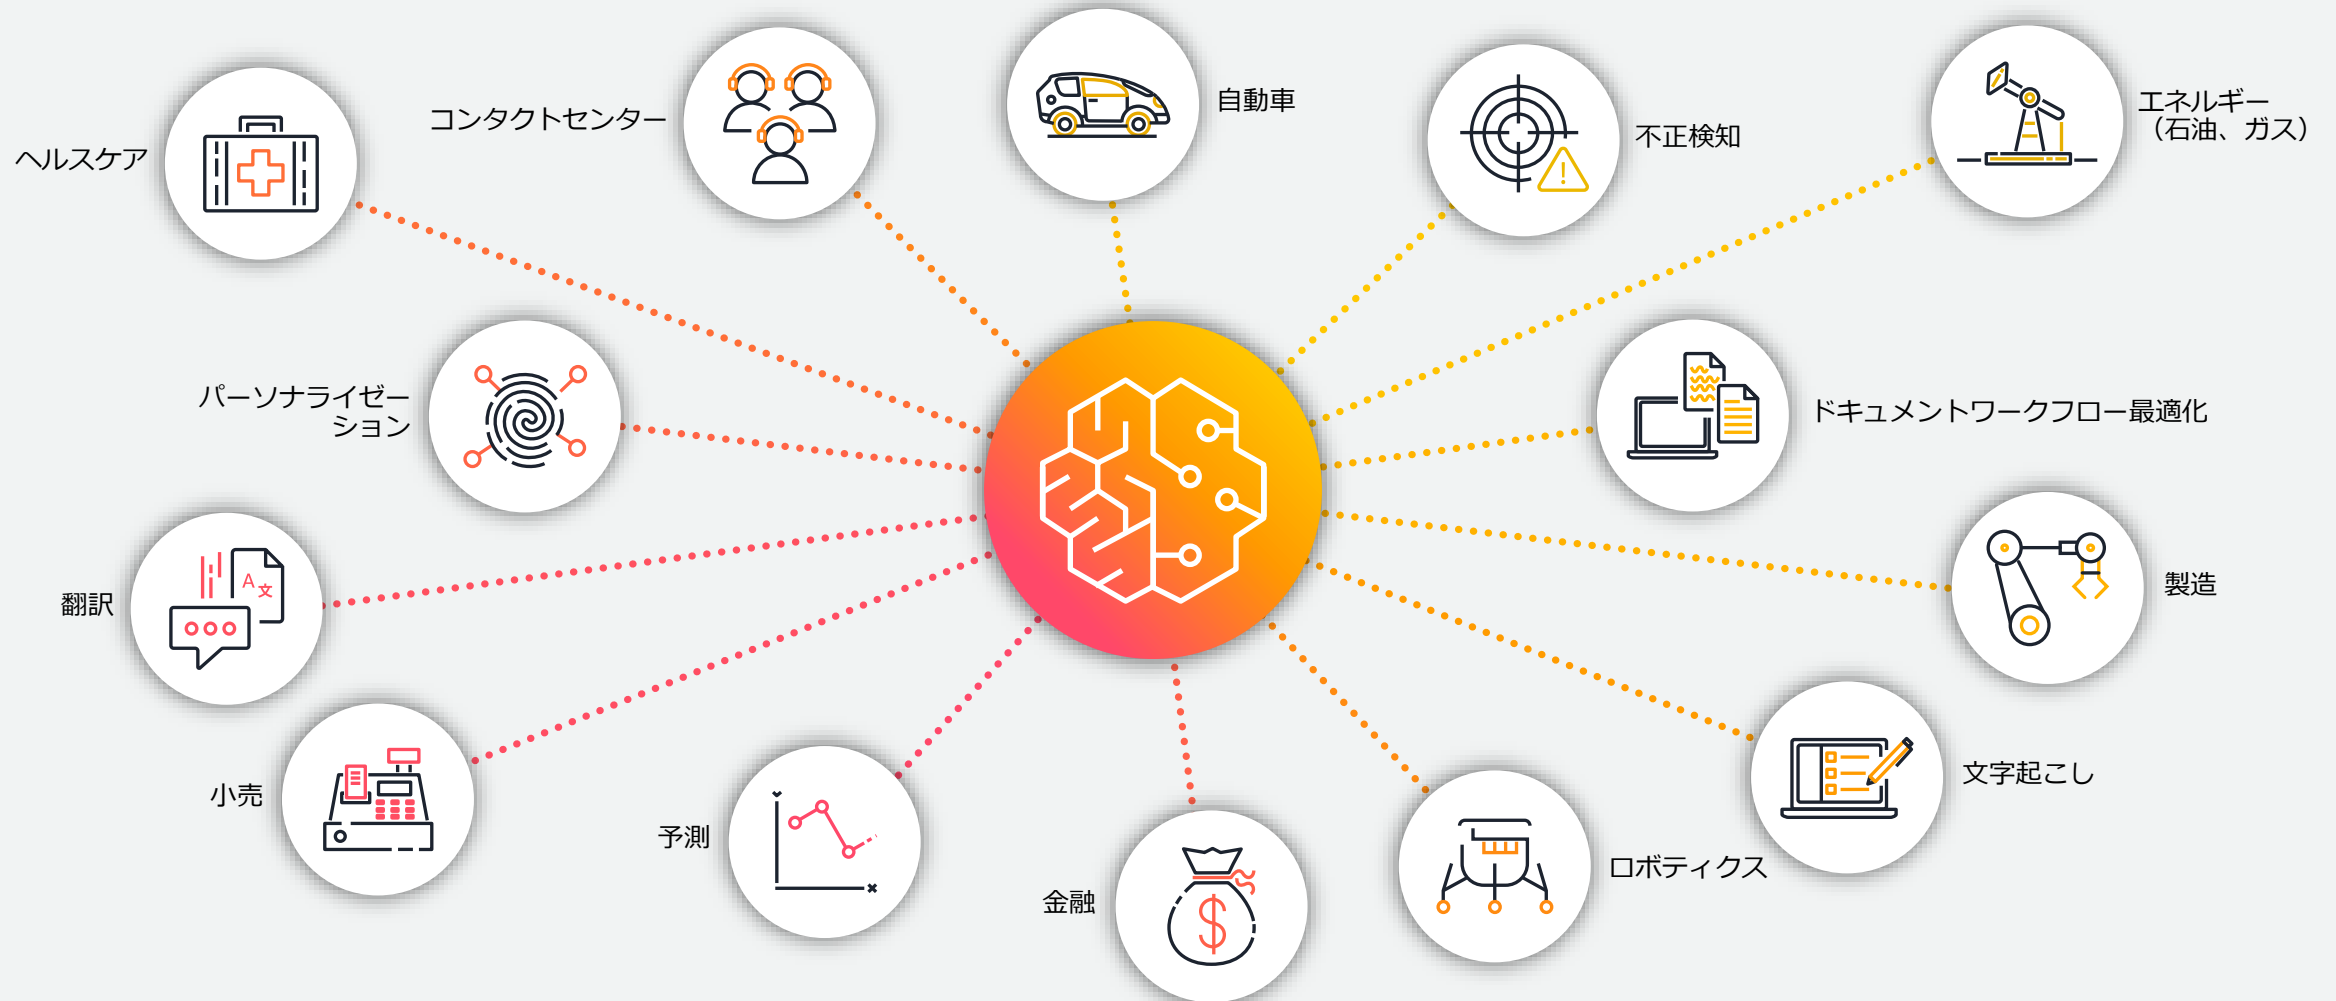
## 推薦

大規模イベント用ホテルの推薦

HYATT




# 機械学習はあらゆる場面に



# Amazonでの機械学習の実用例

## AMAZON'S MACHINE LEARNING INNOVATION



# ナレッジチェック: 機械学習のタスク

**次のユースケースに適用できる機械学習のタスクは何?  
回帰・分類・クラスタリング・異常検知・ランキング・推薦**

- a) 人手による商品価格設定の効率化
- b) 偽造品の特定
- c) 誤って分類された商品の識別
- d) マーケティングセグメント特定のための顧客のグループ化
- e) コホート別顧客支出の予測



# ナレッジチェック: 機械学習のタスク

次のユースケースに適用できる機械学習のタスクは何?

回帰・分類・クラスタリング・異常検知・ランキング・推薦

- a) 人手による商品価格設定の効率化 - **回帰**
- b) 偽造品の特定 - **分類**
- c) 誤って分類された商品の識別 - **異常検出**
- d) マーケティングセグメント特定のための顧客のグループ化 - **クラスタリング**
- e) コホート別顧客支出の予測 - **回帰**


**上記以外の方法がありますか？**

# Appendix:

1. AWS の機械学習サービス
2. 機械学習の解説
3. DevOps と MLOps
4. 機械学習の事例

# DevOpsに基づく開発プロセスの流れ


## DevOps



[AWS “DevOpsとは?”より図を引用](#)



# DevOpsのおさらい

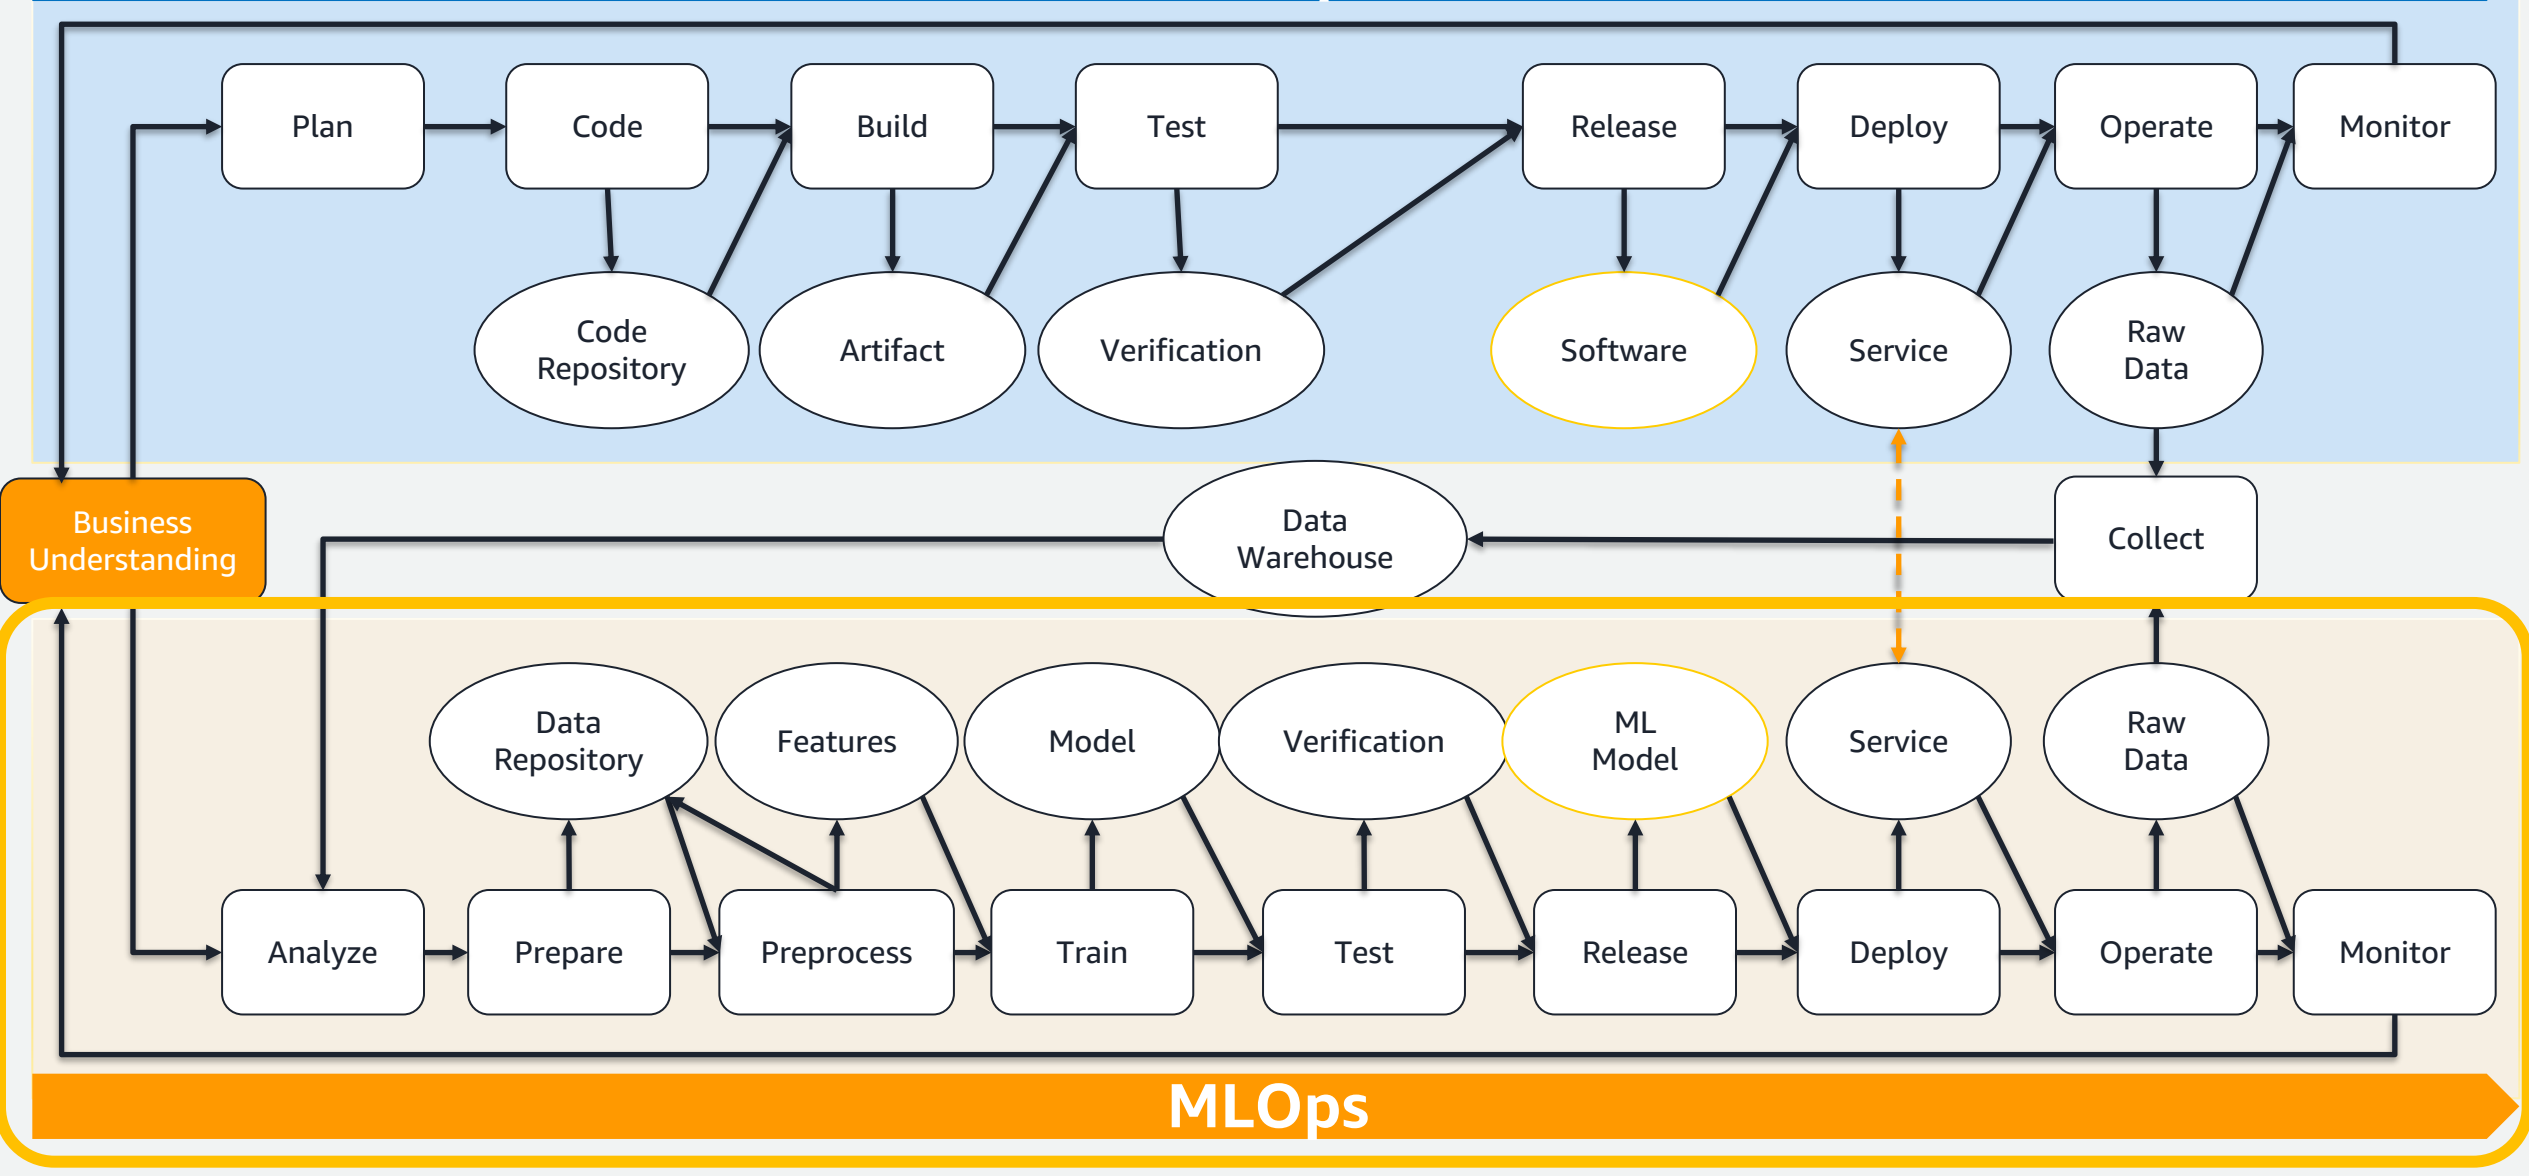


DevOpsは開発(Development)と運用(Operations)から成る造語。分断されていた開発チームと運用チームを協調させる。

1. ソフトウェア／システムのビジネス価値をより高める
2. ビジネスの価値をより確実かつ迅速にエンドユーザーに届け続ける


# 機械学習プロジェクトではモデルを開発するMLOpsが加わる

## DevOps




**MLOps は、DevOps の開発手法や組織文化を、  
機械学習の開発に取り込んだ開発手法**

MLOpsのプロセスはまだ定まったものがないが、下図はAWSの定義([MLLens](#))を主に参照し定義。




# 蓄積されたデータから機械学習モデルを構築し、連携させる

## ① DevOpsによるソフトウェア開発



## ② 利用データの蓄積



## ④ API連携

## ③ MLOpsによる機械学習モデル開発

# Appendix:

1. AWS の機械学習サービス
2. 機械学習の解説
3. DevOps と MLOps
- 4. 機械学習の事例**

# Intuit: 問い合わせ回答待ちの時間を削減

## BUSINESS NEED

Intuitには毎年1650万人以上の顧客からの問合せがあり、総対応時間は2.75億分/年にもものぼる。顧客は対応の待ち時間にいらついていた。

また、問い合わせは所得税申告の1月から4月に集中し、その間だけコンタクトセンターの対応要員を6,000から10,000にスケールさせる必要があった。

## SOLUTION

問い合わせ内容を自動で「**分類**」し、対応するセルフサービス型のオンラインサポート機能を実装。コールセンターへの問い合わせを自動で書き起こし、業務を効率化。前者にAmazon Lex(チャットボット)とPolly(音声合成)、後者にContact Lens for Amazon Connect(機械学習による音声分析)を使用。

## IMPACT

セルフサービス型オンラインサポートにより問合せコール数を削減。また、6カ月かかっていたコールセンターのスケールを2週間に短縮。

# Fannie Mae: 債務不履行となる可能性を予測し貸倒を抑止

## PROBLEM

ローン申請者の資産評価を行うため、毎日40,000件の評価レポートと50万枚の画像を受け取っていた。より適正な審査を行うためには、データに基づく判断を支援する適切なツールが不可欠だった。

## SOLUTION

ローン審査業務の各工程で利用する予測モデル(**回帰**や**分類**)を構築。実装に Amazon SageMaker(MLモデルの開発環境) を活用。

## IMPACT

業務を効率化するだけでなく、債務不履行の可能性のあるローン申請者の特定精度を3.5%から48%まで改善。モデルの透明性を維持するため、貸し手、投資家、アナリストのそれぞれに開発過程の可視化を実施。

MORE INFO: [ARTICLE](#)



# Intuit: 控除対象の経費を探す時間を削減

## PROBLEM

Intuit社の主力製品「TurboTax」を用いて米国の所得税控除の申告書を作成する際、ユーザが控除対象となる項目の抽出に多くの作業時間を要していた

## SOLUTION

顧客の1年間の銀行取引データを解析し、控除可能な経費を自動的に「**分類**」。  
モデルの構築に Amazon SageMaker(MLモデルの開発環境) を活用し、「ExpenseFinder」という商品を開発。

## IMPACT

ユーザの作業時間を数時間から数分に短縮。また、SageMakerの導入によってAI/MLを実用化するまでの期間を90%短縮（6カ月→1週間）。

# Pomelo: 嗜好に合う商品を探す時間の削減

## PROBLEM

創業以来同じ形式でWebサイト上に商品が表示されており、販売データの反映も遅かった。そのため、顧客は好みの商品を見つけることもトレンドの商品を見つけることも困難だった。

## SOLUTION

個々の顧客向けにパーソナライズされた商品**推薦**を実装。推薦に使用するデータを最新化し、顧客の好みを数分で反映できるようにした。実装にはAmazon Personalize(推薦)を活用した。

## IMPACT

商品カテゴリページから個別商品へのクリックスルー率を18%向上し、商品カテゴリページからの収益を15%向上した。これにより、1カ月以内にROI 400%増加を達成。

MORE INFO: [CASE STUDY](#) | [VIDEO](#)



# Fraud.net: 新たな詐欺の手法を検知し不正利用被害を防止

## PROBLEM

新たな詐欺の手口がどんどん開発されるため、顧客の不正利用被害を防ぐには多様な手口それぞれについて高い精度で検知する必要がある。しかし、現状では1つのモデルで**異常検知**しているため個々の手口の精度を高めることが困難だった。

## SOLUTION

単一のモデルですべての不正に対応する方式から、不正ごとにモデルを構築する方法に切り替えた。これにより、個々の不正検知の精度を高めることができる。一方で、モデルの管理が煩雑になるため管理、運用を行うためAmazon Machine Learningを採用した。

## IMPACT

個別の不正を正確に検知できるようになったことで、Fraud.netの顧客は1週間で100万ドルの不正被害を防止できるようになった。200ミリ秒以内での応答が可能になり、アプリケーションのレスポンスも改善された。