



ML Enablement Workshop #3 : 開始編

成長サイクルの検証を 開始する

久保 隆宏

Developer Relation
Machine Learning

ML Enablement Workshop

プロダクトマネージャー、開発者、データサイエンティストの3者が**組織横断的**に AI/ML のユースケースを特定し **1~3 カ月以内**に手ごたえを得る計画を作る。

理解編

目的

機械学習の改善がプロダクトの成長につながるサイクルを理解し、アイデアを**ビジネスモデル**に落とし込めるようになる。

アウトプット

自社プロダクトの成長サイクルを表すビジネスモデル図

時間

・ 2~3時間

応用編

目的

顧客への**提案シナリオ**を作成、シミュレーションすることで事前に反応を洗い出し対処すべき課題を洗い出す。

アウトプット

顧客への提案シナリオと反応を可視化したボード

時間

・ 3~4時間

開始編

目的

改善後の体験実現を最終目標とし、実現可能かつ短期で効果と学びが得られる最初の計画を立てる。

アウトプット

1~3 カ月間の活動と計測指標
をまとめた行動計画

時間

・ 2~3時間

はじめに：応用編の振り返り

- 多様な選択肢がある顧客に選ばれるにはストーリーが不可欠。
 - 顧客や社員の生活や業務で、プロダクトを採用する必然性が生まれるかを Step by Step にイベントを書き出すことで確認する。
- ストーリーを可視化することで関係者を巻き込む。
 - 顧客との接点を作るのは営業、プロダクトを実装するのは開発者やデータサイエンティスト、パートナーとの契約は調達部門などビジネスモデルを実現するには様々なチームの力が必要。
- ストーリーが成立するかシミュレーションを行い検証する
 - 具体的な顧客にサービスを提案し使ってもらう様子をシミュレーションし回答すべき質問を洗い出すことで、検証のためのアクションにつなげる。

開始編で計画を立てる範囲

加速フェーズ
1~3 ヶ月

ユースケースを決め、
仮説検証に着手する

異なるチームとの協調を
日常的にする

チームで検証を繰り返し
価値あるユースケースを
特定する

拡大フェーズ
1 年～

AI/ML の組織戦略立案

検証を通じ得られた知見をもとに、長期的な AI/ML の投資計画を立て、推進するための組織を組成する。

データ基盤・ML基盤構築

仮説検証の速度、AI/ML の開発速度を速めるためのデータ基盤や ML 基盤の設計と構築。

チームワークの醸成

MLEW から始まったチームワークを組織全体へ波及しつつ、責任ある AI 活用に向けガバナンスを整える

開始編の流れ

1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
3. 実践

20 min

90 min

開始編の流れ

1. 成長サイクルの検証を開始する

20 min

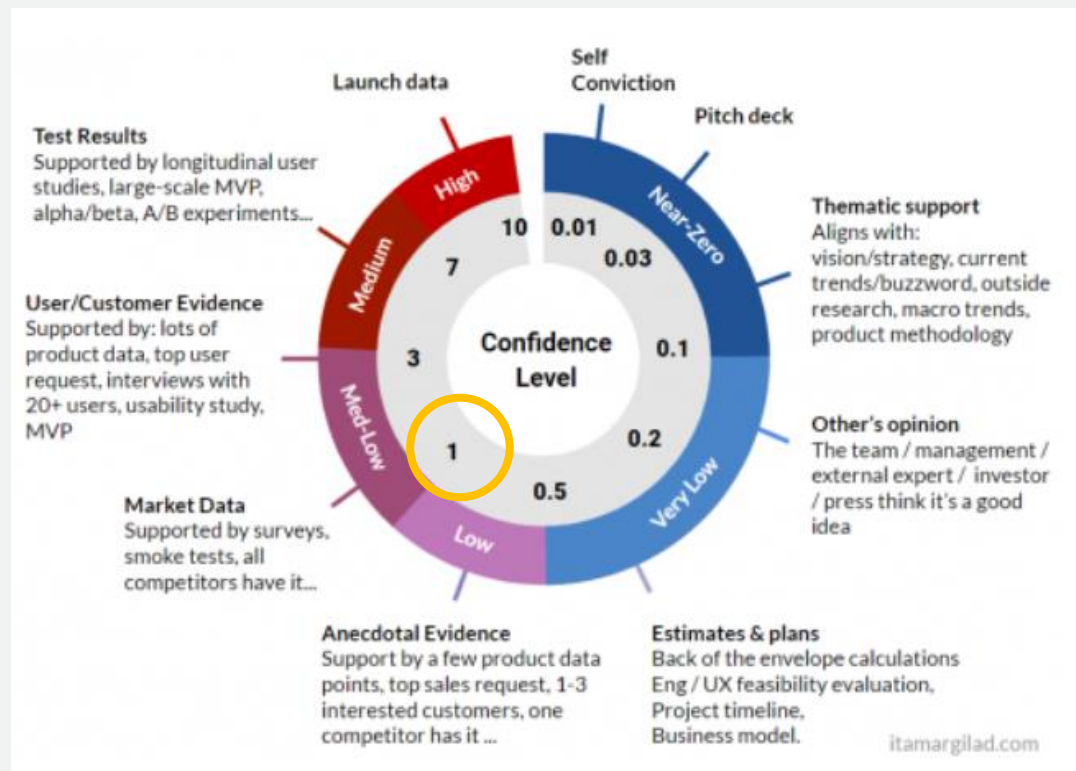
2. 検証から成長の実現に向けたステップの設計

3. 実践

90 min

検証の必要性

成長サイクルが本当に回るか確認するためには顧客の反応を検証する必要がある。



ICE スコア:

アイデアの価値を示すスコア。Impact / Confidence / Ease of implementation のスコアの掛け算で計算する。

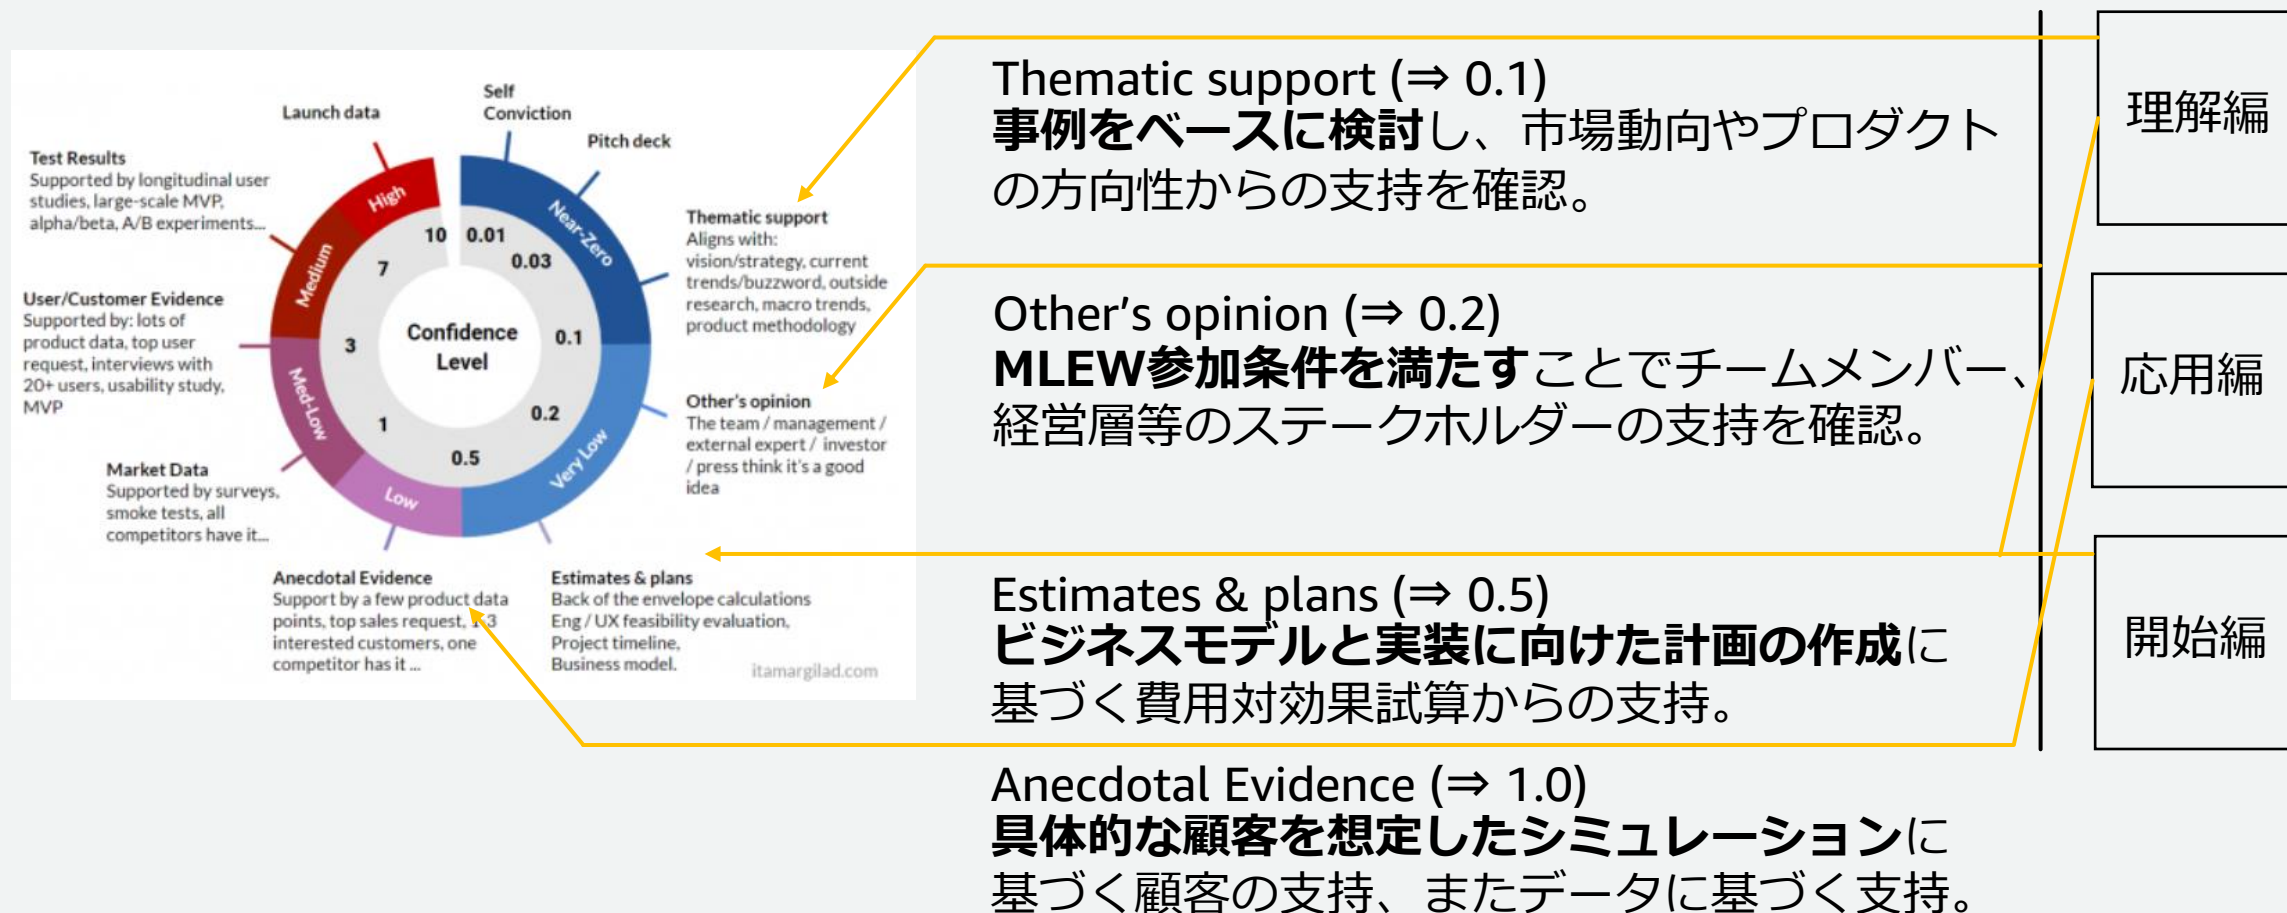
左図は Confidence のスコア表。

MLEW 終了時点だとスコアは最大 1 (Low)。

掛け算なので 1 以下はスコアを減らす。

検証の必要性

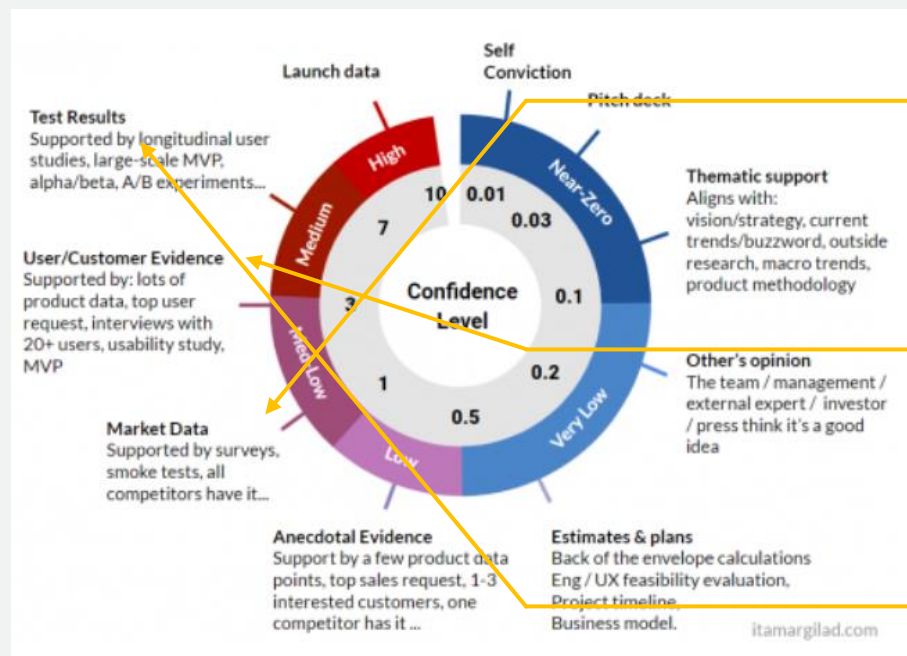
ML Enablement Workshop を通じ行ってきた検証



“[より良い製品案を選択するために役立つツール](#)” より引用

検証の必要性

1 以上に行くためには、顧客に仮説を当てる検証が不可欠。



- Market Data (⇒ 3)
テストマーケティング等による顧客の反応計測に基づく支持。
- User/Customer Evidence (⇒ 7~)
(MVP による) 20+ の顧客の反応、大量のプロダクトデータに基づく支持。
- Test Results
長期的なユーザーのサーベイ、α/β 版の反応、 A/B テストに基づく支持。

我々の想定はどれだけ顧客の実体から外れるか？

過去のワークショップの実例：

応用編で、同じ職種（営業）の経験がある参加者が提案側と顧客側に分かれてロールプレイを実施。同じ経験があれば顧客側の懸念を予測して質問を切り返すのはたやすい・・・と思いきや、**1割程度しか予測できなかった。**

実際の顧客に相對したときはそれ以上にずれる。

検証失敗のとらえ方

期待された検証結果が出ないことはもちろんある。

外れてがっかり・・・ワークショップの時間は無駄だった??

着実に成果がプラスになり、次はより大きくなる計画が必要。

落ち込まずに済む計画の立て方を本編にて解説

開始編の流れ

1. 成長サイクルの検証を開始する

2. 検証から成長の実現に向けたステップの設計

1. 成長を計測する指標を決める
2. 指標改善のマイルストーンを決める
3. 各担当のタスクを決める
4. 会議体、レポートラインを決める

開始編の流れ

1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
 1. **成長を計測する指標を決める**
 2. 指標改善のマイルストーンを決める
 3. 各担当のタスクを決める
 4. 会議体、レポートラインを決める

成長を計測する指標を決める：良い指標の条件

- 顧客体験の向上、また顧客の定着に相関がある
- 収益と相関がある（先行指標となる）
- 機械学習モデルの精度と相関がある

ex: 推薦したアイテムのうち、お気に入りに登録された数の割合

顧客体験の改善

- 顧客の好むアイテムが提案できたことを示す

ビジネスの成長

- お気に入りの商品は購入される可能性が高い

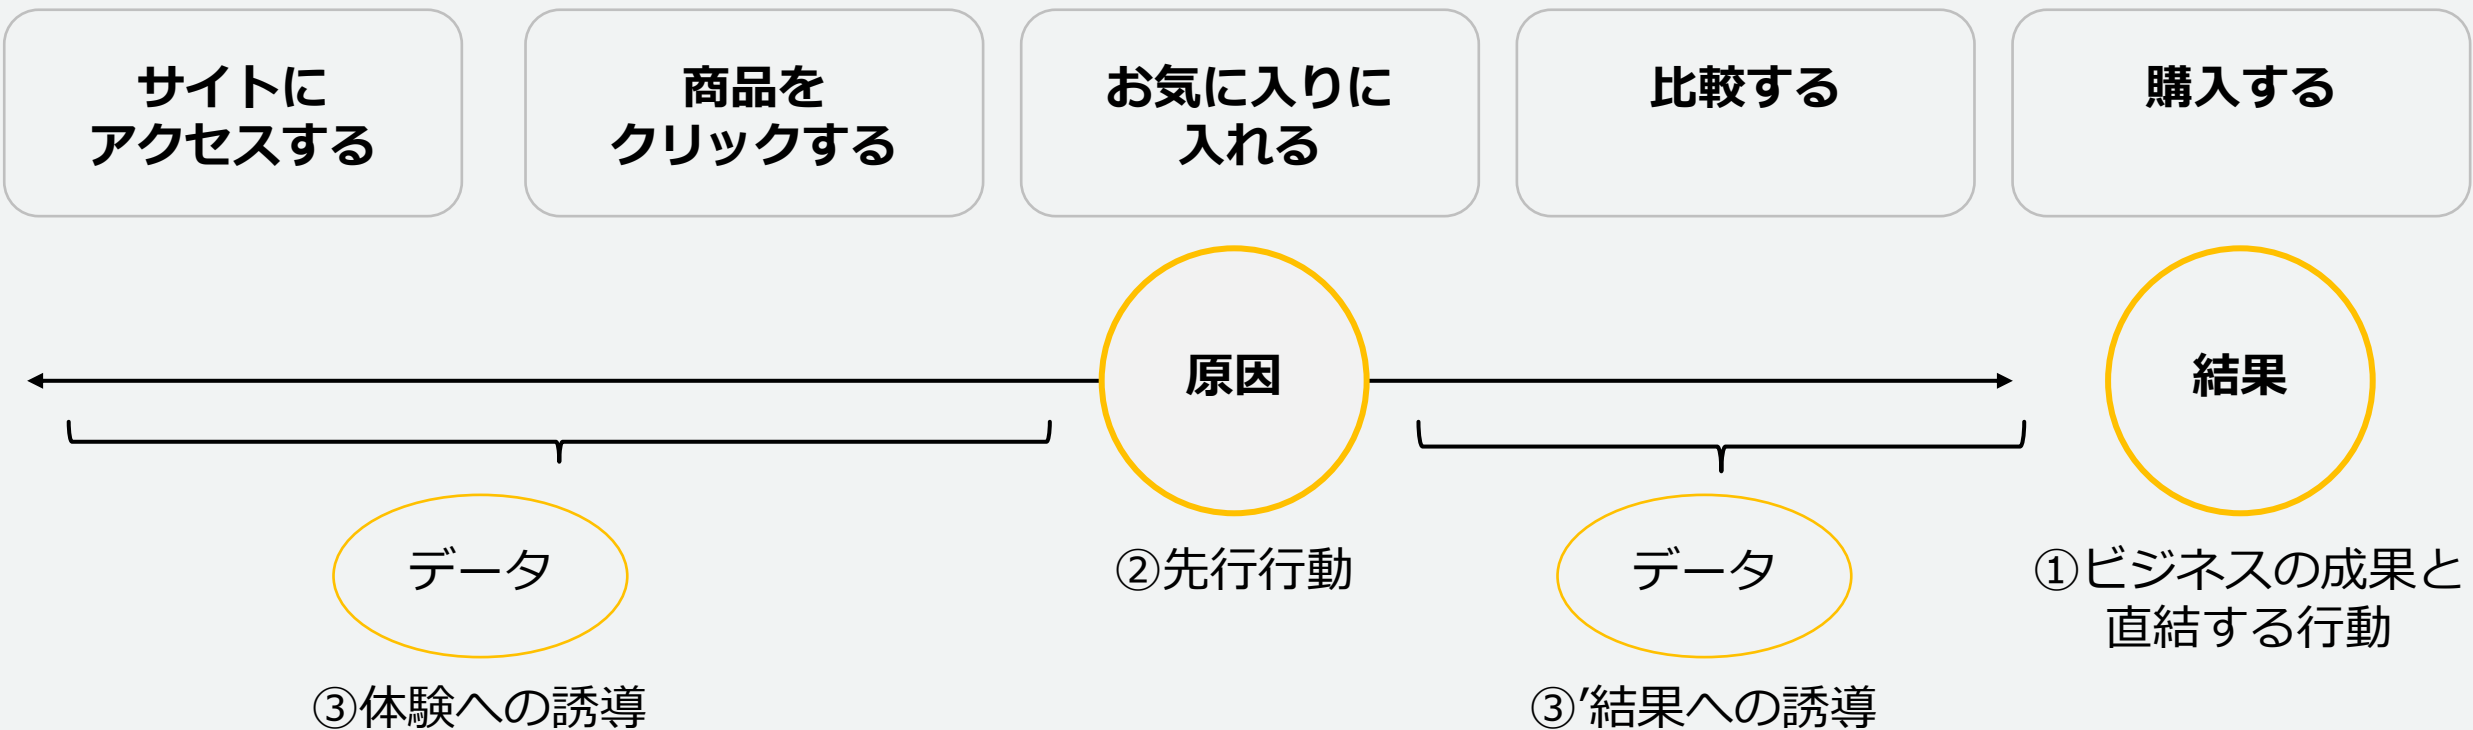
機械学習の精度向上

- ラベル付きデータを蓄積できる

計算方法の例：「[機械学習の価値を計算する](#)」を参照

指標を考える際のヒント

- ① ビジネスの成果と直結する行動を終点として決める
- ② 終点の行動に向けて顧客が能動的に取るアクションを見つける
- ③ 始点からアクションまでの間にとれるデータをみつける



良い指標の例：ユーザーの能動的な行動を表す定量値

- Amazon: プライムユーザーの購入点数
 - 購入回数が多いほど欲しい商品を提供できていることを示し、購入数は手数料収入につながる。
- Spotify: 月間コンテンツ再生時間
 - 再生時間が長いほど聞きたい曲が提供できていることを示し、長いほどサブスクリプションの購入に繋がる。
- Salesforce: 1アカウント当たりのレコード登録数
 - 登録数が多いほど活用されていることを示し、活用されているほどアカウント数が増えプランの拡大につながる。

参考：「[ノーススターメトリックの求め方](#)」

良くない指標の条件

- 顧客体験が改善されなくても上がる
- 収益との相関が薄い
- 直接学習データとして使えないデータが蓄積される

ex: トップページのアクセス数

顧客体験の改善

× 広告に釣られてきた
場合も上昇する

ビジネスの成長

△ 個別アイテムの購入
に必ずしもつながらない


機械学習の精度向上

△ アクセスログから
モデルが学習できるか？

開始編の流れ


1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
 1. 成長を計測する指標を決める
 2. 指標改善のマイルストーンを決める
 3. 各担当のタスクを決める
 4. 会議体、レポートラインを決める

マイルストンの考え方



良い例

- 目標と差はあるものの効果が出ている
- **目標と実際のギャップ**から、次はより目標達成確率が高いアクションが取れるようになっている
- 低コストで実施できる



良くない例

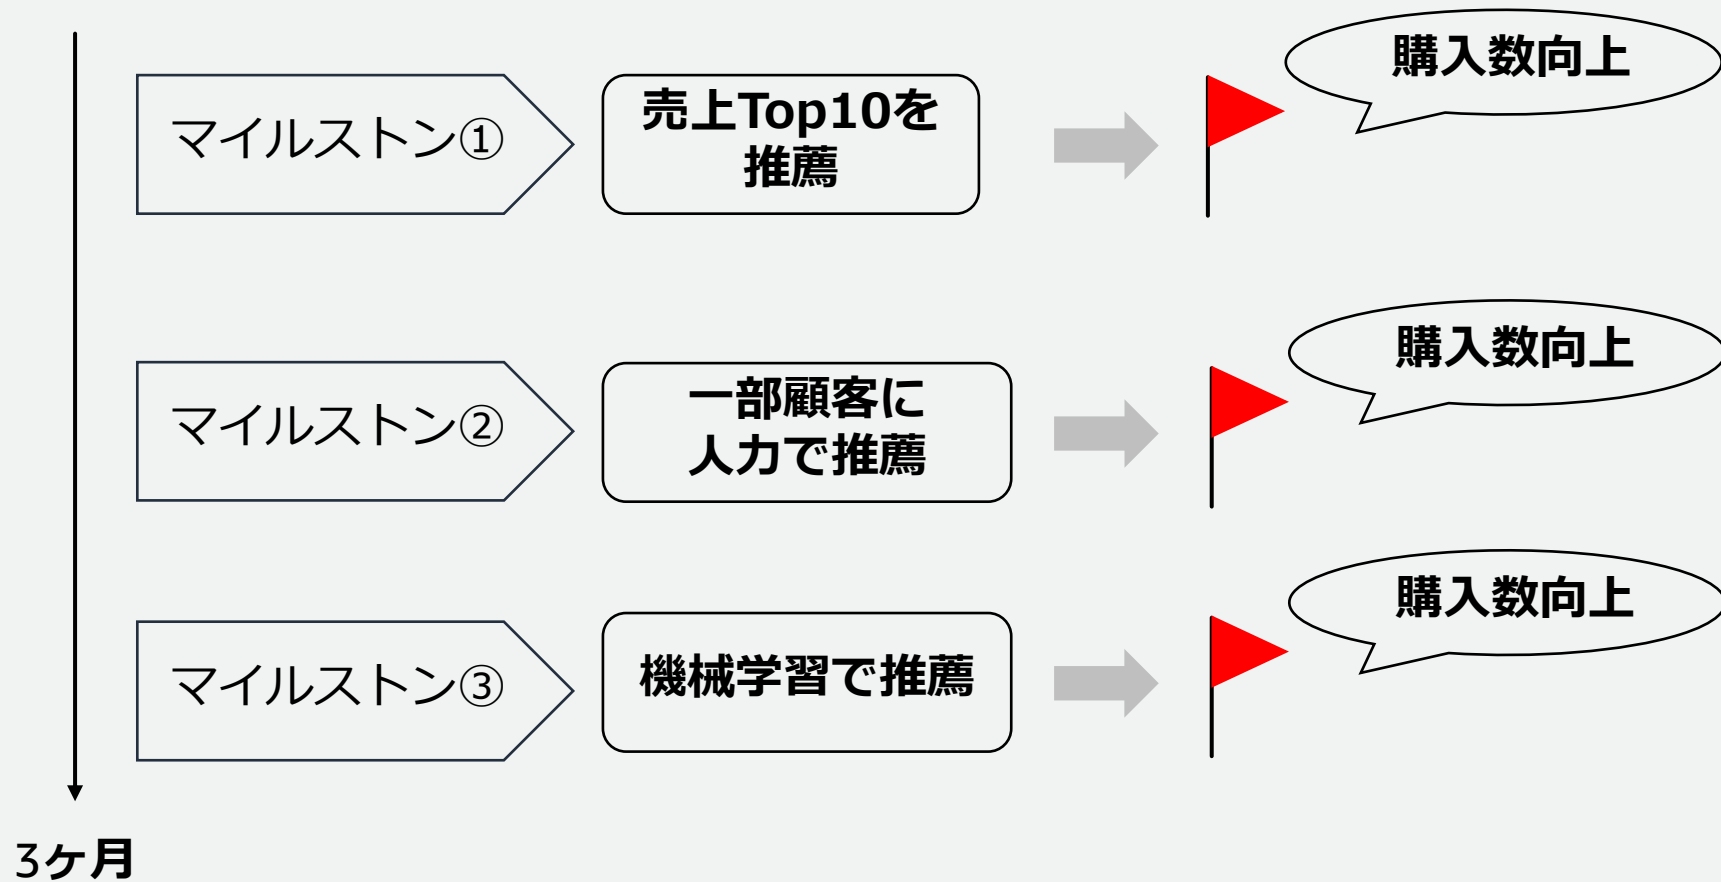
- **効果を計測していない**
- アクションと効果の因果関係がわからない
- 取得した定量・定性データに基づかない判断をする。
- 1 アクションのコストが高い

-----> 計画
—————> 実績

データを取り改善するのは当たり前と感じるかもしれないが、データ利活用に取り組む企業の 50% 近くが成果を測定していない ([DX 白書 2023 より](#))。

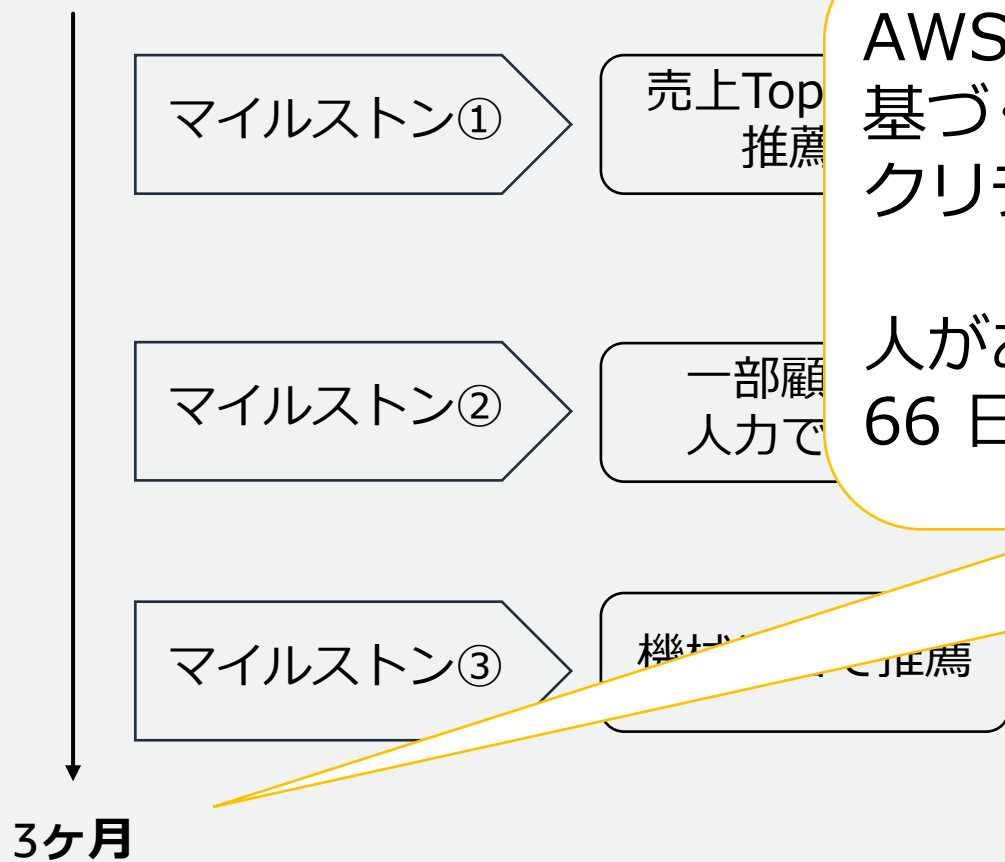
指標改善のマイルストーンを決める

どのマイルストーンでも**必ず KPI が改善されるようにする。**



指標改善のマイルストーンを決める

必ず 3 カ月以内に最初のマイルストーンを達成する。



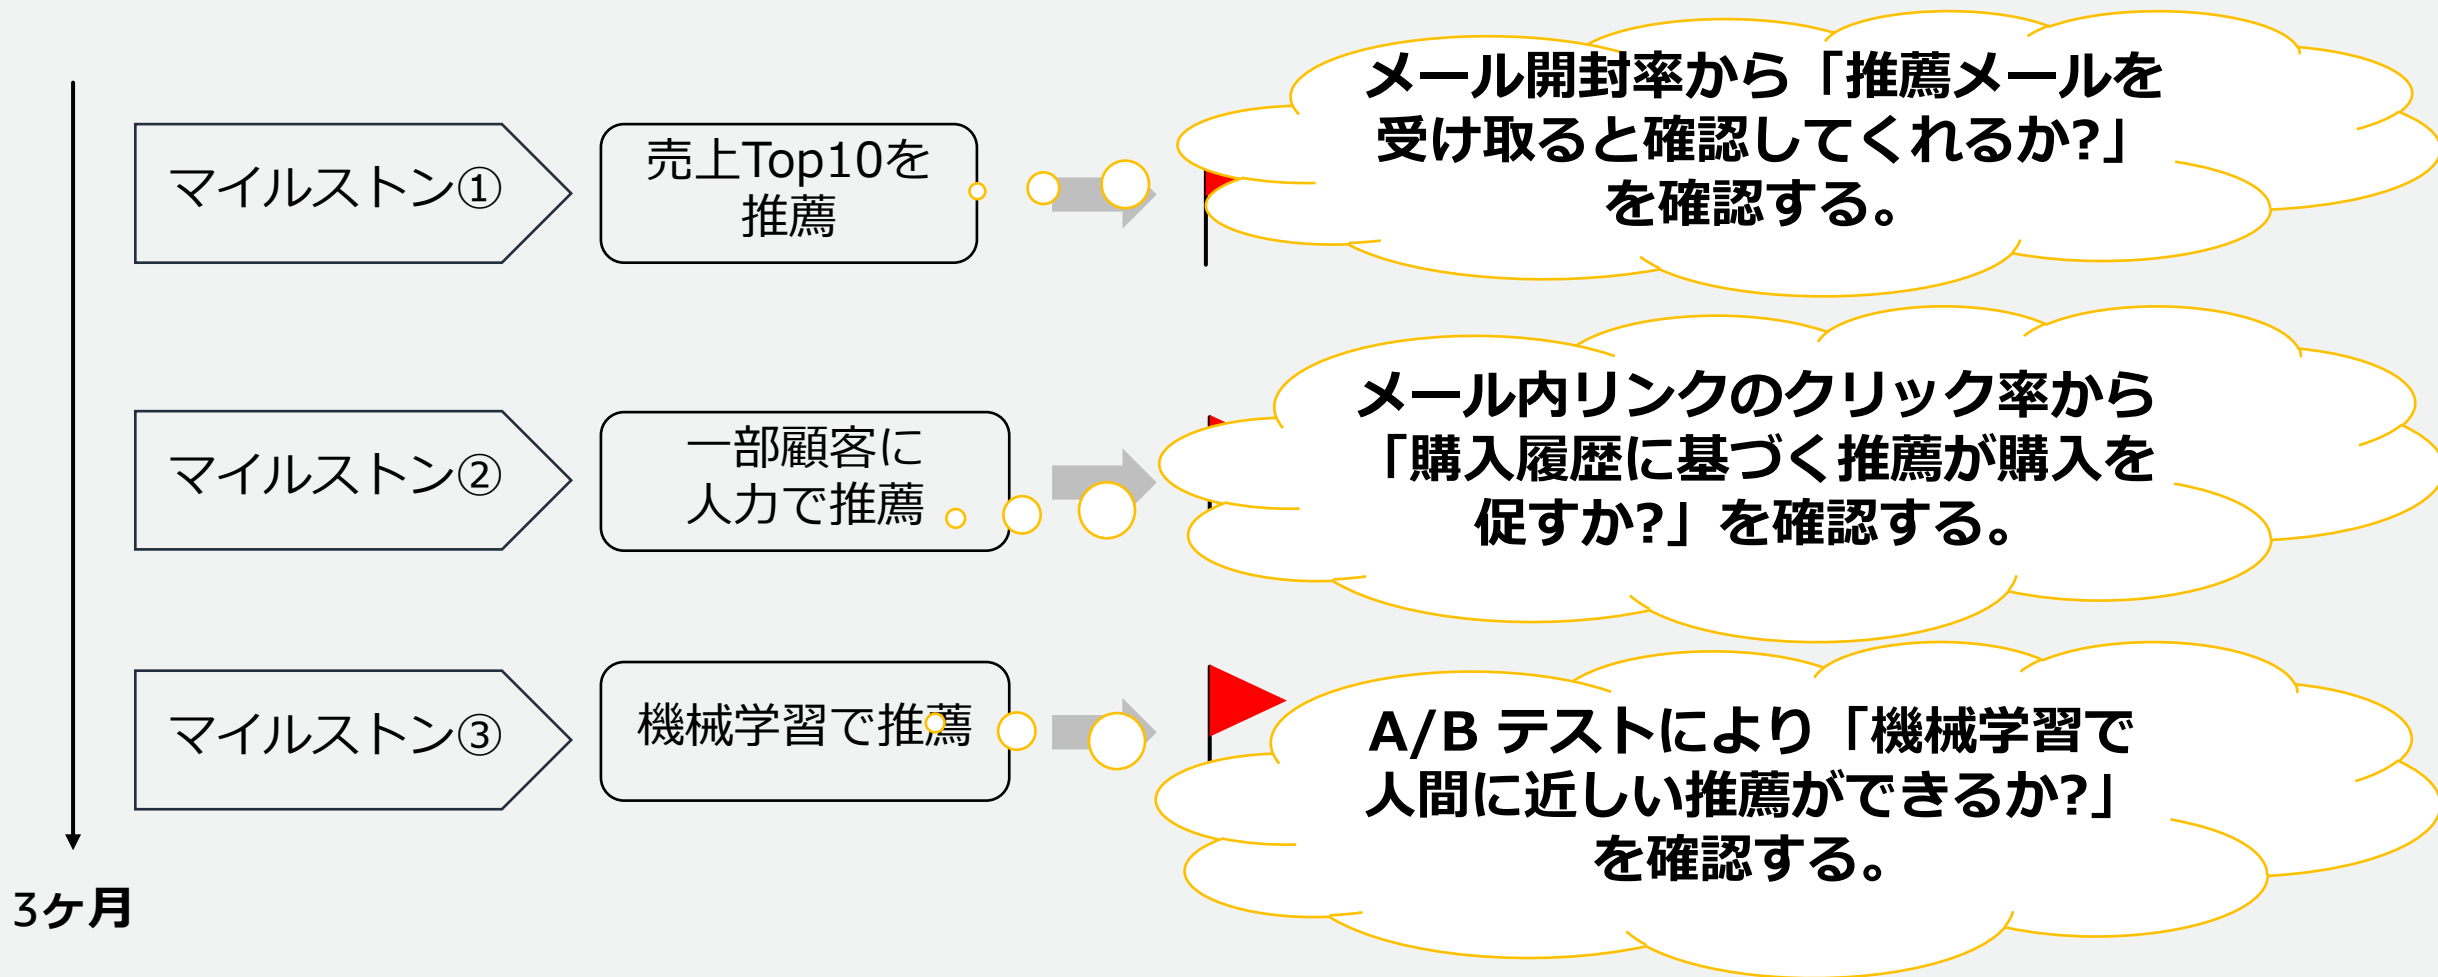
AWS の CTO に対するエンゲージメントの記録に基づく、3 ヶ月以内には AI/ML より優先すべきクリティカルなタスクが発生することが多い。

人がある習慣を身に付けるには、平均で同じ行動を 66 日 (2 カ月超) 続けることが必要 (※)

※ロンドン大学のフィリパ・ラリー博士の研究に基づく


指標改善のマイルストーンを決める

どのマイルストーンでも**データに基づき質問への回答を完了する。**



マイルストーンをクリアするたび、ストーリーとビジネスモデルを更新する。

マイルストーンを経るごとに応用編で作成したストーリーから発生する質問が解決され確度が高まり、 Day1 のビジネスモデルが成立する確率が高まる。



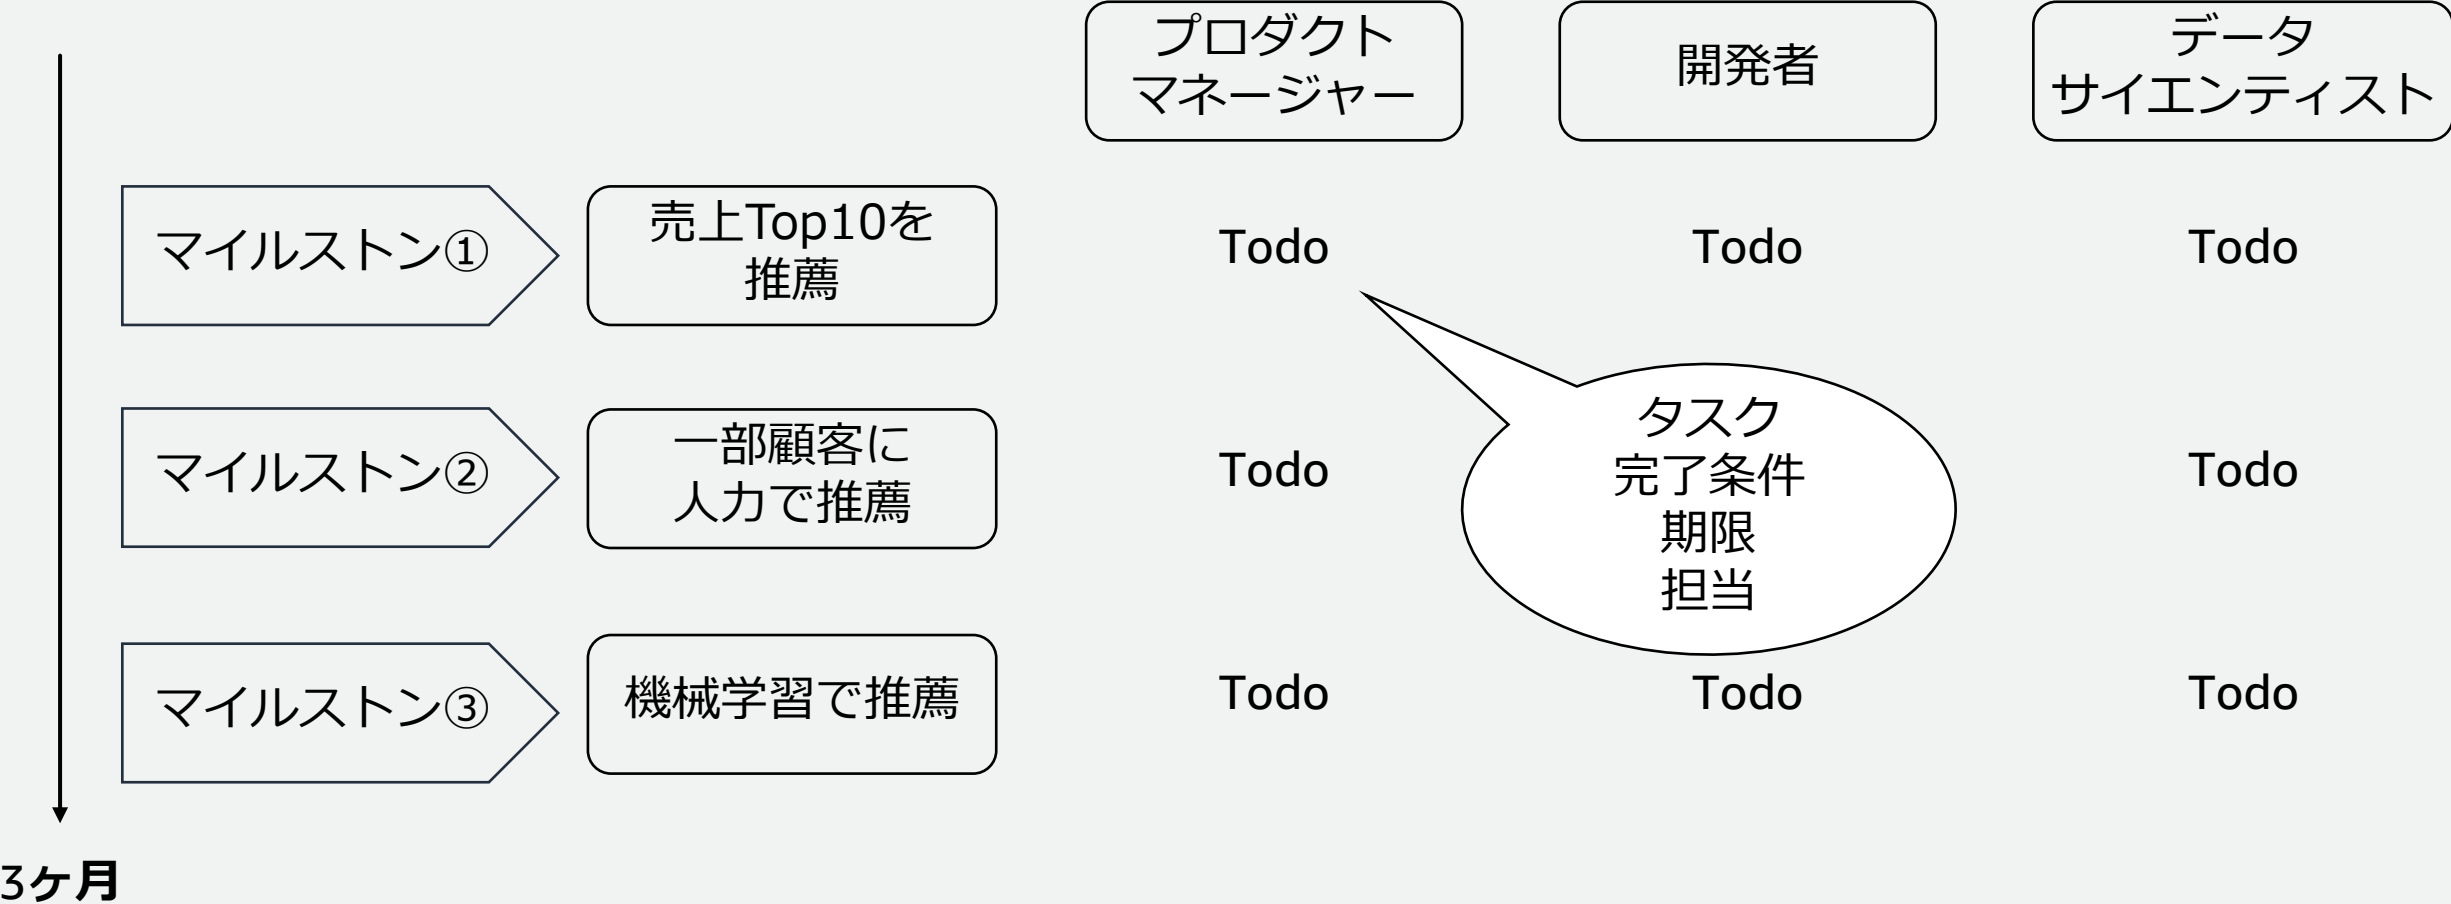
いずれもデジタル化、バージョン管理をぜひお願いします

開始編の流れ

1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
 1. 成長を計測する指標を決める
 2. 指標改善のマイルストーンを決める
 3. 各担当のタスクを決める
 4. 会議体、レポートラインを決める

各担当のタスクを決める

完了状態、期限を明確にした実行可能なタスクを定義する



開始編の流れ

1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
 1. 成長を計測する指標を決める
 2. 指標改善のマイルストーンを決める
 3. 各担当のタスクを決める
 4. 会議体、レポートラインを決める

会議体、レポートラインを決める

特に、「ワークショップ終了後最初にミーティング」と「経営への報告」を決めておく。



实践

開始編の流れ

1. 検証から成長の実現に向けたステップの設計

- | | |
|---------------------|--------|
| 1. 成長を計測する指標を決める | 20 min |
| 2. 指標改善のマイルストーンを決める | 40 min |
| 3. 各担当のタスクを決める | 20 min |
| 4. 会議体、レポートラインを決める | 10 min |

ワークショップ終了後、進捗管理が行いやすいツールに
まとめてください。

作成する成果物のイメージ




Next Step



機械学習のスケール

最初のリリースを経て、機械学習を使ったプロダクトのコツがわかってきたら迅速な検証とスケールができるよう標準化を進めていく。



[Amazon SageMaker を利用したエンタープライズのための MLOps 基盤ロードマップ](#)

機械学習のスケールをご支援する AWS のプログラム



AWS のお客様担当チームからももちろん支援を継続させていただきます。

先のフェーズの検討もご支援させていただきます

1~3 ヶ月

ユースケースの仮説検証
に着手する

異なるチームとの協調を
日常的にする

検証を繰り返し、実装に
値するユースケースを発
見する

1 年～

AI/ML の戦略構築

検証の知見をベースにした長期的な AI/ML の投資
分野の決定

組織文化の醸成

MLEW から始まったチームワークを組織全体に波
及させるための文化の醸成

データ戦略構築

仮説検証の確度と速度を速めるためのデータ基盤の
整備



Thank you!

This material is based on the AWS Machine Learning Embark Program,
an immersive ML training program provided by Amazon Machine Learning Solutions Lab