



ML Enablement Workshop #3 : 開始編

成長サイクルの検証を 開始する

久保 隆宏

Developer Relation
Machine Learning

ML Enablement Workshop

プロダクトマネージャー、開発者、データサイエンティストの3者が**組織横断的**にチームを組成し、機械学習による**成長サイクル**を実現する計画を作成する。

理解編

目的

機械学習の改善がプロダクトの成長につながるサイクルを理解し、自社プロダクトでの実現方法を考えられるようになる。

アウトプット

自社プロダクトの成長サイクルを表すビジネスモデル図

時間

・ ~2時間

応用編

目的

顧客の視点からプロダクトの体験をたどることで問題点を特定し、改善後の体験をチーム全員で共有できるようになる。

アウトプット

顧客体験、課題、改善後体験を可視化したボード

時間

・ ~3時間

開始編

目的

改善後の体験実現を最終目標とし、実現可能かつ短期で効果が確認できる最初の計画を立てられるようになる。

アウトプット

1~3 カ月間の活動と計測指標をまとめた行動計画

時間

・ ~2時間

はじめに：応用編の振り返り

- 多様な選択肢がある顧客に選ばれるにはストーリーが不可欠。
 - 顧客の生活や業務で、自社プロダクトを採用する必然性が生まれるかを Step by Step にイベントを書き出すことで確認する。
- ストーリーを可視化することで関係者を巻き込む。
 - 顧客との接点を作るのは営業、プロダクトを実装するのは開発者やデータサイエンティスト、パートナーとの契約は調達部門などビジネスモデルを実現するには様々なチームの力が必要。
- ストーリーが成立するかシミュレーションを行い検証する
 - 具体的な顧客にサービスを提案し使ってもらう様子をシミュレーションし回答すべき質問を洗い出すことで、検証のためのアクションにつなげる。

開始編で立てる計画のスコープ

1~3 ヶ月

**ユースケースを決め、
仮説検証に着手する**

**異なるチームとの協調を
日常的にする**

**チームで検証を繰り返し
価値あるユースケースを
特定する**

1 年～

AI/ML の組織戦略立案

検証を通じ得られた知見をもとに、長期的な AI/ML の投資計画を立て、推進するための組織を組成する。

データ基盤構築

仮説検証の速度、AI/ML の開発速度を速めるためのデータ基盤の設計と構築。

チームワークの醸成

MLEW から始まったチームワークを組織全体へ波及しつつ、責任ある AI 活用に向けガバナンスを整える

開始編の流れ

1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
3. 実践

20 min

90 min

開始編の流れ

1. 成長サイクルの検証を開始する

20 min

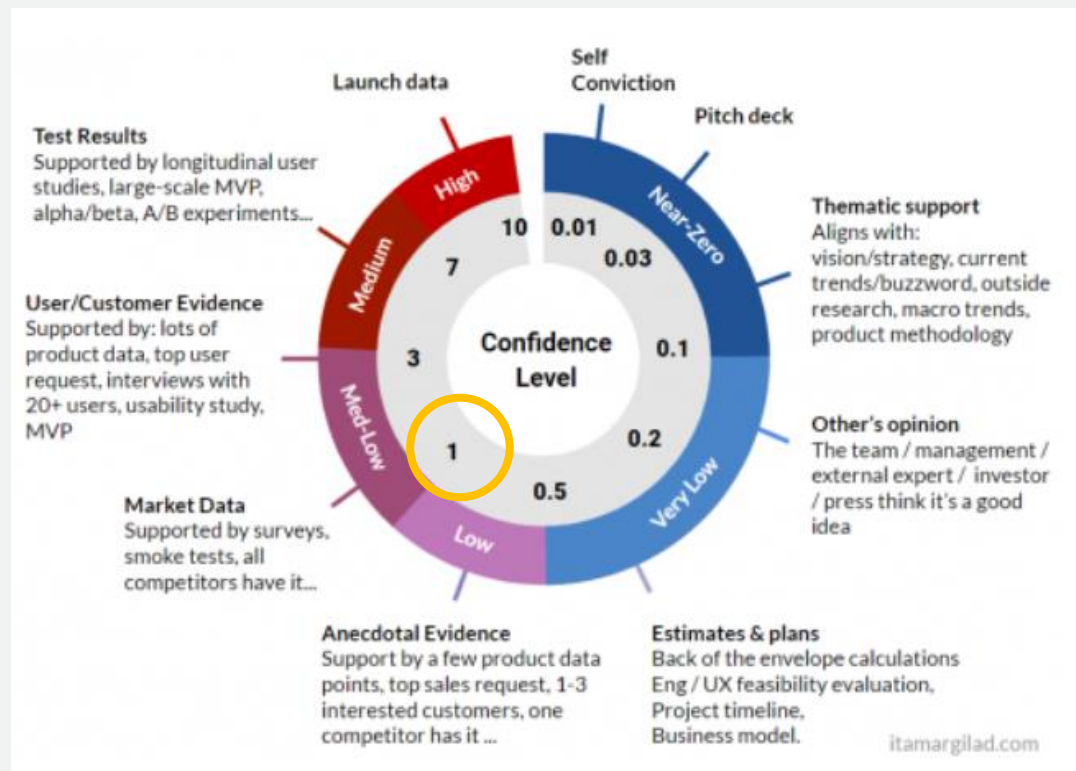
2. 検証から成長の実現に向けたステップの設計

3. 実践

90 min

検証の必要性

成長サイクルが本当に回るか確認するためには顧客の反応を検証する必要がある。



ICE スコア:

アイデアの価値を示すスコア。Impact / Confidence / Ease of implementation のスコアの掛け算で計算する。

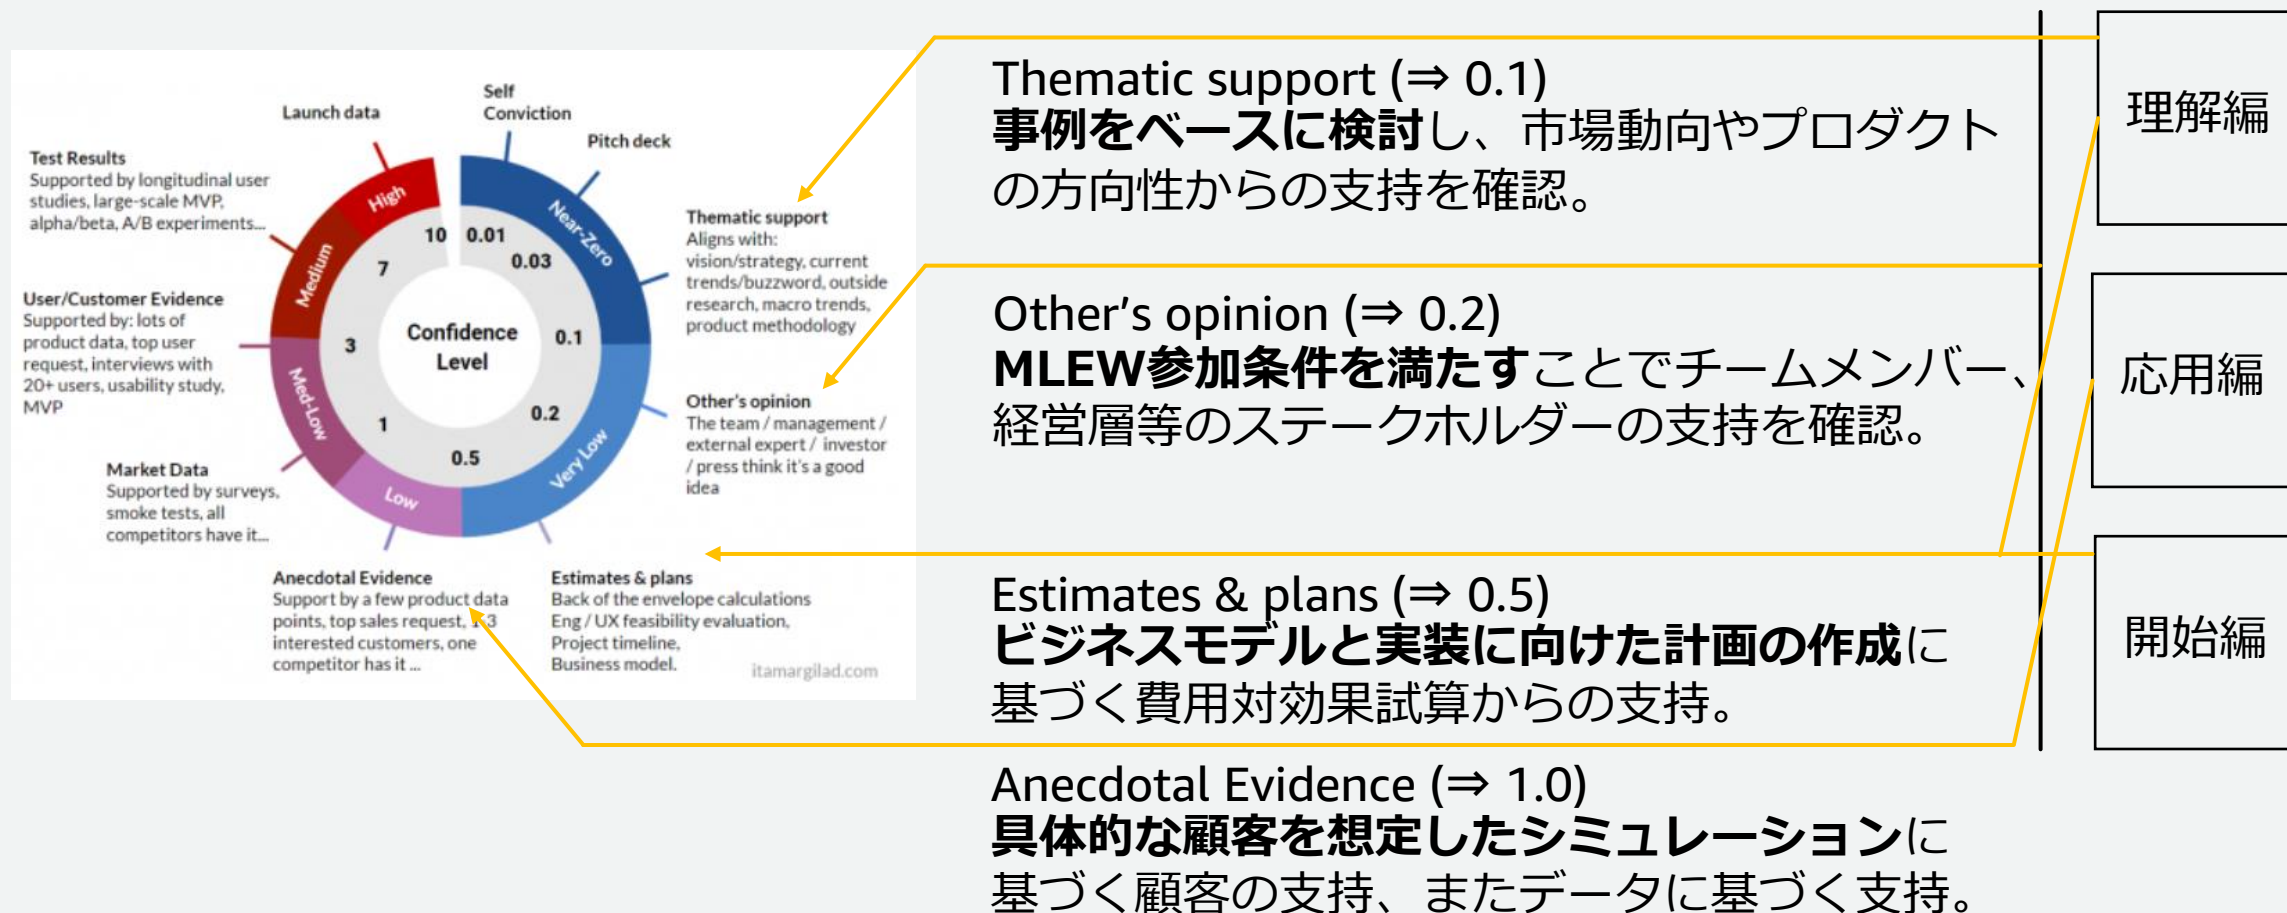
左図は **Confidence のスコア表**。

MLEW 終了時点だとスコアは最大 1 (Low)。

掛け算なので 1 以下はスコアを減らす。

検証の必要性

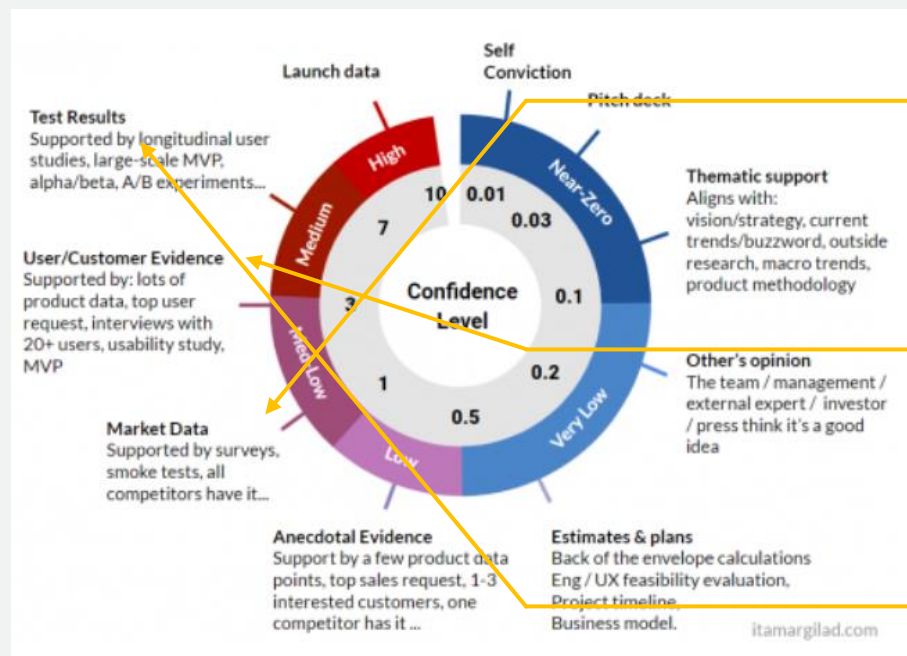
ML Enablement Workshop を通じ行ってきた検証



“[より良い製品案を選択するために役立つツール](#)” より引用

検証の必要性

1 以上に行くためには、顧客に仮説を当てる検証が不可欠。



- Market Data (⇒ 3)
テストマーケティング等による顧客の反応計測に基づく支持。
- User/Customer Evidence (⇒ 7~)
(MVP による) 20+ の顧客の反応、大量のプロダクトデータに基づく支持。
- Test Results
長期的なユーザーのサーベイ、α/β 版の反応、 A/B テストに基づく支持。

検証失敗のとらえ方

期待された検証結果が出ないことはもちろんある。

外れてがっかり・・・ワークショップの時間は無駄だった??

着実に成果がプラスになり、次はより大きくなる計画が必要。

落ち込まずに済む計画の立て方を本編にて解説

開始編の流れ

1. 成長サイクルの検証を開始する

2. 検証から成長の実現に向けたステップの設計

1. 成長を計測する指標を決める
2. 指標改善のマイルストーンを決める
3. 各担当のタスクを決める
4. 会議体、レポートラインを決める

開始編の流れ

1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
 1. 成長を計測する指標を決める
 2. 指標改善のマイルストーンを決める
 3. 各担当のタスクを決める
 4. 会議体、レポートラインを決める

成長を計測する指標を決める：良い指標の条件

- 顧客体験の向上、また顧客の定着に相関がある
- 収益と相関がある（先行指標となる）
- 機械学習モデルの精度と相関がある

ex: 推薦したアイテムのうち、お気に入りに登録された数の割合

顧客体験の改善

- 顧客の好むアイテムが提案できたことを示す

ビジネスの成長

- お気に入りの商品は購入される可能性が高い

機械学習の精度向上

- ラベル付きデータを蓄積できる

計算方法の例：「[機械学習の価値を計算する](#)」を参照

良い指標の例：ユーザーの能動的な行動を表す定量値

- Amazon: プライムユーザーの購入点数
 - 購入回数が多いほど欲しい商品を提供できていることを示し、購入数は手数料収入につながる。
- Spotify: 月間コンテンツ再生時間
 - 再生時間が長いほど聞きたい曲が提供できていることを示し、長いほどサブスクリプションの購入に繋がる。
- Salesforce: 1アカウント当たりのレコード登録数
 - 登録数が多いほど活用されていることを示し、活用されているほどアカウント数が増えプランの拡大につながる。

参考：「[ノーススターメトリックの求め方](#)」

良くない指標の条件

- 顧客体験が改善されなくても上がる
- 収益との相関が薄い
- 直接学習データとして使えないデータが蓄積される

ex: トップページのアクセス数

顧客体験の改善

× 広告に釣られてきた
場合も上昇する

ビジネスの成長

△ 個別アイテムの購入
に必ずしもつながらない


機械学習の精度向上

△ アクセスログから
モデルが学習できるか？

開始編の流れ


1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
 1. 成長を計測する指標を決める
 2. 指標改善のマイルストーンを決める
 3. 各担当のタスクを決める
 4. 会議体、レポートラインを決める

マイルストンの考え方



良い例

- どのマイルストーンでも KPI が改善される（計画よりずれることはあっても）
- ストーリー中の問いが徐々に解消され、より目標達成確率が高いアクションが取れるようになっている。
- 1 アクションのコストが KPI 改善に比べ低い



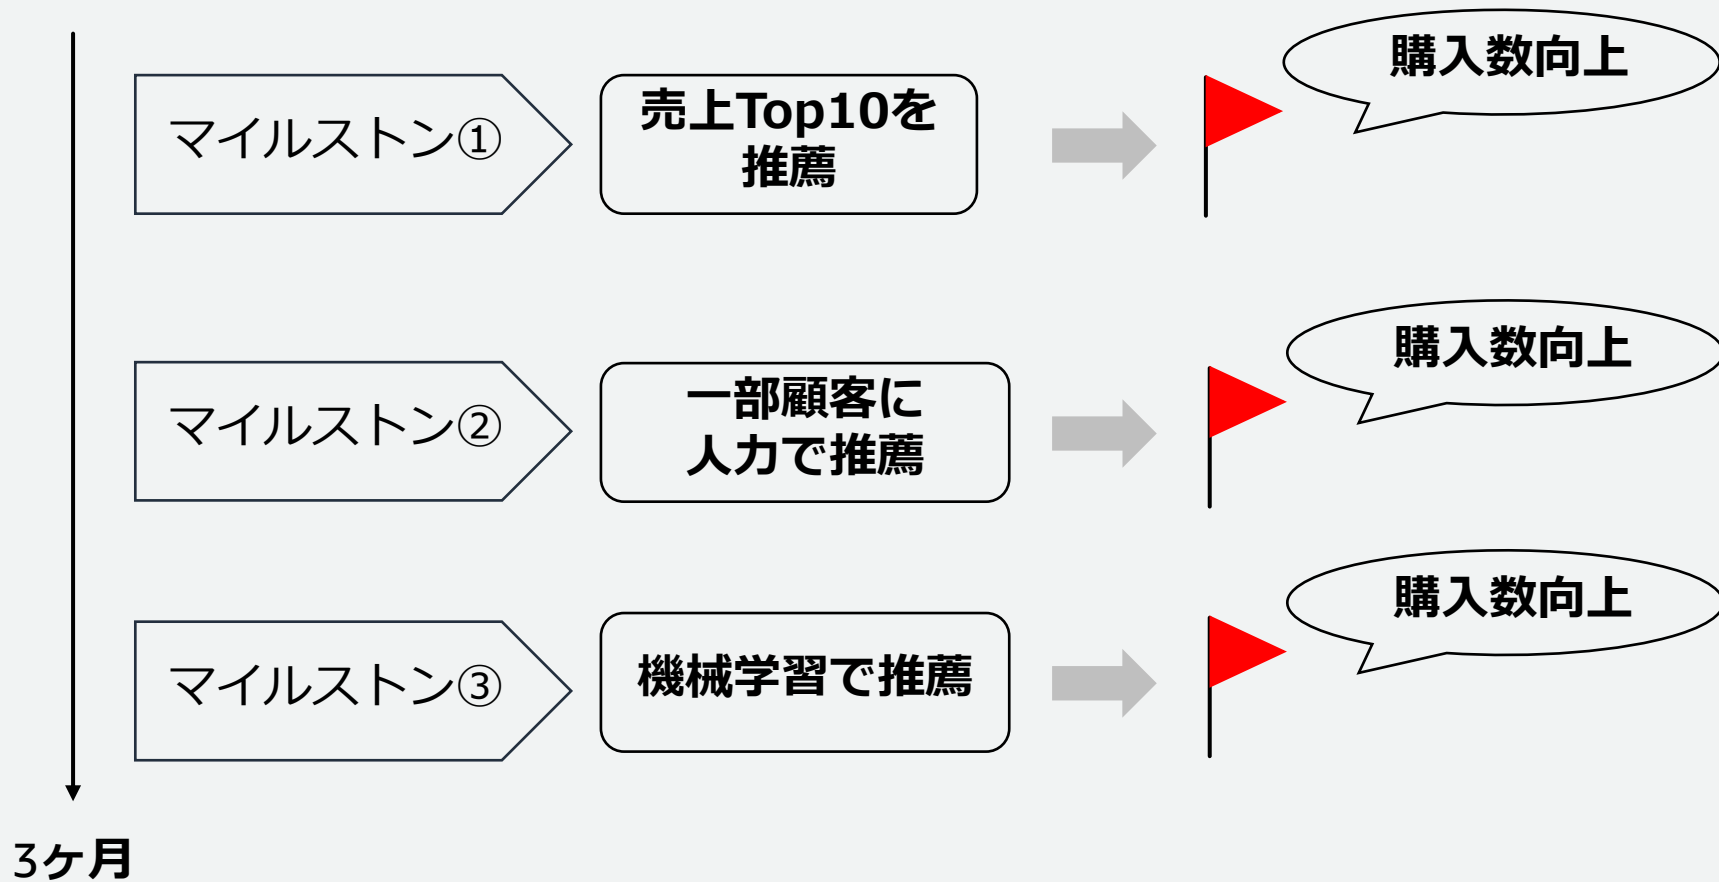
良くない例

- 単体で KPI が改善されないマイルストーンがある（「モデルを作る」など）
- 問いが証明されたか曖昧で次の不確実性が下がらない。（証明に必要なデータ量や項目の合意漏れなど）
- 1 アクションのコストが高い（モデルを作り直す等）

-----> 計画
—————> 実績

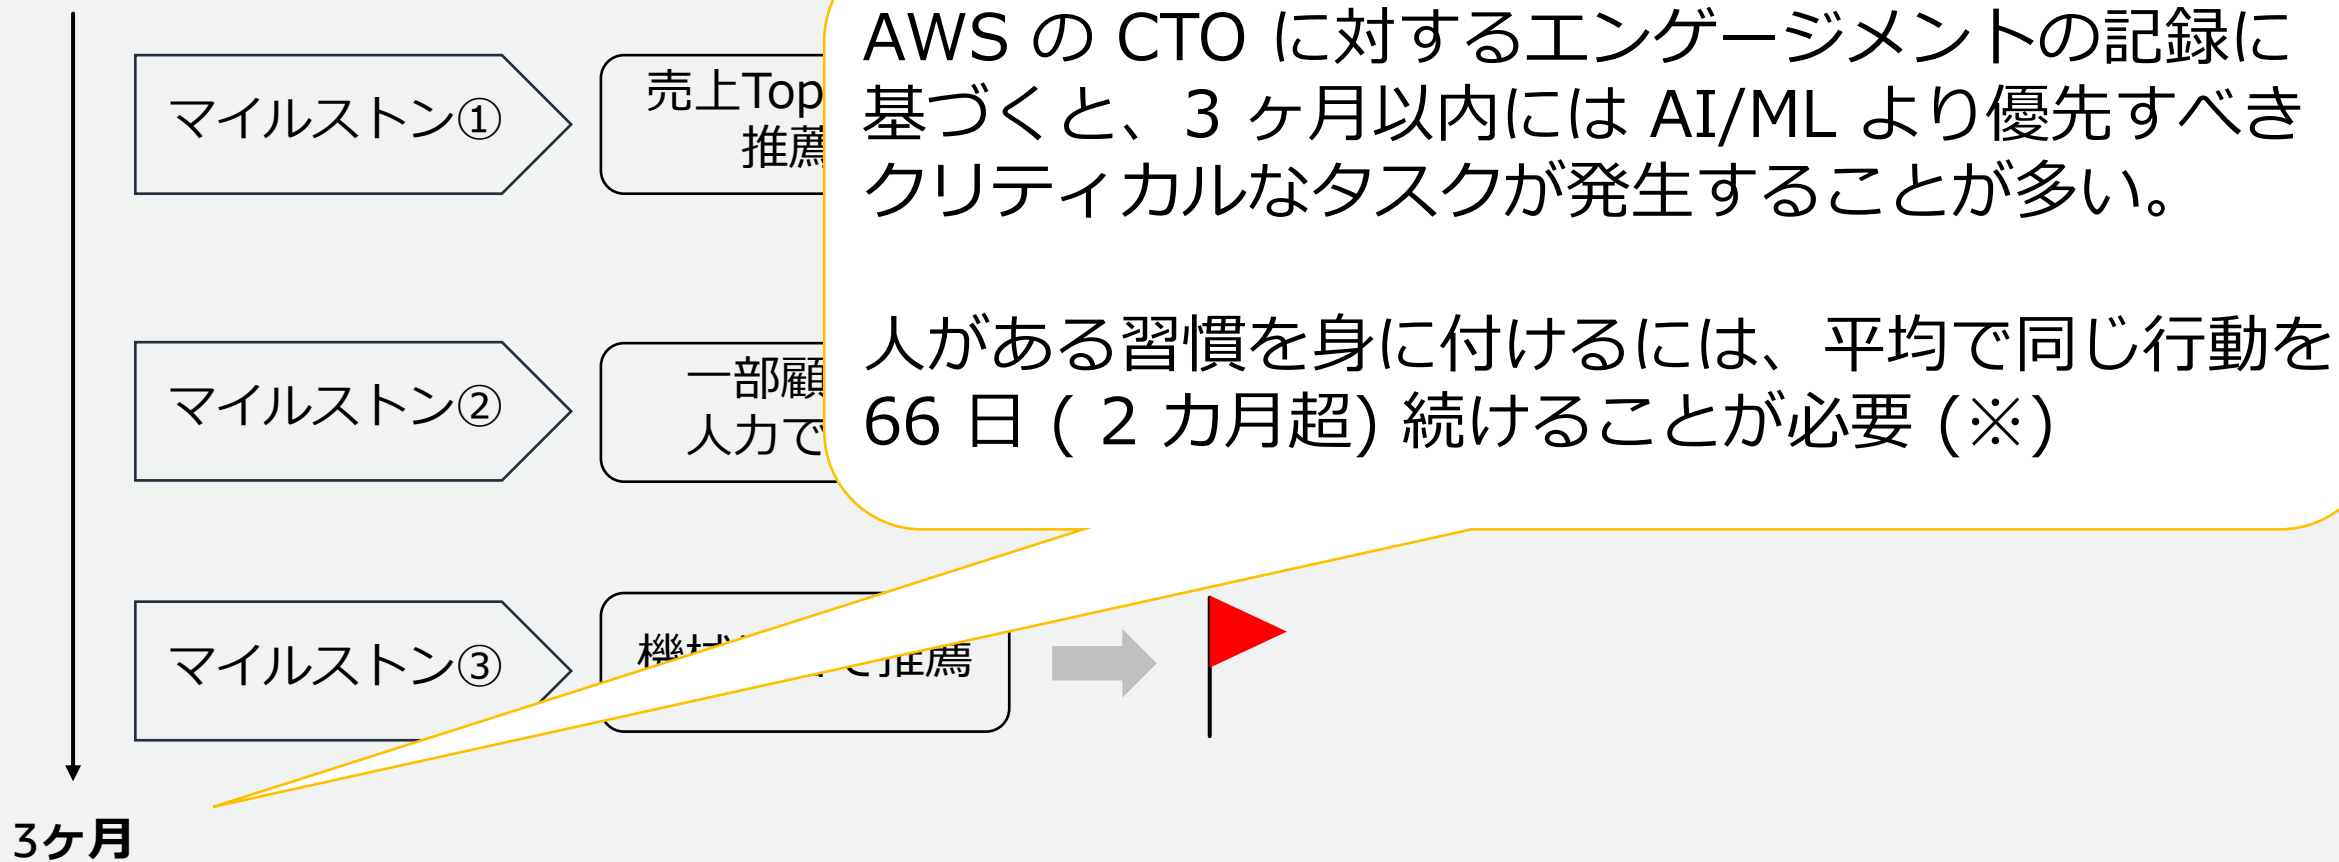
指標改善のマイルストーンを決める

どのマイルストーンでも**必ず KPI が改善されるようにする。**



指標改善のマイルストーンを決める

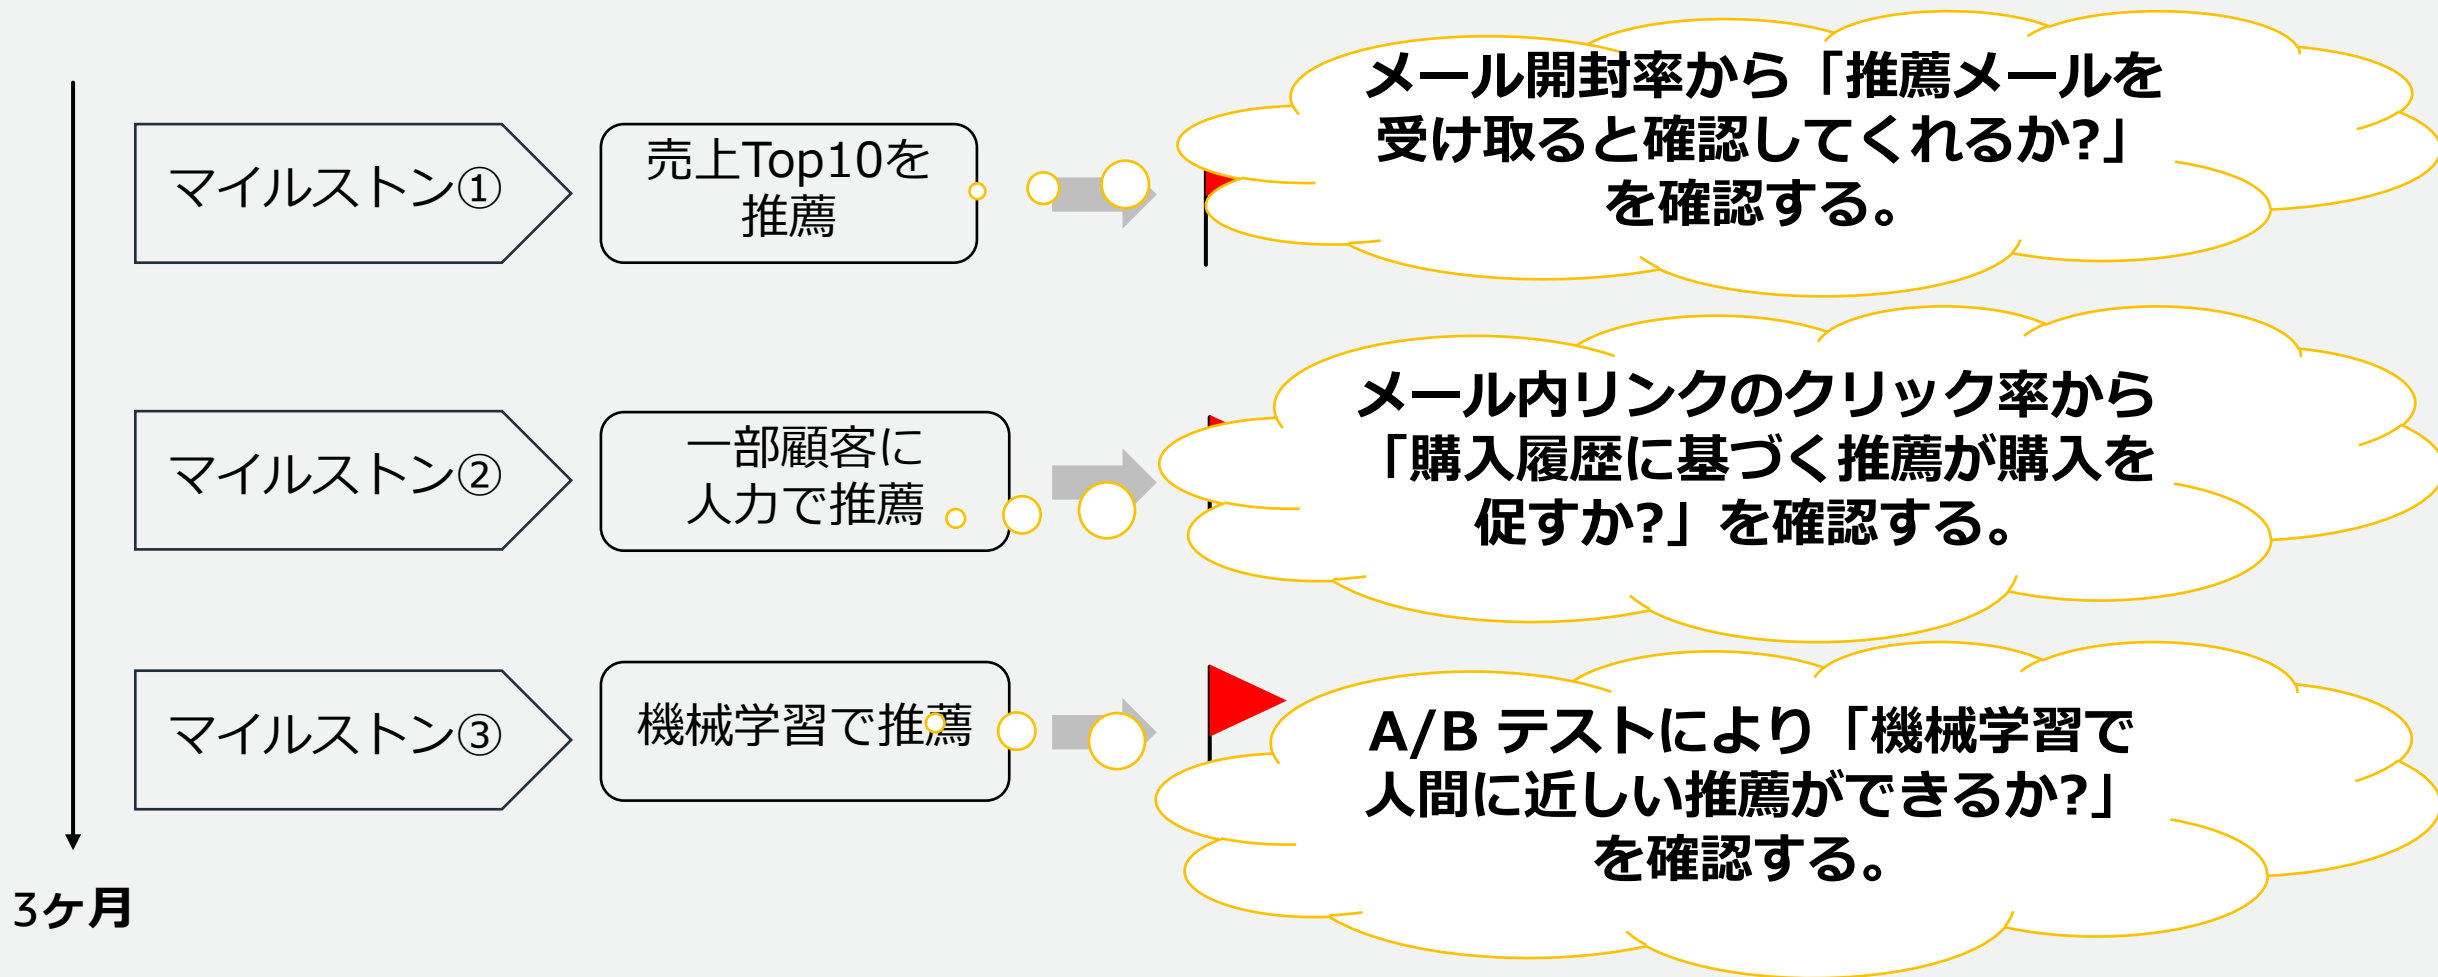
必ず 3 カ月以内に最初のマイルストーンを達成する。



※ロンドン大学のフィリパ・ラリー博士の研究に基づく

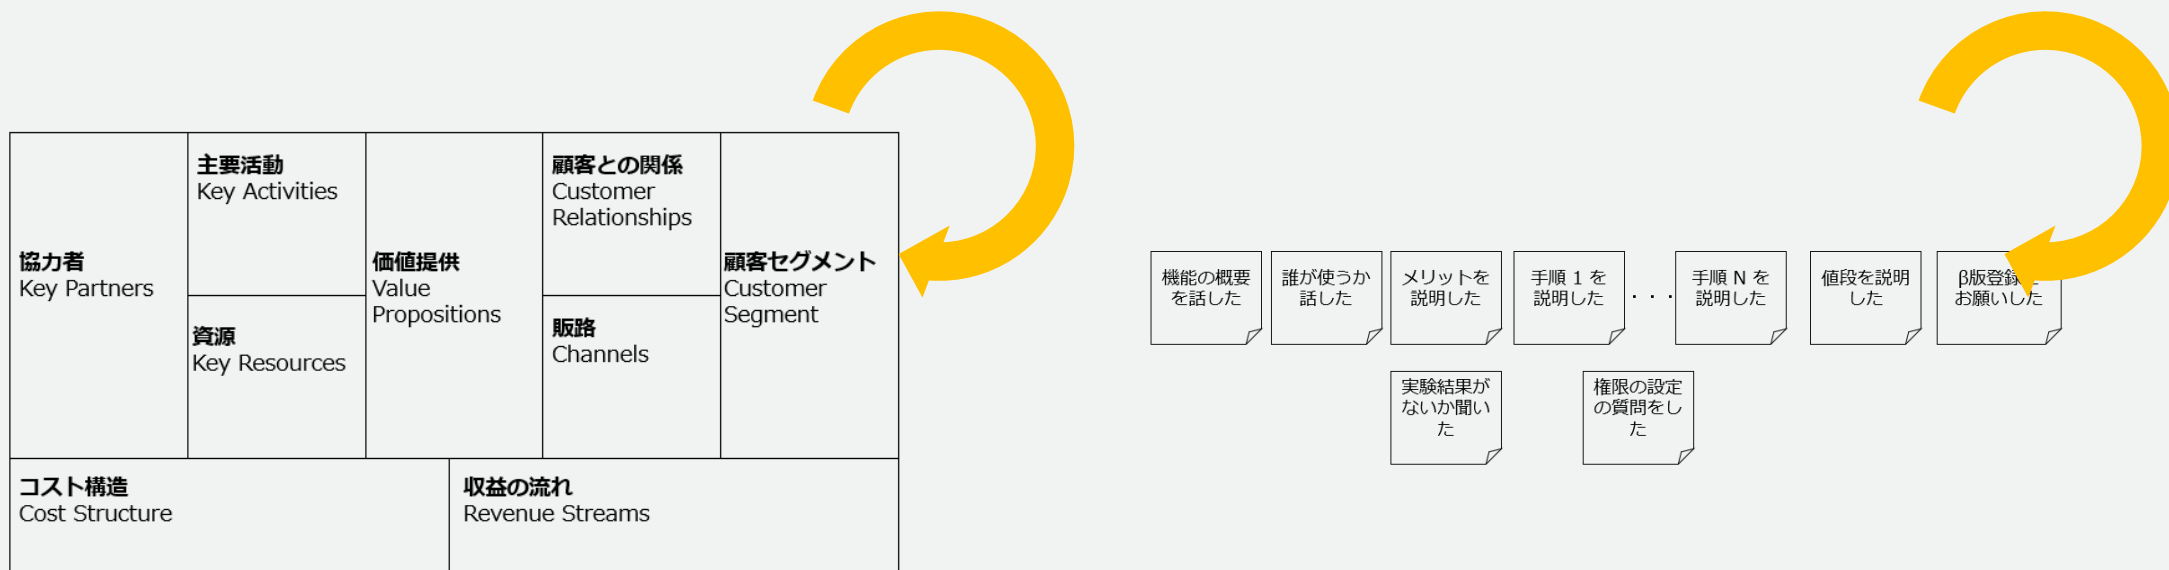
指標改善のマイルストーンを決める

どのマイルストーンでも**データに基づき質問への回答を完了する。**



マイルストーンをクリアするたび、ストーリーとビジネスモデルを更新する。

マイルストーンを経るごとに応用編で作成したストーリーから発生する質問が解決され確度が高まり、 Day1 のビジネスモデルが成立する確率が高まる。

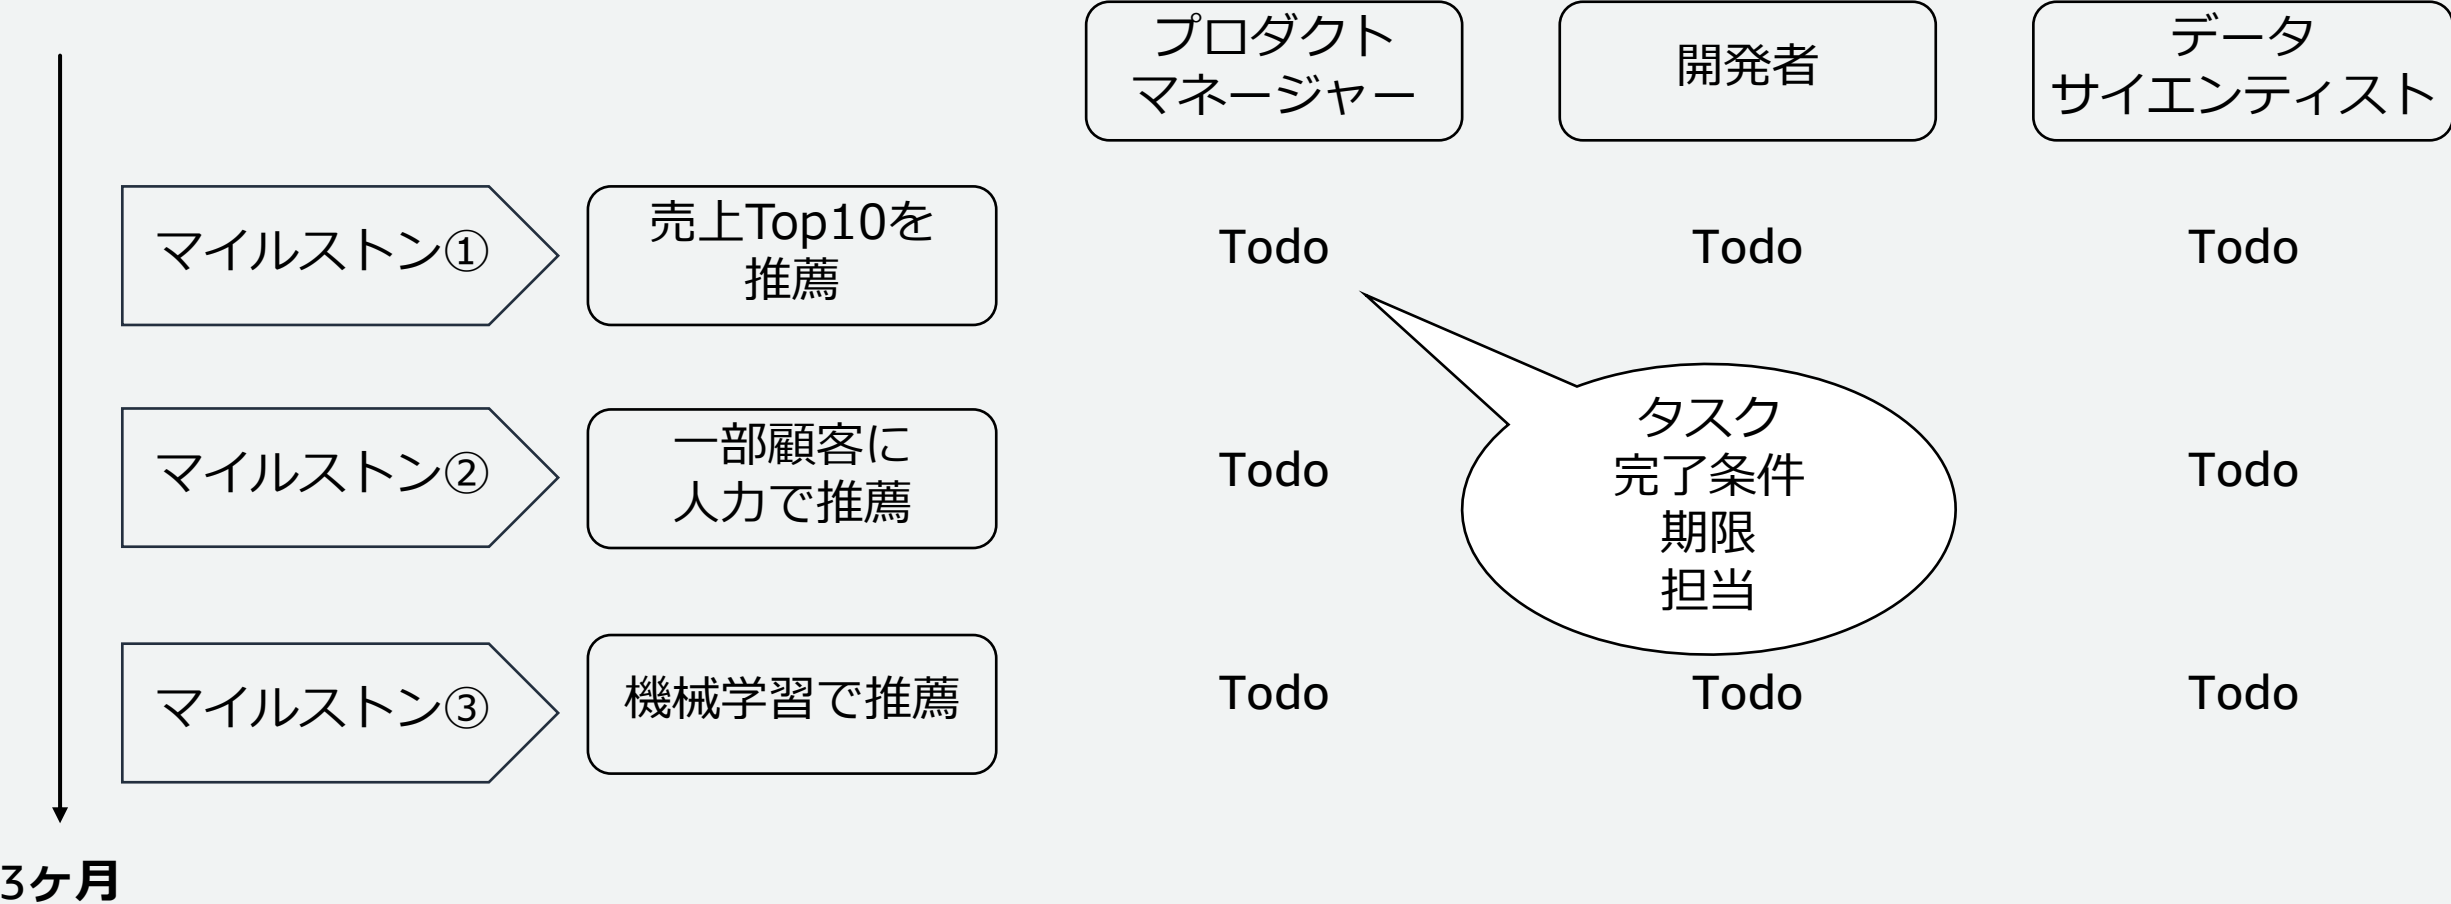


開始編の流れ

1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
 1. 成長を計測する指標を決める
 2. 指標改善のマイルストーンを決める
 3. 各担当のタスクを決める
 4. 会議体、レポートラインを決める

各担当のタスクを決める

完了状態、期限を明確にした実行可能なタスクを定義する



開始編の流れ

1. 成長サイクルの検証を開始する
2. 検証から成長の実現に向けたステップの設計
 1. 成長を計測する指標を決める
 2. 指標改善のマイルストーンを決める
 3. 各担当のタスクを決める
 4. 会議体、レポートラインを決める

会議体、レポートラインを決める

特に、「ワークショップ終了後最初にミーティング」と「経営への報告」を決めておく。



实践

開始編の流れ

1. 検証から成長の実現に向けたステップの設計

- | | |
|---------------------|--------|
| 1. 成長を計測する指標を決める | 20 min |
| 2. 指標改善のマイルストーンを決める | 40 min |
| 3. 各担当のタスクを決める | 20 min |
| 4. 会議体、レポートラインを決める | 10 min |

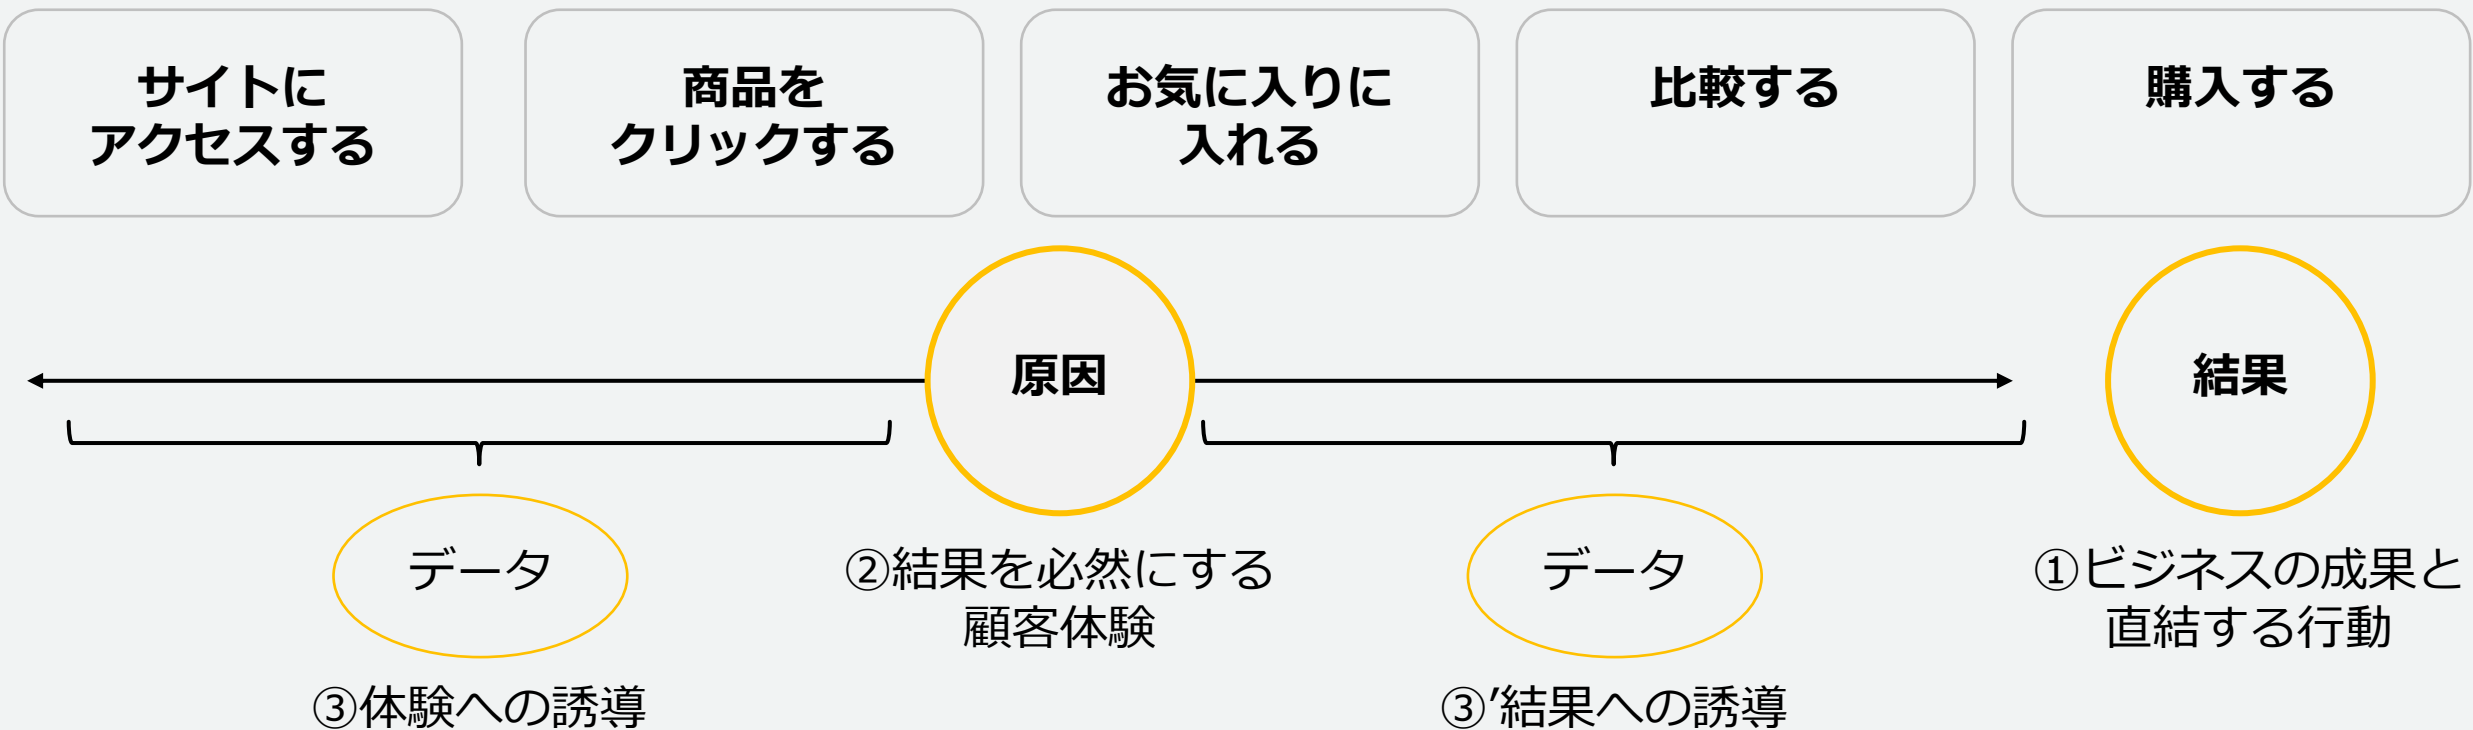
ワークショップ終了後、進捗管理が行いやすいツールに
まとめてください。

作成する成果物のイメージ



指標を考える際のヒント

- ① ビジネスの成果と直結する行動を終点として決める
- ② 終点の行動を必然とする顧客体験を遡り特定する
- ③ 体験 / 結果、いずれか誘導したいほうに合わせて蓄積データを選ぶ

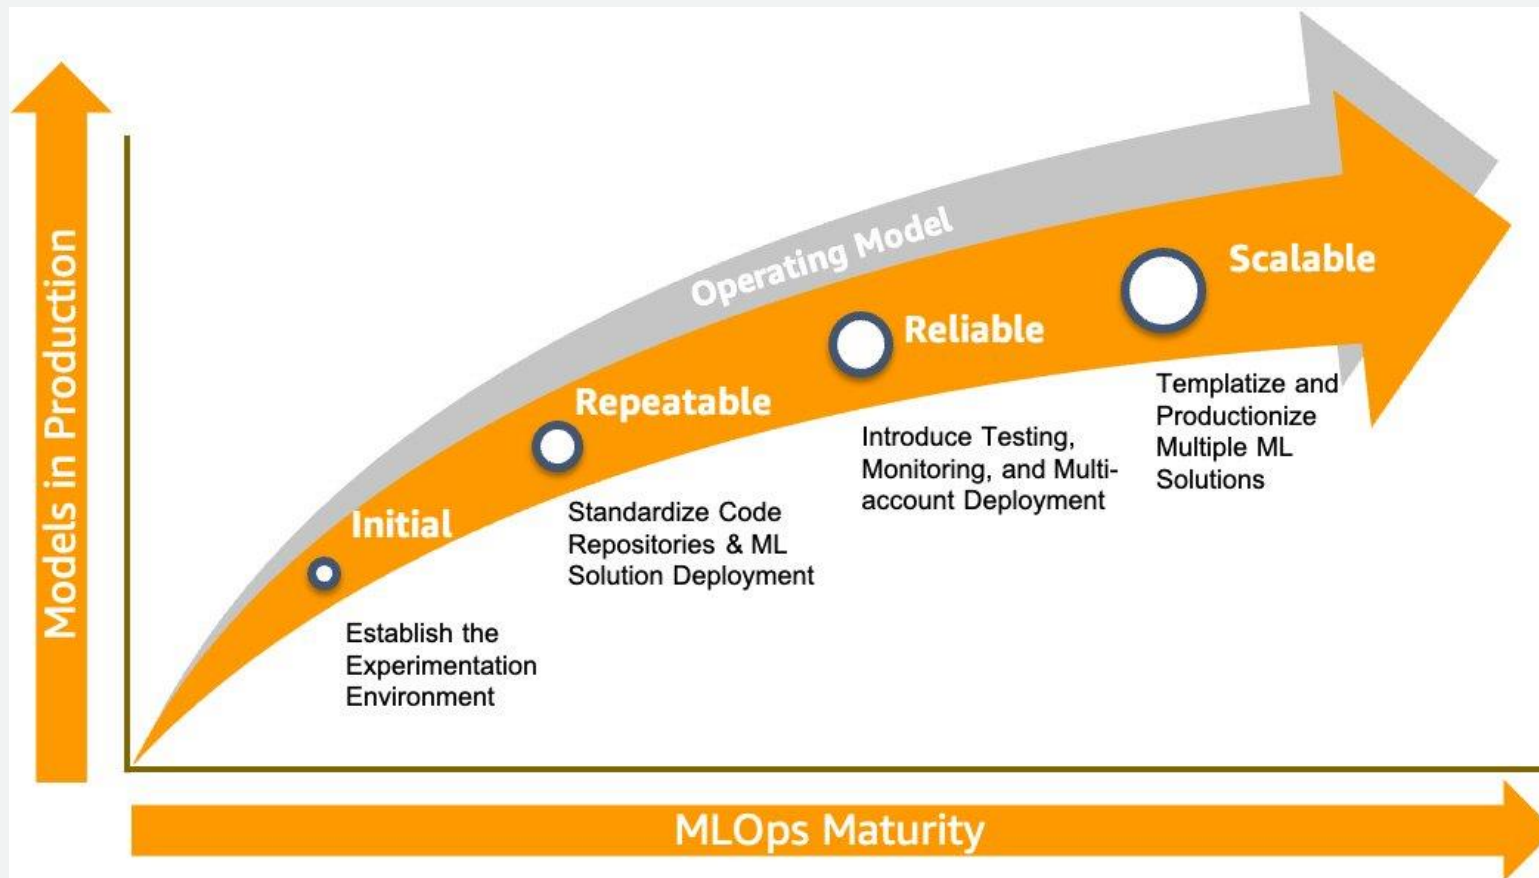


Next Step



機械学習のスケール

最初のリリースを経て、機械学習を使ったプロダクトのコツがわかってきたら迅速な検証とスケールができるよう標準化を進めていく。



[Amazon SageMaker を利用したエンタープライズのための MLOps 基盤ロードマップ](#)

機械学習のスケールをご支援する AWS のプログラム



AWS のアカウントチームからももちろん支援を継続させていただきます。
アカウントチームは、必要に応じ MLEW 運営のメンバーを招聘します。



先のフェーズの検討もご支援させていただきます

1~3 ヶ月

ユースケースの仮説検証
に着手する

異なるチームとの協調を
日常的にする

検証を繰り返し、実装に
値するユースケースを発
見する

1 年～

AI/ML の戦略構築

検証の知見をベースにした長期的な AI/ML の投資
分野の決定

組織文化の醸成

MLEW から始まったチームワークを組織全体に波
及させるための文化の醸成

データ戦略構築

仮説検証の確度と速度を速めるためのデータ基盤の
整備



Thank you!

This material is based on the AWS Machine Learning Embark Program,
an immersive ML training program provided by Amazon Machine Learning Solutions Lab